IMPLEMENTASI *SUPPORT VECTOR MACHINE* UNTUK ANALISIS SENTIMEN TERHADAP FENOMENA TAKUT MENIKAH PADA PLATFORM X

LAPORAN PROYEK TUGAS AKHIR

Disusun Oleh:

HASNA OKTAVIANI

5221811028

PROGRAM STUDI SAINS DATA

FAKULTAS SAINS & TEKNOLOGI

UNIVERSITAS TEKNOLOGI YOGYAKARTA

2026

LEMBAR PENGESAHAN

IMPLEMENTASI *SUPPORT VECTOR MACHINE* UNTUK ANALISIS SENTIMEN TERHADAP FENOMENA TAKUT MENIKAH PADA PLATFORM X

Disusun Oleh:

HASNA OKTAVIANI
5221811028

Telah dipertahankan di depan Dewan Penguji

Pada tanggal 24 Juni 2026

DEWAN PENGUJI

Nama & Gelar	Jabatan	Tanda Tangan	Tanggal
Tri Widodo, S.T., M.Kom. **NIK. 110215071**	Ketua penguji	.....	2/7 2026
Anita Fira Waluyo, S.Si., M.Sc. **NIK. 110717132**	Penguji I	.....	2/07 '26
Muhammad Fachrie, S.T., M.Cs. **NIK. 110517125**	Penguji II (Dosen Pembimbing)	.....	3/07-2026

Yogyakarta, 3/7/2026

Ketua Program Studi Sains Data

Sri Wulandari, S.Kom., M.Cs.
NIK.110918173

LEMBAR PERNYATAAN

Yang bertanda tangan di bawah ini, saya:

Nama	: Hasna Oktaviani
NPM	: 5221811028
Program Studi	: Sains Data
Program	: Sarjana
Fakultas	: Sains & Teknologi

Menyatakan bahwa artikel dengan judul "Implementasi Support Vector Machine untuk Analisis Sentimen terhadap Fenomena Takut Menikah pada Platform X", merupakan karya asli saya dan belum pernah dipublikasikan oleh orang lain. Artikel hanya akan dipublikasikan pada jurnal atau media publikasi yang ditentukan oleh program sesuai ketentuan yang berlaku dan tidak akan dipublikasikan pada media lain tanpa persetujuan yang diperlukan.

Demikian surat pernyataan ini saya buat dengan sebenarnya.

Yogyakarta, 05 Juli 2024

Yang menyatakan,



Hasna Oktaviani

KATA PENGANTAR

Puji syukur kehadirat Tuhan Yang Maha Esa atas segala rahmat dan karunia-Nya sehingga Tugas Akhir ini dapat diselesaikan dengan baik. Penelitian ini dilakukan sebagai bagian dari upaya akademik dalam menganalisis sentimen terhadap fenomena takut menikah pada platform X menggunakan algoritma Support Vector Machine (SVM) dan metode Latent Dirichlet Allocation (LDA).

Dalam proses penyusunan laporan penelitian ini, banyak pihak yang telah memberikan bantuan, bimbingan, dukungan, dan motivasi. Oleh karena itu, penulis menyampaikan ucapan terima kasih dan apresiasi kepada:

1. Rektor Universitas Teknologi Yogyakarta, Dr. Bambang Moertono Setiawan, M.M., Akt., CA., yang telah memberikan kesempatan kepada penulis untuk menempuh pendidikan dan mengembangkan kemampuan akademik selama masa perkuliahan.
2. Dekan Fakultas Sains dan Teknologi, Prof. Dr. Ar. Endy Marlina, S.T., M.T., IAI., yang telah memberikan dukungan serta fasilitas selama proses pendidikan dan penyusunan tugas akhir ini.
3. Ketua Program Studi Sains Data, Sri Wulandari, S.Kom., M.Cs., yang telah memberikan arahan dan dukungan selama penulis menempuh pendidikan di Program Studi Sains Data.
4. Bapak Muhammad Fachrie, S.T., M.Cs., selaku Dosen Pembimbing Tugas Akhir yang telah meluangkan waktu, tenaga, dan pikiran untuk memberikan arahan, bimbingan, masukan, serta motivasi yang sangat berarti selama proses penyusunan dan penyelesaian tugas akhir ini.
5. Kepada Kayla Putri Nandayani, Icha Rahmawati dan Atia Laila selaku teman seperjuangan yang telah memberikan dukungan, bantuan, serta kebersamaan selama proses penyusunan tugas akhir ini. Terima kasih karena selalu hadir untuk mendengarkan keluh kesah, berbagi tawa, memberikan semangat, serta menemani penulis sejak awal proses penelitian hingga penyusunan draf skripsi ini selesai.

6. Kepada sahabat terbaik penulis sejak SMP, Rani Anggarini. Terima kasih karena tetap menjaga komunikasi, memberikan dukungan, serta selalu bersedia mendengarkan keluh kesah penulis meskipun terpisah oleh jarak dan kesibukan. Kehadiran dan dukungan yang diberikan sangat berarti selama proses penyusunan skripsi ini.
7. Kepada Siti Dayamanti, teman terdekat penulis yang selalu memberikan dukungan, semangat, dan kebersamaan selama proses perkuliahan hingga penyusunan tugas akhir ini. Terima kasih karena selalu hadir, meluangkan waktu untuk mendengarkan keluh kesah, serta menjadi salah satu sistem pendukung terbaik bagi penulis.
8. Kepada Jeno, Jaemin, Junseo, Leo, Sangwon, dan Seungmin yang telah menjadi sumber motivasi, semangat, dan hiburan bagi penulis selama proses penyusunan tugas akhir ini. Terima kasih atas energi positif dan inspirasi yang diberikan sehingga penulis tetap termotivasi untuk menyelesaikan skripsi ini dengan baik.

Penulis menyadari bahwa Tugas Akhir ini masih jauh dari sempurna. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan guna penyempurnaan penelitian di masa mendatang. Penulis berharap Tugas Akhir ini dapat memberikan manfaat dan menambah wawasan bagi pembaca serta menjadi referensi bagi penelitian selanjutnya di bidang analisis sentimen dan data science.

.

Hormat Saya,

Penulis

ABSTRAK

Fenomena takut menikah menjadi isu yang banyak dibahas oleh masyarakat pada platform X. Penelitian ini bertujuan untuk menganalisis sentimen masyarakat terhadap fenomena tersebut menggunakan algoritma *Support Vector Machine* (SVM) serta mengidentifikasi topik dominan menggunakan metode *Latent Dirichlet Allocation* (LDA). Data penelitian diproses melalui tahapan *preprocessing* dan ekstraksi fitur TF-IDF sebelum dilakukan klasifikasi sentimen dan pemodelan topik. Hasil penelitian menunjukkan bahwa model SVM memperoleh akurasi pelatihan sebesar 97,80% dan akurasi pengujian sebesar 85,99%, dengan nilai *precision* 87%, *recall* 86%, dan F1-score 86%. Analisis sentimen menunjukkan bahwa sentimen positif mendominasi percakapan dengan 985 tweet (54,12%), sedangkan sentimen negatif sebanyak 835 tweet (45,88%). Hasil *topic modeling* menghasilkan tiga topik utama, yaitu kesiapan menikah dan keraguan, tuntutan karier dan finansial, serta trauma dan ketidaksiapan mental.

Kata kunci: Analisis Sentimen, *Support Vector Machine*, *Latent Dirichlet Allocation, Topic Modeling*, Platform X.

ABSTRACT

Fear of marriage has become a widely discussed issue on the X platform. This study aims to analyze public sentiment toward this phenomenon using the Support Vector Machine (SVM) algorithm and identify dominant topics using the Latent Dirichlet Allocation (LDA) method. The data were processed through preprocessing and TF-IDF feature extraction before sentiment classification and topic modeling were performed. The results show that the SVM model achieved a training accuracy of 97.80% and a testing accuracy of 85.99%, with a precision of 87%, recall of 86%, and F1-score of 86%. Sentiment analysis revealed that positive sentiment dominated the discussions with 985 tweets (54.12%), while negative sentiment accounted for 835 tweets (45.88%). Topic modeling identified three main topics: marriage readiness and doubt, career and financial demands, and trauma and mental unpreparedness.

Keywords*: Sentiment Analysis, Support Vector Machine, Latent Dirichlet Allocation, Topic Modeling, X Platform.*

DAFTAR ISI

LEMBAR PERNYATAAN iii
KATA PENGANTAR iv
ABSTRAK vi
ABSTRACT vii
DAFTAR ISI viii
DAFTAR GAMBAR xi
DAFTAR TABEL xii
BAB I PENDAHULUAN 1
1.1 latar Belakang 1
1.2 Rumusan Masalah 2
1.3 Batasan Masalah 2
1.4 Tujuan Penelitian 3
1.5 Manfaat Penelitian 3
1.6 Sistematika Penulisan 4
BAB II KAJIAN HASIL PENELITIAN DAN LANDASAN TEORI 6
2.1 Kajian Hasil Penelitian 6
2.2 Landasan Teori 9
2.2.1 Analisis Sentimen 9
2.2.2 Text Mining 12
2.2.3 *Support Vector Machine* (SVM) 23
2.2.4 *Topic modeling* 27
2.2.5 Platform X 30
2.2.6 Python 32
2.2.7 SocialX 33
2.2.8 Streamlit 34
2.2.9 Evaluasi Model 35
2.2.10 *Confusion Matrix* 38
2.2.11 *Visual Studio Code* 40
BAB III METODE PROYEK TUGAS AKHIR 42
3.1 Metode Penelitian 42
3.1.1 Identifikasi Masalah 43

3.1.2 Pelabelan Sentimen Skor 43
3.1.3 Pengambilan Data 44
3.1.4 *Preprocessing* 45
3.1.5 Ekstraksi Fitur 45
3.1.6 Pemodelan 45
3.1.7 Evaluasi Model 46
3.1.8 Hasil dan Pembahasan 46
3.2 Objek Penelitian 46
BAB IV ANALISIS DAN PERANCANGAN 49
4.1 Analisis Sistem 49
4.1.1 Analisis Sistem yang Berjalan 50
4.1.2 Analisis Sistem yang Diusulkan 51
4.2 Analisis Fungsional 54
4.2.1 Kebutuhan Fungsional 54
4.2.2 Kebutuhan Non-Fungsional 55
4.3 Perancangan Sistem 56
4.3.1 Perancangan Arsitektur Sistem 57
4.3.2 Perancangan Alur Sistem 58
4.3.3 Perancangan Antarmuka 59
4.4 Persiapan Data dan Eksperimen Komputasi 62
4.4.1 Sumber dan Pengumpulan Dataset 62
4.4.2 *Preprocessing Data* 63
4.4.3 Ekstraksi Fitur TF-IDF 64
4.5 Pemodelan Klasifikasi dan Perhitungan Manual 65
4.5.1 Pembagian Data Latih dan Data Uji 65
4.5.2 Alur Pemodelan Berbasis SVM Linier 66
4.6 Simulasi Perhitungan Manual Algoritma .... **Error! Bookmark not defined.**
BAB V IMPLEMENTASI DAN PEMBAHASAN SISTEM 67
5.1 Implementasi Data 67
5.1.1 Pengumpulan Data 67
5.1.2 Filtering dan Pelabelan Data 68
5.1.3 *Preprocessing* Data 70
5.1.4 Ekstraksi Fitur 74
5.1.5 Implementasi Support Vector Machine 75

5.1.6 *Topic modeling* 76
5.1.7 Implementasi Sistem 78
5.2 Pembahasan 83
5.2.1 Hasil Analisis Sentimen 83
5.2.2 Evaluasi Kinerja Model SVM 96
5.2.3 Hasil *Topic modeling* 101
BAB VI PENUTUP 105
6.1 Kesimpulan 105
6.2 Saran 106
DAFTAR PUSTAKA 107

DAFTAR GAMBAR

Gambar 2. 1 Ilustrasi Hyperplane dan Support Vector pada SVM 23
Gambar 2. 2 Confusion Matrix 39
Gambar 3. 1 Metode Penelitian 42
Gambar 4. 1 Kerangka Penelitian 49
Gambar 4. 2 Sistem yang Sedang Berjalan 50
Gambar 4. 3 Sistem Yang Diusulkan 52
Gambar 4. 4 Antarmuka Halaman Analisis Sentimen 60
Gambar 4. 5 Antarmuka Halaman Simulator Sentimen 61
Gambar 4. 6 Antarmuka Implementasi Support Vector Machine 62
Gambar 5. 1 Preview Hasil Crawling Data Sentimen 68
Gambar 5. 2 Kode Filtering Data Berbahasa Indonesia 68
Gambar 5. 3 Kode Penghapusan Data Kosong dan Duplikat 69
Gambar 5. 4 Kode Daftar Kata Kunci untuk Pelabelan Sentimen 69
Gambar 5. 5 Kode Proses Case Folding 70
Gambar 5. 6 Kode Proses Cleaning Teks 71
Gambar 5. 7 Kode Penghapusan Stopword Pada Data Teks 71
Gambar 5. 8 Kode Penggabungan Stopword NLTK dan Sastrawi 71
Gambar 5. 9 Kode Penyelamatan Kata Negasi dari Daftar Stopword 72
Gambar 5. 10Kode Penyaringan Token Menggunakan Daftar Stopword 72
Gambar 5. 11 Kode Penambahan Kata Gaul dan Singkatan 73
Gambar 5. 12 Kode Inisialisasi Stemmer Sastrawi 73
Gambar 5. 13 Kode Ekstraksi Fitur Menggunakan TF-IDF 74
Gambar 5. 14 Kode Model SVM 76
Gambar 5. 15 Kode Prediksi dan Evaluasi Akurasi Model SVM 76
Gambar 5. 16 Kode Pengujian Coherence score 77
Gambar 5. 17 Grafik Nilai Coherence Score 77
Gambar 5. 18 Kode Algoritma LDA 78
Gambar 5. 19 Halaman Analisis Sentimen dan Topik (Bagian Atas) 79
Gambar 5. 20 Halaman Analisis Sentimen dan Topik (Bagian Bawah) 79
Gambar 5. 21 Halaman Simulator Analisis Sentimen 80
Gambar 5. 22 Halaman Implementasi Support Vector Machine (Bagian Atas) 81
Gambar 5. 23 Halaman Implementasi Support Vector Machine (Bagian Bawah) .. 81
Gambar 5. 24 Distribusi Kelas Sentimen Hasil Pelabelan Keyword 83
Gambar 5. 25 Visualisasi Confusion Matrix 99
Gambar 5. 26 Grafik Pengujian Coherence Score 101

DAFTAR TABEL

Tabel 2. 1 Perbandingan Penelitian Sebelumnya 7
Tabel 2. 2 Perbandingan Teks Asli dan Hasil Case Folding 14
Tabel 2. 3 Contoh Hasil Cleansing pada Data Teks 14
Tabel 2. 4 Perbandingan Teks Sebelum dan Sesudah Proses Normalisasi 15
Tabel 2. 5 Hasil Tokenisasi Pada Data Teks 15
Tabel 2. 6 Contoh Stopword Removal Pada Data 16
Tabel 2. 7 Hasil Penghapusan Stopword Pada Data 16
Tabel 2. 8 Hasil Pembentukan Matriks Bag of Words 18
Tabel 2. 9 Contoh Data untuk TF-IDF 20
Tabel 2. 10 Hasil Perhitungan Term Frequency (TF) 20
Tabel 2. 11 Hasil Perhitungan IDF 20
Tabel 2. 12 Hasil Pembobotan TF-IDF 21
Tabel 3. 1 Hasil Pengambilan Data 47
Tabel 4. 1 Perangkat Keras Yang Digunakan Pada Penelitian 56
Tabel 4. 2 Perangkat Lunak Yang Digunakan Pada Penelitian 56
Tabel 4. 3 Hasil Preprocessing 5 Sampel Data Sentimen **Error! Bookmark not defined.**
Tabel 4. 4 Matriks Frekuensi Kemunculan Kata (*Term Frequency*) ..... **Error! Bookmark not defined.**
Tabel 4. 5 Matriks Nilai Akhir Pembobotan Vektor TF-IDF **Error! Bookmark not defined.**
Tabel 5. 1 Dimensi Matriks Hasil Transformasi TF-IDF 75
Tabel 5. 2 Hasil Preprocessing 5 Sampel Data Sentimen 85
Tabel 5. 3 Matriks Frekuensi Kemunculan Kata (Term Frequency) 87
Tabel 5. 4 Matriks Nilai Akhir Pembobotan Vektor TF-IDF 90
Tabel 5. 5 Hasil Evaluasi Akurasi Model SVM 96
Tabel 5. 6 Hasil Classification Report Model SVM 97
Tabel 5. 7 Hasil Distribusi Topik Dominan 102

BAB I
PENDAHULUAN

1.1 latar Belakang

Fenomena takut menikah (*fear of marriage*) pada generasi muda menjadi isu sosial yang semakin mengemuka di era digital. Data resmi Badan Pusat Statistik (BPS) menunjukkan adanya penurunan angka pernikahan di Indonesia dalam beberapa tahun terakhir. Pada tahun 2023, jumlah pernikahan tercatat sebanyak 1.577.255, menurun dibandingkan dengan tahun 2022 yang mencapai 1.705.348 pernikahan. Di sisi lain, angka perceraian masih tergolong tinggi, yakni 463.654 kasus pada tahun 2023 (Satriyanto & Oktaviani, 2025). Data tersebut mengindikasikan bahwa sebagian masyarakat mulai meragukan stabilitas dan keberlanjutan institusi pernikahan, sehingga memilih untuk menunda atau bahkan menghindari pernikahan.

Fenomena takut menikah semakin sering muncul di media sosial. Ungkapan seperti "*marriage is scary*" mencerminkan kekhawatiran generasi muda terhadap pernikahan. Kekhawatiran ini dipengaruhi oleh faktor psikologis, sosial, dan hubungan interpersonal. Media sosial menjadi ruang bagi generasi Z untuk mengekspresikan pandangan dan pengalaman mereka. Sejumlah penelitian menunjukkan bahwa generasi Z memiliki kecenderungan lebih kritis dan realistis dalam memandang pernikahan. Mereka mempertimbangkan kesiapan psikologis, kondisi ekonomi, tingkat pendidikan, serta kesehatan mental(Maimun et al., 2025). Namun, sebagian besar penelitian masih menggunakan pendekatan kualitatif. Penelitian tersebut umumnya dilakukan melalui survei atau wawancara dengan jumlah responden yang terbatas. Kondisi ini menyebabkan hasil penelitian belum mampu merepresentasikan opini publik secara luas. Platform X (Twitter) menyediakan data teks dalam jumlah besar. Data ini dapat menggambarkan sentimen masyarakat dalam periode tertentu. Namun, data bersifat tidak terstruktur dan kompleks. Oleh karena itu, diperlukan pendekatan komputasi agar analisis

dapat dilakukan secara sistematis dan menghasilkan gambaran yang lebih komprehensif.

Dengan demikian, penelitian ini memerlukan metode klasifikasi teks yang mampu menangani kompleksitas fitur secara efektif. Metode *Support Vector Machine* (SVM) memiliki keunggulan dalam mengklasifikasikan data teks berdimensi tinggi dan menghasilkan performa yang stabil pada data tidak terstruktur. Metode ini relevan untuk digunakan dalam analisis sentimen terhadap fenomena takut menikah. Oleh karena itu, topik ini dipilih dalam penelitian. Selain itu, penelitian ini juga memanfaatkan pendekatan *Topic modeling* untuk mengidentifikasi topik utama yang muncul dalam data serta mengungkap isu dominan yang melatarbelakangi sentimen publik. Kombinasi kedua pendekatan tersebut diharapkan mampu memberikan gambaran yang lebih objektif dan terukur mengenai pandangan generasi muda terhadap pernikahan.

1.2 Rumusan Masalah

Berdasarkan latar belakang penelitian yang telah diuraikan, maka rumusan masalah dalam penelitian ini sebagai berikut:

1. Bagaimana kinerja algoritma *Support Vector Machine* (SVM) dalam mengklasifikasikan sentimen pada data teks platform X terkait fenomena takut menikah?
2. Bagaimana kecenderungan sentimen masyarakat terhadap fenomena takut menikah pada platform X?
3. Topik-topik apa saja yang muncul dalam percakapan mengenai fenomena takut menikah di platform X?

1.3 Batasan Masalah

Agar penelitian lebih terfokus dan sesuai dengan tujuan yang ditetapkan, maka batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Data penelitian dibatasi pada data teks yang diperoleh dari platform X dengan kata kunci yang relevan dengan fenomena takut menikah
2. Analisis *Topic modeling* digunakan untuk mengidentifikasi topik dominan dalam percakapan media sosial tanpa membahas hubungan kausal secara mendalam.
3. Algoritma yang digunakan untuk analisis sentimen adalah *Support Vector Machine*, sedangkan metode *Topic modeling* disesuaikan dengan karakteristik data teks.
4. Penelitian ini tidak membahas aspek demografis pengguna media sosial secara rinci, seperti usia, jenis kelamin, atau latar belakang sosial ekonomi.

1.4 Tujuan Penelitian

Tujuan dari penelitian ini adalah mengimplementasikan algoritma *Support Vector Machine* untuk menganalisis sentimen terhadap fenomena takut menikah pada platform X.

1.5 Manfaat Penelitian

Manfaat dalam penelitian ini adalah:

1. Memberikan kontribusi pada pengembangan kajian analisis teks berbasis data sains, khususnya integrasi analisis sentimen dan *Topic modeling* dalam mengkaji fenomena sosial.
2. Memberikan gambaran berbasis data mengenai pola sentimen dan topik utama yang melatarbelakangi fenomena takut menikah di media sosial.
3. Membantu memahami isu-isu dominan yang memengaruhi persepsi generasi muda terhadap pernikahan di era digital.
4. Menjadi referensi bagi penelitian selanjutnya yang menggunakan pendekatan *machine learning* dan pemrosesan bahasa alami pada data media sosial berbahasa Indonesia.

1.6 Sistematika Penulisan

Laporan ini disusun secara sistematis dalam beberapa bab yang saling berkaitan. Berikut adalah sistematika penulisannya:

1. Bab I Pendahuluan

   Bab ini menjelaskan gambaran umum penelitian yang meliputi latar belakang terkait fenomena takut menikah yang banyak dibahas di platform X. Selain itu, bab ini juga memuat rumusan masalah, batasan masalah, tujuan penelitian, manfaat penelitian, serta sistematika penulisan skripsi.
2. Bab II Kajian Hasil Penelitian dan Landasan Teori

   Bab ini berisi uraian mengenai penelitian terdahulu yang relevan dengan topik penelitian serta teori-teori yang mendukung penelitian. Teori yang dibahas meliputi text mining, natural language processing, analisis sentimen, pembobotan kata menggunakan TF-IDF, algoritma *Support Vector Machine,* dan *Topic modeling*
3. Bab III Metode Penelitian

   Bab ini menjelaskan metode yang digunakan dalam penelitian, meliputi proses pengumpulan data dari platform X (Twitter), tahapan *Preprocessing* data teks, proses pembobotan kata, serta penerapan algoritma *Support Vector Machine* (SVM) untuk klasifikasi sentimen. Metode SVM dikombinasikan dengan pendekatan *Topic modeling* sehingga tidak hanya mampu mengklasifikasikan sentimen, tetapi juga mengidentifikasi topik utama yang mendasari opini publik. Selain itu, bab ini juga menjelaskan metode evaluasi yang digunakan untuk mengukur kinerja model.
4. Bab IV Analisis dan Perancangan

   Bab ini membahas proses analisis terhadap data yang telah dikumpulkan serta perancangan alur penelitian. Analisis dilakukan

untuk melihat kecenderungan sentimen masyarakat terhadap fenomena takut menikah berdasarkan data dari platform X (Twitter). Selain itu, bab ini juga memuat perancangan penerapan *Topic modeling* untuk mengidentifikasi topik utama yang muncul dalam data.

5. Bab V Implementasi dan Pembahasan

   Bab ini menyajikan hasil penerapan metode *Support Vector Machine* (SVM) dalam analisis sentimen serta implementasi *Topic modeling* dalam mengidentifikasi isu dominan. Bab ini juga menjelaskan hasil pengujian model dan pembahasan terhadap hasil klasifikasi sentimen serta topik yang diperoleh.

6. Bab VI Implementasi dan Pembahasan

   Bab ini berisi kesimpulan dari hasil penelitian yang telah dilakukan serta saran yang dapat digunakan sebagai pertimbangan untuk penelitian selanjutnya

BAB II
KAJIAN HASIL PENELITIAN DAN LANDASAN TEORI

2.1 Kajian Hasil Penelitian

Fenomena analisis sentimen terhadap isu pernikahan di media sosial telah banyak dikaji menggunakan pendekatan *machine learning*. Salah satunya, penelitian oleh Isnawan Argi Aryasatya (2023)yang menganalisis sentimen publik terhadap pernikahan usia muda pada platform Twitter dengan menggunakan algoritma *Support Vector Machine* (SVM) . Data yang digunakan berupa opini masyarakat dari Twitter yang kemudian diproses melalui beberapa tahapan *preprocessing*, seperti pembersihan teks, tokenisasi, dan normalisasi. Selanjutnya, data diklasifikasikan ke dalam kategori sentimen untuk mengetahui persepsi publik terhadap pernikahan usia muda. Hasil penelitian menunjukkan bahwa metode SVM cukup efektif dalam melakukan klasifikasi sentimen pada data teks media sosial.

Selain itu, penelitian oleh Ar'bah Lailany et al. (2024) mengkaji sentimen publik terhadap penurunan jumlah pernikahan di Indonesia dengan menggunakan algoritma *K-Nearest Neighbors* (KNN). Data yang digunakan berjumlah 2.000 komentar yang diambil dari platform TikTok. Proses analisis dilakukan menggunakan pendekatan CRISP-DM yang meliputi tahap pemahaman bisnis, pemahaman data, persiapan data, pemodelan, evaluasi, dan *deployment*. Hasil penelitian menunjukkan bahwa algoritma KNN mampu mengklasifikasikan sentimen masyarakat ke dalam kategori positif, negatif, dan netral dengan baik.

Penelitian lainnya dilakukan oleh (Isma et al., 2026) yang menganalisis klasifikasi opini masyarakat terhadap pernikahan menggunakan algoritma *Support Vector Machine* (SVM) dan *Multi-Layer Perceptron* (MLP) . Data yang digunakan berjumlah 1.003 komentar dari media sosial. Penelitian ini menerapkan dua pendekatan, yaitu penggunaan *stemming* dan *data augmentation.* Hasil penelitian menunjukkan bahwa penggunaan *data augmentation* mampu meningkatkan akurasi model secara signifikan, di mana SVM mencapai akurasi hingga 93% dan MLP mencapai 96% .

Terakhir, penelitian oleh Kristanti et al. (2025) menganalisis sentimen pengguna media sosial X terhadap penurunan angka pernikahan di Indonesia menggunakan metode *Support Vector Machine* (SVM) dan *Naïve Bayes* . Data yang digunakan berjumlah 1.082 tweet yang diperoleh melalui teknik *crawling*. Data kemudian diproses melalui tahapan *preprocessing* seperti *case folding, cleansing,* tokenisasi*, stopword removal*, dan *stemming*. Hasil penelitian menunjukkan bahwa metode SVM memiliki performa yang lebih baik dibandingkan *Naïve Bayes* dengan tingkat akurasi sebesar 74%.

Tabel 2. 1 Perbandingan Penelitian Sebelumnya

No.	Judul	Penulis	Metode Analisis	Hasil
1	Analisis Sentimen Twitter terhadap Pernikahan di Usia Muda	Raden Isnawan Argi Aryasatya (2023)	SVM (Support Vector Machine)	Penelitian ini menggunakan data opini dari Twitter yang membahas pernikahan usia muda. Hasil penelitian menunjukkan bahwa SVM mampu mengklasifikasikan sentimen dengan baik, namun tidak disebutkan secara spesifik nilai akurasi yang diperoleh.
2	Analisis Sentimen Publik terhadap Penurunan Jumlah Pernikahan di Indonesia	Afyra Ar'bah Lailany, Sri Lestari (2024)	KNN + CRISP-DM	Penelitian ini menggunakan data sebanyak 2.000 komentar dari platform TikTok terkait penurunan jumlah pernikahan. Hasil menunjukkan bahwa KNN mampu mengklasifikasikan sentimen positif, negatif, dan netral dengan baik, namun tidak disebutkan secara rinci tingkat akurasi yang dihasilkan.

Tabel 2. 1 Perbandingan Penelitian Sebelumnya (Lanjutan)

No.	Judul	Penulis	Metode Analisis	Hasil
3	Analisis Klasifikasi Opini terhadap Pernikahan	Nur Isma dkk. (2026)	SVM & MLP	Penelitian ini menggunakan data sebanyak 1.003 komentar dari media sosial. Dengan penerapan teknik data *augmentation*, hasil menunjukkan peningkatan akurasi yang signifikan, yaitu sebesar 93% pada SVM dan 96% pada MLP, sehingga metode ini sangat efektif dalam klasifikasi sentimen.
4	Sentiment Analysis of Social Media X Users on the Decline of Marriage Rates	Novi Amelia Kristanti dkk. (2024)	SVM & Naïve Bayes	Penelitian ini menggunakan data sebanyak 1.082 tweet dari platform X. Hasil menunjukkan bahwa metode SVM memperoleh akurasi sebesar 74%, lebih tinggi dibandingkan *Naïve Bayes* yang hanya mencapai 53%, sehingga SVM dinilai lebih efektif dalam klasifikasi sentimen.
5	Fenomena Marriage Is Scary terhadap Kesiapan Menikah Gen Z	Natasya Rahmawati (2025)	Kualitatif (Interaksionisme Simbolik)	Penelitian ini menggunakan data hasil wawancara terhadap mahasiswa. Hasil menunjukkan bahwa fenomena *Marriage Is Scary* tidak memberikan dampak signifikan terhadap kesiapan menikah, melainkan dipengaruhi oleh faktor lain seperti usia, kondisi finansial, dan kesiapan mental.

Berdasarkan Tabel 2.1, hasil kajian terhadap penelitian-penelitian terdahulu menunjukkan bahwa metode seperti *Support Vector Machine* (SVM), *K-Nearest Neighbor* (KNN), dan *Multilayer Perceptron* (MLP) efektif digunakan dalam

analisis sentimen media sosial. SVM menjadi metode yang paling dominan karena mampu menangani data teks berdimensi tinggi dan menghasilkan performa klasifikasi yang stabil. Sementara itu, KNN unggul dalam kesederhanaan dan kemampuannya dalam mengenali pola berdasarkan kedekatan data, sedangkan MLP mampu memodelkan hubungan non-linear yang kompleks. Berbagai penelitian tersebut membuktikan bahwa metode klasifikasi mampu memberikan informasi yang bermanfaat dalam memahami opini publik pada berbagai isu sosial.

Keunggulan penelitian ini terletak pada penggunaan metode SVM yang dikombinasikan dengan pendekatan *Topic modeling* untuk menganalisis data secara lebih komprehensif. Penelitian ini tidak hanya berfokus pada klasifikasi sentimen, tetapi juga mengidentifikasi topik utama yang melatarbelakangi opini publik. Selain itu, penelitian ini menerapkan tahapan *Preprocessing* data yang lebih sistematis untuk meningkatkan kualitas data yang dianalisis. Dengan demikian, hasil penelitian diharapkan mampu menghasilkan analisis sentimen yang akurat serta memberikan informasi terkait isu dominan dalam fenomena “takut menikah” pada platform X (Twitter) guna mendukung pemahaman yang lebih mendalam terhadap perspektif generasi muda.

2.2 Landasan Teori

2.2.1 Analisis Sentimen

Analisis sentimen (*sentiment analysis* atau *opinion mining*) merupakan cabang kajian dalam *text mining* dan *Natural Language Processing* (NLP). Kajian yang berfokus pada identifikasi dan pengelompokan opini, perasaan, atau aspek emosional yang terkandung dalam teks. Secara umum, tujuan utama analisis sentimen adalah untuk mengetahui arah opini yang bersifat positif, negatif, atau netral sehingga dapat dipahami kecenderungan emosional dalam suatu kumpulan data teks. Studi literatur menunjukkan bahwa analisis sentimen berkembang sebagai salah satu teknik penting dalam NLP untuk mengolah opini publik yang sangat besar pada era digital saat ini.

Menurut Ningsih et al. (2024), analisis sentimen adalah proses mengklasifikasikan dokumen teks berdasarkan polaritas opini. Proses ini penting karena opini publik yang tersebar di media sosial dapat menjadi indikator tren sosial, politik, maupun ekonomi. Dalam konteks penelitian ini, analisis sentimen digunakan untuk memahami fenomena "takut menikah" yang muncul di X.

Tahapan umum analisis sentimen meliputi:

1. Pengumpulan data

   Data dikumpulkan dari sumber teks seperti ulasan pengguna, posting media sosial, atau forum diskusi. Pengumpulan data ini dapat menggunakan *web scraping* atau API platform media sosial untuk memperoleh data yang akan dianalisis.

2. *Preprocessing* teks

   Langkah ini meliputi *case folding*, penghapusan tanda baca, penghentian kata (*stopword removal*), tokenisasi, dan normalisasi teks. Tujuan *preprocessing* adalah membersihkan data agar struktur bahasa dapat diproses oleh model secara efektif dan konsisten.

3. Ekstraksi fitur

   Setelah *preprocessing*, teks diubah menjadi representasi numerik. Metode umum adalah *Term Frequency–Inverse Document Frequency* (TF-IDF) dan pendekatan *word embedding* seperti *Word2Vec* atau *GloVe*. Representasi fitur ini memungkinkan algoritma *Machine Learning* beroperasi pada data teks yang sebelumnya tidak terstruktur.

4. Klasifikasi sentimen

   Pada tahap ini, model *Machine Learning* dilatih untuk memetakan fitur teks ke kategori positif, negatif, dan netral. Pendekatan klasifikasi dapat menggunakan algoritma tradisional seperti *Naïve Bayes*, *Support Vector Machine (SVM)*, *Random Forest*, atau teknik pembelajaran mendalam (*deep learning*). Pemilihan model bergantung pada tujuan penelitian serta karakteristik data.

   Literatur membagi analisis sentimen ke dalam beberapa tingkatan pengamatan. Menurut Mao et al. (2024), analisis sentimen dapat

diklasifikasikan ke dalam tiga level utama, yaitu *document-level*, *sentence-level*, dan *aspect-level*.

Secara umum, ketiga tingkatan tersebut meliputi:

1. *Document-Level*

   Analisis sentimen pada tingkat dokumen menilai sikap atau opini secara keseluruhan dalam satu unit teks. Pendekatan ini melihat dokumen sebagai satu kesatuan yang merepresentasikan satu opini utama.

2. *Sentence-Level*

   Analisis ini menilai sentimen pada tingkat kalimat individu untuk menangkap variasi emosional dalam satu teks yang lebih panjang.

3. *Aspect-Level*

   Membedakan opini berdasarkan aspek tertentu dari topik yang dibahas, yang lebih rinci dibanding dengan klasifikasi polaritas umum.

Pengelompokan tingkat analisis seperti ini penting ketika suatu teks memuat opini yang kompleks dan mengandung lebih dari satu aspek emosi atau subjek. Teknik *aspect-level* mampu mengekstrak opini yang lebih spesifik dibandingkan dengan pendekatan umum yang hanya melihat teks secara keseluruhan. Kemampuan analisis pada berbagai tingkat tersebut menjadikan analisis sentimen tidak hanya berfungsi sebagai alat klasifikasi sederhana, tetapi juga sebagai instrumen analitik yang mampu menggali struktur opini secara lebih mendalam. Dengan fleksibilitas tersebut, analisis sentimen dapat diterapkan pada berbagai konteks yang memerlukan pemahaman terhadap kecenderungan persepsi publik dalam skala besar.

Analisis sentimen memiliki banyak aplikasi dalam berbagai domain. Hal ini disebabkan oleh kemampuannya dalam menangkap kecenderungan opini dari data teks dalam jumlah besar. Beberapa contoh penerapan analisis sentimen antara lain sebagai berikut:

1. *Monitoring* opini publik terhadap isu sosial, politik, atau budaya berdasarkan posting media sosial.
2. Ulasan pelanggan dalam bisnis untuk memahami kepuasan atau ketidakpuasan konsumen.

3. Analisis tren pasar dan prediksi perilaku konsumen berdasarkan pola emosional dalam ulasan produk.

Dengan demikian, analisis sentimen tidak hanya bertujuan mengklasifikasikan teks secara sederhana, tetapi juga memberikan wawasan empiris mengenai pola-pola opini dan persepsi yang diwujudkan dalam bentuk data teks.

2.2.2 Text Mining

1. Definisi

Text mining adalah proses mengekstraksi informasi bermutu serta pola tersembunyi dari data teks yang tidak terstruktur melalui teknik komputasional dan statistik. Secara lebih luas, *text mining* termasuk dalam disiplin *Knowledge Discovery in Text* (KDT). Disiplin ini merupakan serangkaian proses yang bertujuan menghasilkan pengetahuan baru dari kumpulan teks dalam jumlah besar. Proses tersebut berbeda dengan *data mining* pada umumnya karena data teks yang tidak terstruktur memerlukan transformasi dan representasi khusus sebelum dapat dianalisis secara matematis.

Menurut Aleqabie et al. (2024a), *text mining* merupakan sub bidang dari *Natural Language Processing* (NLP) yang berfokus pada pengolahan data teks melalui tahapan yang terstruktur. Tahapan ini bertujuan untuk mengekstraksi informasi penting dari sejumlah besar data teks. NLP sendiri merupakan cabang dari *Artificial Intelligence* yang berfokus pada kemampuan komputer untuk memahami, memproses, dan menganalisis bahasa manusia secara otomatis (Patwardhan et al., 2023). NLP memungkinkan mesin menangkap makna, struktur, serta pola dalam bahasa alami yang bersifat tidak terstruktur sehingga data teks dapat diolah secara komputasional untuk tujuan analitik maupun prediktif.

Dalam implementasinya, NLP tidak hanya membaca teks, tetapi juga menerjemahkan struktur bahasa yang kompleks melalui analisis makna kata, hubungan antarfrasa, serta konteks kalimat yang kemudian diubah menjadi representasi numerik agar dapat dipahami oleh algoritma *Machine Learning*. Oleh

karena itu, *text mining* mencakup berbagai proses seperti identifikasi frekuensi kata, pencarian pola sederhana dalam teks, penggunaan algoritma *Machine Learning*, pemodelan topik, serta teknik representasi teks untuk menghasilkan informasi yang dapat dimanfaatkan dalam pengambilan keputusan berbasis data. Teknik *text mining* terus berkembang seiring dengan meningkatnya kemampuan komputasi dan volume data teks yang bertambah secara eksponensial, terutama pada domain media sosial, kesehatan, dan bisnis.

2. Tahapan *Text Mining*

Tahapan dalam *text mining* umumnya memanfaatkan berbagai teknik dalam *Natural Language Processing* (NLP) untuk mengolah data teks yang tidak terstruktur menjadi bentuk yang dapat dianalisis. Proses tersebut meliputi *preprocessing*, representasi fitur, pemodelan atau penemuan pola, serta evaluasi dan interpretasi hasil analisis. Dari seluruh tahapan tersebut, *preprocessing* menjadi tahap awal yang sangat penting karena berperan dalam meningkatkan kualitas data teks sebelum dilakukan proses analisis lebih lanjut.

A. *Preprocessing*

Text preprocessing merupakan tahap fundamental yang bertujuan mengurangi *noise* serta meningkatkan kualitas data teks sebelum dilakukan analisis lebih lanjut. Data teks mentah, khususnya yang berasal dari media sosial, sering kali mengandung simbol, tautan, emoji atau emotikon, singkatan, hingga kesalahan ejaan. Tanpa proses pembersihan yang memadai, model klasifikasi berpotensi menghasilkan bias atau kesalahan dalam prediksi.

1) *Case Folding*

Pada tahap *case folding*, seluruh huruf dalam teks diubah menjadi huruf kecil. Proses ini bertujuan untuk menyeragamkan variasi penulisan kata yang sebelumnya berbeda-beda, sehingga menghasilkan representasi data yang lebih konsisten. Contoh hasil dari proses *case folding* dapat dilihat pada Tabel 2.2.

Tabel 2. 2 Perbandingan Teks Asli dan Hasil *Case Folding*

Teks Kotor	Hasil
Jangankan nikah muda. Kepikiran buat nikah aja belum ada. Melihat tiap hari orang tua yg selalu adu mulut bener bener bikin takut buat nikah. Pernikahan itu menyeramkan. Minimal stabil secara finansial dulu baru berani untuk menikah. Butuh banyak ilmu jg. Bnyak yg hrs dipersiapkn	jangankan nikah muda. kepikiran buat nikah aja belum ada. melihat tiap hari orang tua yg selalu adu mulut bener bener bikin takut buat nikah. pernikahan itu menyeramkan. minimal stabil secara finansial dulu baru berani untuk menikah. butuh banyak ilmu jg. bnyak yg hrs dipersiapkn

2) *Removal Punction* (Penghapusan Tanda Baca)

Setelah tahap *case folding*, peneliti melakukan proses *cleansing* atau *removal punction* untuk menghapus seluruh tanda baca dan karakter khusus yang tidak diperlukan dalam analisis. Proses ini bertujuan untuk mengurangi gangguan (*noise*) pada data sehingga algoritma hanya berfokus pada konten teks utama. Contoh hasil penghapusan tanda baca dapat dilihat pada Tabel 2.3.

Tabel 2. 3 Contoh Hasil *Cleansing* pada Data Teks

Sebelum	Sesudah
jangankan nikah muda. kepikiran buat nikah aja belum ada. melihat tiap hari orang tua yg selalu adu mulut bener bener bikin takut buat nikah. pernikahan itu menyeramkan. minimal stabil secara finansial dulu baru berani untuk menikah. butuh banyak ilmu jg. bnyak yg hrs dipersiapkn	jangankan nikah muda kepikiran buat nikah aja belum ada melihat tiap hari orang tua yg selalu adu mulut bener bener bikin takut buat nikah pernikahan itu menyeramkan minimal stabil secara finansial dulu baru berani untuk menikah butuh banyak ilmu jg bnyak yg hrs dipersiapkn

3) Normalisasi

Tahap normalisasi bertujuan untuk mengubah kata-kata tidak baku, singkatan, atau bahasa gaul (*slang*) menjadi bentuk baku sesuai dengan Pedoman Umum Ejaan Bahasa Indonesia (PUEBI). Proses ini

membantu menyatukan berbagai variasi penulisan kata yang memiliki makna sama. Ilustrasi proses normalisasi teks disajikan pada Tabel 2.3.

Tabel 2. 4 Perbandingan Teks Sebelum dan Sesudah Proses Normalisasi

Kata Asli	Hasil Normalisasi
jangankan nikah muda kepikiran buat nikah aja belum ada melihat tiap hari orang tua yg selalu adu mulut bener bener bikin takut buat nikah pernikahan itu menyeramkan minimal stabil secara finansial dulu baru berani untuk menikah butuh banyak ilmu jg bnyak yg hrs dipersiapkn	jangankan nikah muda kepikiran buat nikah saja belum ada melihat tiap hari orang tua **yang** selalu adu mulut benar benar bikin takut buat nikah pernikahan itu menyeramkan minimal stabil secara finansial dulu baru berani untuk menikah butuh banyak ilmu **juga banyak yang harus dipersiapkan**

4) Tokenisasi

Memecah teks menjadi unit kecil (token), biasanya berupa kata-kata. Setelah menghapus tanda baca dan simbol, teks dipecah menjadi token agar mudah diolah oleh algoritma. Tokenisasi membantu model *machine learning* memproses teks sebagai sekumpulan kata independen. Tokenisasi dapat dimodelkan sebagai fungsi:

$$T = f(D) \tag{2.1}$$

Contoh hasil pemecahan teks menjadi token ditunjukkan pada Tabel 2.5.

Tabel 2. 5 Hasil Tokenisasi Pada Data Teks

Teks Kotor	Hasil
jangankan nikah muda kepikiran buat nikah saja belum ada melihat tiap hari orang tua yang selalu adu mulut benar benar bikin takut buat nikah pernikahan itu menyeramkan minimal stabil secara finansial dulu baru berani untuk menikah butuh banyak ilmu juga banyak yang harus dipersiapkan	['nikah', 'muda', 'kepikiran', 'nikah', 'melihat', 'orang', 'tua', 'adu', 'mulut', 'takut', 'nikah', 'pernikahan', 'menyeramkan', 'minimal', 'stabil', 'finansial', 'berani', 'menikah', 'butuh', 'ilmu', 'dipersiapkan']

5) *Stopword Removal*

Menghilangkan kata-kata umum (*stopwords*) yang tidak memiliki makna penting (misalnya “dan”, “atau”, “di”, “yang”). Langkah ini mengurangi kebisingan (*noise*) dan dimensi fitur, sehingga model fokus pada kata bermakna saja. Sebagai contoh, penelitian menggunakan daftar *stopword* dari pustaka NLTK untuk Bahasa Indonesia dan Inggris. Hasil dari penyaringan kata ini dapat dilihat pada Tabel 2.6.

Tabel 2. 6 Contoh *Stopword Removal* Pada Data

Teks Kotor	Hasil
'jangankan', 'nikah', 'muda', 'kepikiran', 'buat', 'nikah', 'saja', 'belum', 'ada', 'melihat', 'tiap', 'hari', 'orang', 'tua', 'yang', 'selalu', 'adu', 'mulut', 'benar', 'benar', 'bikin', 'takut', 'buat', 'nikah', 'pernikahan', 'itu', 'menyeramkan', 'minimal', 'stabil', 'secara', 'finansial', 'dulu', 'baru', 'berani', 'untuk', 'menikah'	'nikah', 'muda', 'kepikiran', 'nikah', 'melihat', 'orang', 'tua', 'adu', 'mulut', 'takut', 'nikah', 'pernikahan', 'menyeramkan', 'minimal', 'stabil', 'finansial', 'berani', 'menikah', 'butuh', 'ilmu', 'dipersiapkan'

6) *Stemming*

Tahap *stemming* berfungsi untuk mengubah kata berimbuhan menjadi kata dasar (*root word*) dengan cara menghilangkan awalan maupun akhiran. Dalam penelitian ini, peneliti menggunakan algoritma yang sesuai untuk Bahasa Indonesia guna mendapatkan bentuk akar kata. Representasi ini dapat dirumuskan sebagai fungsi:

$$stem(w_i) = root(w_i) \tag{2.2}$$

Tabel 2.7 contoh perubahan kata setelah melalui proses *stemming*.

Tabel 2. 7 Hasil Penghapusan *Stopword* Pada Data

Teks Kotor	Hasil
'nikah', 'muda', 'kepikiran', 'nikah', 'melihat', 'orang', 'tua', 'adu', 'mulut', 'takut', 'nikah', 'pernikahan', 'menyeramkan', 'minimal', 'stabil', 'finansial', 'berani', 'menikah', 'butuh', 'ilmu', 'dipersiapkan'	'nikah', 'muda', 'pikir', 'nikah', 'lihat', 'orang', 'tua', 'adu', 'mulut', 'takut', 'nikah', 'nikah', 'seram', 'minimal', 'stabil', 'finansial', 'berani', 'nikah', 'butuh', 'ilmu', 'siap'

B. *Feature Extraction*

Feature extraction merupakan tahapan krusial dalam *text mining* yang berfungsi untuk mengubah data teks tidak terstruktur menjadi representasi numerik. Representasi ini diperlukan karena algoritma *machine learning* hanya dapat memproses input dalam bentuk vektor angka atau matriks. Pada tahap ini, kumpulan kata yang telah melalui proses *preprocessing* akan dipetakan ke dalam ruang vektor berdimensi tertentu agar pola-pola bahasa dapat dianalisis secara kuantitatif.

1) *Bag of Words* (BoW)

Bag of Words merupakan teknik ekstraksi fitur yang merepresentasikan dokumen sebagai kumpulan kata tanpa mempertimbangkan struktur tata bahasa maupun urutan kata di dalamnya. Metode ini mentransformasikan dokumen menjadi vektor numerik dengan dimensi yang sesuai dengan jumlah kata unik dalam seluruh korpus. Setiap elemen di dalam vektor tersebut menunjukkan frekuensi kemunculan kata tertentu pada dokumen yang dianalisis.

Proses penggunaan *Bag of Words* diawali dengan tahap tokenisasi untuk memecah teks menjadi kata-kata individual. Selanjutnya, kata-kata unik diidentifikasi guna menyusun daftar fitur atau *dictionary*. Setiap dokumen direpresentasikan sebagai baris dalam sebuah matriks, di mana nilai pada setiap sel menunjukkan frekuensi kemunculan kata tersebut. Teknik BoW ini dapat diterapkan pada berbagai tugas pemrosesan teks, termasuk dalam pemodelan topik.

Secara matematis, jika kosakata seluruh dokumen dinyatakan sebagai:

$$V = \{t_1, t_2, \dots, t_n\} \tag{2.3}$$

maka sebuah dokumen $d$dapat direpresentasikan sebagai vektor:

$$d = (f_1, f_2, \dots, f_n) \tag{2.4}$$

Di mana f_i adalah frekuensi kemunculan kata t_i dalam dokumen.

Contoh 2.1 Peneliti memberikan ilustrasi perhitungan BoW menggunakan dua baris data teks yang telah disederhanakan sebagai berikut:

1. D1: nikah muda seram
2. D2: nikah butuh ilmu

Hasil pemetaan frekuensi kata tersebut disajikan pada tabel 2.8.

Tabel 2. 8 Hasil Pembentukan Matriks *Bag of Words*

Dokumen	**nikah**	**mudah**	**seram**
Dokumen 1	1	1	1
Dokumen 2	1	0	0

Berdasarkan Tabel 2.9, setiap baris mewakili sebuah dokumen dan setiap kolom mewakili kata unik yang terdapat dalam seluruh korpus (kosakata). Nilai 1 pada kolom 'muda' di baris Dokumen 1 menunjukkan bahwa kata tersebut muncul dalam dokumen tersebut. Sebaliknya, nilai 0 pada kolom 'muda' di baris Dokumen 2 menunjukkan bahwa kata tersebut tidak ditemukan dalam Dokumen 2. Secara keseluruhan, tabel ini mentransformasikan teks kualitatif menjadi data kuantitatif berupa vektor frekuensi yang siap diproses oleh algoritma klasifikasi.

2) *Term Frequency–Inverse Document Frequency* (TF-IDF)

Term weighting merupakan proses pembobotan kata yang bertujuan untuk mengoptimalkan analisis sentimen (Hanif Razka et al., 2023). Salah satu metode yang digunakan adalah TF-IDF untuk mentransformasikan teks menjadi representasi numerik dalam proses ekstraksi fitur. Metode ini melibatkan dua faktor utama, yaitu *Term Frequency* (TF) *dan Inverse Document Frequency* (IDF). *Term Frequency* (TF) digunakan untuk menghitung frekuensi kemunculan suatu kata dalam sebuah dokumen. Kata yang sering muncul dianggap memiliki tingkat kepentingan yang tinggi pada profil item tersebut.

Sementara itu, *Inverse Document Frequency* (IDF) berfungsi untuk mengukur kelangkaan suatu kata di seluruh kumpulan dokumen. Kata yang muncul pada terlalu banyak dokumen dianggap kurang informatif

sehingga mendapatkan bobot yang lebih rendah. Perhitungan nilai TF dilakukan menggunakan Persamaan 2.5.

$$TF(i,j) = \frac{freq\ (i,j)}{N_j} \tag{2.5}$$

Keterangan:

$TF\ (i,j)$: Frekuensi kata dari kata *i* dalam dokumen *j*
$freq\ (i,j)$: Jumlah kemunculan kata *i* dalam dokumen *j*
N_j : Jumlah kata dalam dokumen *j*

Persamaan tersebut berfungsi untuk mengukur intensitas kata *i* dalam dokumen *j* yang kemudian dinormalisasi agar tidak terpengaruh oleh panjang dokumen. Selanjutnya, perhitungan untuk nilai IDF ditunjukkan pada Persamaan 2.6.

$$IDF\ = \log(\frac{N}{n(i)}) \tag{2.6}$$

Keterangan:

N : Frekuensi kata dari kata *i* dalam dokumen *j*
$n(i)$: Jumlah kemunculan kata *i* dalam dokumen *j*

Nilai akhir pembobotan diperoleh dengan mengalikan skor *Term Frequency* (TF) dan *Inverse Document Frequency* (IDF) dari setiap kata. Persamaan 2.7. menunjukkan formula yang digunakan dalam perhitungan skor TF-IDF tersebut:

$$TF - IDF = TF(t,d)\ \times IDF(t) \tag{2.7}$$

Contoh 2.1 menyajikan ilustrasi data yang terdapat pada Tabel 2.9. Kolom "Sesudah" pada tabel tersebut menampilkan hasil tahap

Preprocessing data yang telah dilakukan terhadap data mentah pada kolom "Sebelum".

Tabel 2. 9 Contoh Data untuk TF-IDF

No	Sebelum	Sesudah
D1	Nikah muda bikin takut	nikah, muda, takut
D2	Takut nikah karena ekonomi	takut, nikah, ekonomi
D3	Ilmu nikah itu penting	ilmu, nikah, penting
D4	Penting untuk siap nikah	penting, siap, nikah

Selanjutnya, peneliti melakukan perhitungan *Term Frequency* (TF) untuk setiap kata pada seluruh dokumen menggunakan Persamaan 2.5. Nilai TF dihitung dengan membagi jumlah kemunculan suatu kata dengan total kata dalam dokumen tersebut. Sebagai contoh, perhitungan TF untuk kata "nikah" pada dokumen 1 adalah:

$$TF(\text{"nikah"},\text{D1}) = \frac{1}{3} = 0{,}33$$

Hasil perhitungan TF untuk keseluruhan kata disajikan pada Tabel 2.10.

Tabel 2. 10 Hasil Perhitungan *Term Frequency* (TF)

No.	nikah	takut	muda
D1	0,33	0,33	0,33
D2	0,33	0,33	0
D3	0,33	0	0
D4	0,33	0	0

Setelah nilai TF berhasil dihitung, langkah berikutnya adalah menghitung *Inverse Document Frequency* (IDF). Nilai ini berfungsi untuk mengukur tingkat kepentingan atau kelangkaan suatu kata di dalam dataset. Semakin sedikit dokumen yang mengandung kata tersebut, maka nilai IDF akan semakin tinggi. Perhitungan IDF untuk seluruh kata ditunjukkan pada Tabel 2.11.

Tabel 2. 11 Hasil Perhitungan IDF

Kata	Jumlah Dokumen (df)	Perhitungan IDF	Hasil IDF
Nikah	4	$\log_{10}\frac{4}{4}$	0
Takut	2	$\log_{10}\frac{4}{2}$	0,3010

Tabel 2. 12 Hasil Perhitungan IDF

Kata	Jumlah Dokumen (df)	Perhitungan IDF	Hasil IDF
Muda	1	$\log_{10}\frac{4}{1}$	0,6020
Ekonomi	1	$\log_{10}\frac{4}{1}$	0,6020
Penting	2	$\log_{10}\frac{4}{2}$	0,3020
Ilmu	1	$\log_{10}\frac{4}{1}$	0,6020
siap	1	$\log_{10}\frac{4}{1}$	0,6020

Tahap terakhir adalah melakukan perhitungan skor TF-IDF dengan mengalikan nilai TF dan nilai IDF untuk setiap kata. Proses ini bertujuan untuk menyeimbangkan bobot frekuensi kata dalam dokumen dengan distribusinya di seluruh dokumen agar kata-kata yang terlalu umum tidak mendominasi representasi.

Sebagai ilustrasi, perhitungan TF-IDF untuk dokumen 1 (D1) adalah:

TF-IDF (nikah) = $0{,}33 \times 0 = 0$

TF-IDF (takut) = $0{,}33 \times 0{,}3010 = 0{,}1003$

TF-IDF (muda) = $0{,}33 \times 0{,}6020 = 0{,}2007$

Hasil perhitungan TF-IDF untuk seluruh dokumen disajikan pada Tabel 2.12.

Tabel 2. 13 Hasil Pembobotan TF-IDF

No	nikah	takut	muda
D1	0	0,1003	0,2007
D2	0	0,1003	0
D3	0	0	0
D4	0	0	0

Nilai TF-IDF yang tinggi menunjukkan bahwa suatu kata sering muncul dalam dokumen tertentu, tetapi jarang ditemukan pada dokumen lain, sehingga kata tersebut dianggap lebih representatif dalam menggambarkan isi dokumen. Dalam konteks analisis sentimen, metode TF-IDF digunakan untuk mengubah data teks menjadi vektor fitur yang

merepresentasikan karakteristik kata. Representasi ini kemudian digunakan sebagai input bagi algoritma klasifikasi guna mengidentifikasi pola sentimen. Dengan menggunakan pembobotan TF-IDF, model dapat lebih mudah mengenali kata-kata yang memiliki kontribusi penting dalam menentukan kecenderungan sentimen suatu teks (Ramadhani & Suryono, 2024).

3. Pattern Discovery

Tahap *pattern discovery* merupakan inti dari *text mining*. Data numerik yang telah direpresentasikan digunakan untuk menemukan pola atau membangun model prediktif. Beberapa teknik yang umum digunakan antara lain:

a) Klasifikasi teks, seperti *Naïve Bayes*, *Support Vector Machine* (SVM), *Logistic Regression*, *Random Forest*, hingga *Deep Neural Networks*. Teknik ini digunakan untuk memprediksi label kategori pada data baru berdasarkan pola dari data latih.
b) Clustering, seperti *K-Means* atau *Hierarchical Clustering*, yang digunakan untuk mengelompokkan dokumen ke dalam beberapa kelompok (*cluster*) berdasarkan kemiripan fitur tanpa menggunakan label.
c) *Topic modeling*, seperti *Latent Dirichlet Allocation* (LDA) atau *Non-negative Matrix Factorization* (NMF), yang digunakan untuk menemukan topik-topik abstrak yang tersembunyi secara otomatis di dalam sekumpulan dokumen.
d) Analisis sentimen, yang bertujuan menentukan polaritas opini, yaitu positif, negatif, atau netral.

Dalam konteks penelitian ini, pendekatan klasifikasi dan *topic modeling* digunakan untuk mengidentifikasi kategori sentimen serta memetakan tren topik utama pada komentar di Twitter berdasarkan pola linguistik yang terbentuk. Pemilihan algoritma dilakukan dengan mempertimbangkan karakteristik data, ukuran data set, serta kompleksitas fitur yang digunakan.

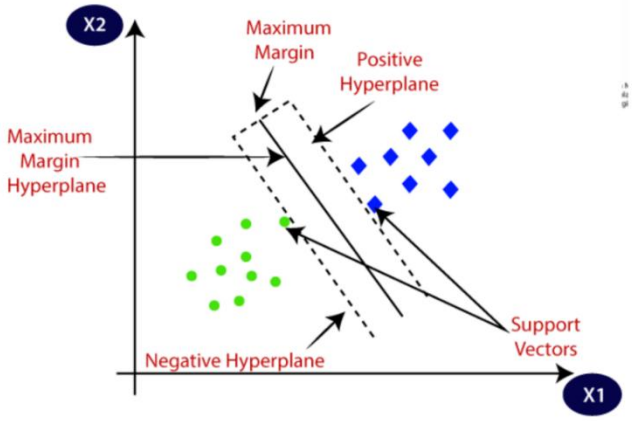
2.2.3 *Support Vector Machine* (SVM)

Support Vector Machine (SVM) merupakan salah satu algoritma *supervised learning* yang banyak digunakan dalam tugas klasifikasi dan regresi. Dalam konteks klasifikasi, SVM bekerja dengan mencari batas pemisah optimal yang disebut *hyperplane* untuk membedakan data dari dua kelas atau lebih (Aleqabie et al., 2024b). *Hyperplane* tersebut dipilih sedemikian rupa sehingga memiliki margin terbesar antara dua kelas data yang berbeda. Margin merupakan jarak antara *hyperplane* dan titik data terdekat dari masing-masing kelas.

Konsep utama SVM adalah bahwa pemisahan kelas yang baik tidak hanya bergantung pada garis pembatas, tetapi juga pada jarak garis tersebut terhadap data terdekat. Titik data yang berada paling dekat dengan *hyperplane* disebut *support vectors*. Titik-titik inilah yang menentukan posisi dan orientasi *hyperplane* dalam ruang fitur. Dengan kata lain, hanya sebagian kecil data yang secara langsung memengaruhi pembentukan model SVM.

Metode ini banyak digunakan dalam berbagai bidang, seperti analisis sentimen, klasifikasi dokumen, pengenalan pola, bioinformatika, dan *computer vision*. Hal ini karena SVM memiliki kemampuan yang baik dalam menangani data berdimensi tinggi, termasuk data teks yang dapat memiliki ribuan fitur kata.

Secara umum, cara kerja SVM melalui beberapa tahapan utama. Ilustrasi konsep pemisahan data menggunakan *Support Vector Machine* dapat dilihat pada Gambar 2.1.



Gambar 2. 1 Ilustrasi Hyperplane dan Support Vector pada SVM

Pada Gambar 2.1 ditunjukkan bagaimana algoritma *Support Vector Machine* memisahkan dua kelas data menggunakan sebuah *hyperplane*. *Hyperplane* tersebut dipilih sedemikian rupa sehingga menghasilkan margin maksimum antara dua kelas data. Titik data yang berada paling dekat dengan *hyperplane* disebut *support vector* dan berperan penting dalam menentukan posisi *hyperplane*. Dengan memaksimalkan margin tersebut, SVM dapat menghasilkan model klasifikasi yang lebih optimal.

Berdasarkan konsep tersebut, secara umum tahapan kerja algoritma *Support Vector Machine* dapat dijelaskan sebagai berikut:

1. Representasi Data

   Data yang akan dianalisis terlebih dahulu direpresentasikan dalam bentuk vektor fitur. Dalam analisis teks, proses ini biasanya dilakukan menggunakan metode seperti TF-IDF sehingga setiap dokumen direpresentasikan sebagai vektor numerik.

2. Pencarian *Hyperplane*

   Setelah data direpresentasikan dalam ruang fitur, algoritma SVM akan mencari *hyperplane* terbaik yang dapat memisahkan dua kelas data. *Hyperplane* tersebut dipilih berdasarkan prinsip *maximum margin*, yaitu garis pemisah yang memiliki jarak paling besar terhadap titik data dari masing-masing kelas.

3. Penentuan *Support Vector*

   Tidak semua data memengaruhi pembentukan *hyperplane*. SVM hanya menggunakan beberapa titik data yang berada paling dekat dengan batas pemisah. Titik-titik ini disebut *support vectors* dan berfungsi sebagai penentu utama posisi *hyperplane*.

4. Proses Klasifikasi

   Setelah *hyperplane* terbentuk, data baru dapat diklasifikasikan dengan melihat posisinya terhadap *hyperplane*. Jika data berada pada satu sisi *hyperplane*, maka data tersebut akan masuk ke kelas pertama. Sebaliknya, jika berada pada sisi lain, maka data tersebut masuk ke kelas kedua.

Secara matematis, *hyperplane* pada SVM dapat dinyatakan dalam bentuk persamaan:

$$\omega \, . x + b = 0 \tag{2.8}$$

dengan:

a. w adalah vektor bobot yang menentukan arah *hyperplane*
b. x adalah vektor fitur dari data
c. b adalah bias atau konstanta

Proses klasifikasi data ke dalam kategori spesifik ditentukan oleh nilai dari fungsi keputusan berikut:

$$f(x) = w.x + b \tag{2.9}$$

Jika:

- $f(x) > 0 \rightarrow$ kelas positif
- $f(x) < 0 \rightarrow$ kelas negatif

Namun, dalam beberapa kasus, data tidak dapat dipisahkan secara linear dalam ruang fitur asli. Hal ini terjadi ketika data dari dua kelas saling bercampur sehingga tidak dapat dipisahkan hanya dengan sebuah garis lurus atau *hyperplane*. Untuk mengatasi kondisi tersebut, *Support Vector Machine* menggunakan konsep *kernel trick*, yaitu teknik yang memetakan data ke ruang berdimensi lebih tinggi sehingga pemisahan antarkelas dapat dilakukan dengan lebih baik.

Fungsi *kernel* bekerja dengan menghitung hubungan antardata tanpa harus secara langsung memetakan data ke dimensi yang lebih tinggi. Dengan menggunakan *kernel*, SVM dapat menangani data yang memiliki pola non-linear secara lebih efektif. Beberapa jenis *kernel* yang umum digunakan dalam algoritma SVM antara lain sebagai berikut.

1. Linear *Kernel*

   Digunakan ketika data dapat dipisahkan secara linear. *Kernel* ini relatif sederhana dan efisien, sehingga sering digunakan dalam analisis teks.

2. *Polynomial Kernel*

   Digunakan untuk menangani data yang memiliki pola non-linear. *Kernel* ini mampu membentuk batas pemisah berbentuk kurva yang lebih kompleks.

3. Radial Basis Function (RBF) *Kernel*

   Kernel ini sering digunakan karena mampu menangani pola data yang kompleks dan tidak linear dengan baik. RBF bekerja dengan memetakan data ke ruang dimensi sangat tinggi sehingga pola pemisahan dapat ditemukan secara lebih optimal.

Dalam penelitian analisis sentimen, penerapan *Support Vector Machine* umumnya melalui beberapa tahapan proses. Tahap pertama adalah pengumpulan data, yaitu pengambilan data teks dari sumber tertentu, seperti media sosial, misalnya platform X. Data yang diperoleh kemudian melalui tahap *preprocessing* teks untuk membersihkan unsur yang tidak diperlukan melalui proses seperti *case folding*, *tokenizing*, *stopword removal*, dan *stemming*. Setelah itu dilakukan tahap *feature extraction*, yaitu mengubah teks menjadi representasi numerik menggunakan metode seperti TF-IDF sehingga dapat diproses oleh algoritma *machine learning*.

Selanjutnya dilakukan proses pelatihan model (*training*), yaitu ketika algoritma SVM dilatih menggunakan data yang telah diberi label sentimen, seperti positif, negatif, atau netral. Model yang telah terbentuk kemudian digunakan pada tahap klasifikasi untuk menentukan sentimen dari data baru berdasarkan pola yang telah dipelajari. Tahap terakhir adalah evaluasi model untuk mengukur kinerja model menggunakan metrik evaluasi seperti *Accuracy*, *Precision*, *Recall*, dan *F1-score*.

Support Vector Machine memiliki beberapa kelebihan yang membuatnya banyak digunakan dalam penelitian *text mining* dan analisis sentimen. Algoritma ini mampu menangani data berdimensi tinggi dengan baik, seperti data teks yang memiliki jumlah fitur sangat besar. Selain itu, SVM juga relatif tahan terhadap masalah *overfitting*, terutama ketika jumlah data pelatihan terbatas. Kemampuannya dalam menentukan margin pemisah yang optimal juga membuat proses klasifikasi menjadi lebih stabil dan menghasilkan tingkat akurasi yang baik.

Meskipun demikian, SVM juga memiliki beberapa keterbatasan. Proses pelatihan model dapat membutuhkan waktu komputasi yang cukup besar

apabila dataset yang digunakan berukuran sangat besar. Selain itu, pemilihan jenis *kernel* dan parameter yang tepat sangat memengaruhi performa model yang dihasilkan. Jika parameter yang digunakan kurang tepat, maka hasil klasifikasi dapat menjadi kurang optimal. SVM juga memiliki keterbatasan dalam memahami konteks bahasa yang kompleks, seperti sarkasme atau makna implisit dalam teks, karena algoritma ini lebih berfokus pada pola matematis dari fitur yang digunakan.

2.2.4 *Topic modeling*

Topic modeling merupakan salah satu pendekatan dalam *text mining* yang digunakan untuk mengidentifikasi topik utama dalam kumpulan dokumen teks berjumlah besar. Pendekatan ini bekerja dengan mengelompokkan kata-kata yang sering muncul secara bersamaan sehingga membentuk pola tematik tertentu (Jelita, 2023a). Melalui *Topic modeling*, peneliti dapat memahami gambaran umum serta struktur topik dalam sekumpulan dokumen tanpa harus membaca seluruh isi dokumen secara manual. Oleh karena itu, metode ini efektif untuk menganalisis data teks yang tidak terstruktur dan memiliki volume besar.

Secara umum, *Topic modeling* termasuk ke dalam metode *unsupervised learning* karena proses identifikasi topik dilakukan tanpa memerlukan label atau kategori yang telah ditentukan sebelumnya. Algoritma secara otomatis menemukan pola keterkaitan antar kata yang sering muncul dalam dokumen sehingga menghasilkan kelompok topik tertentu. Dalam pendekatan ini, setiap dokumen diasumsikan sebagai kombinasi dari beberapa topik, sedangkan setiap topik direpresentasikan sebagai distribusi probabilitas dari sekumpulan kata tertentu. Dengan demikian, model mampu menangkap keterkaitan makna antar kata berdasarkan konteks kemunculannya dalam dokumen.

Pendekatan ini banyak digunakan dalam berbagai penelitian yang berkaitan dengan analisis dokumen teks, seperti analisis berita, media sosial, ulasan pengguna, maupun dokumen ilmiah. Melalui *Topic modeling*, peneliti dapat menemukan pola pembahasan, isu dominan, serta hubungan antar topik yang

muncul dalam suatu kumpulan dokumen. Oleh karena itu, metode ini sering digunakan sebagai teknik eksplorasi data teks untuk memperoleh wawasan awal terhadap isi data sebelum dilakukan analisis lebih lanjut.

Salah satu metode *Topic modeling* yang paling banyak digunakan adalah *Latent Dirichlet Allocation* (LDA). LDA merupakan model statistik yang mengasumsikan bahwa setiap dokumen terbentuk dari campuran beberapa topik, dan setiap topik memiliki distribusi probabilitas terhadap kata-kata tertentu. Dalam prosesnya, dokumen dimodelkan seolah-olah dihasilkan melalui pemilihan topik secara acak, kemudian dari topik tersebut dipilih kata-kata yang menyusun isi dokumen. Pendekatan ini memungkinkan LDA mengidentifikasi topik laten secara otomatis tanpa supervisi serta memberikan representasi dokumen dalam bentuk distribusi topik yang ringkas dan informatif (Puspita et al., 2024).

Konsep utama dalam LDA adalah bahwa dokumen tidak hanya berkaitan dengan satu topik, tetapi dapat terdiri dari beberapa topik sekaligus dengan proporsi yang berbeda. Misalnya, sebuah dokumen dapat terdiri dari 60% topik pendidikan, 30% topik teknologi, dan 10% topik ekonomi. Dengan menggunakan pendekatan probabilistik tersebut, LDA mampu menggambarkan struktur topik dalam dokumen secara lebih fleksibel..

Secara umum, cara kerja metode LDA dapat dijelaskan melalui beberapa tahapan utama. Pada tahap awal, kumpulan dokumen diproses untuk memperoleh daftar kata yang muncul dalam seluruh dokumen. Selanjutnya, algoritma menentukan sejumlah topik yang ingin ditemukan dalam kumpulan dokumen tersebut. Setelah itu, setiap kata dalam dokumen diasosiasikan secara acak dengan salah satu topik yang tersedia.

Pada tahap berikutnya, algoritma LDA melakukan proses iterasi secara berulang untuk memperbarui distribusi topik pada dokumen dan distribusi kata pada setiap topik. Dalam proses ini, probabilitas kemunculan suatu kata dalam topik tertentu dihitung berdasarkan frekuensi kemunculan kata tersebut dalam dokumen serta distribusi topik yang terbentuk. Proses iterasi dilakukan hingga model mencapai kondisi konvergen atau stabil sehingga menghasilkan distribusi topik yang paling representatif terhadap kumpulan dokumen yang dianalisis.

Secara sederhana, alur kerja metode LDA dapat dijelaskan sebagai berikut:

1. Pengumpulan Dokumen

   Peneliti mengumpulkan sekumpulan dokumen teks sebagai data utama yang akan dianalisis. Data tersebut berfungsi sebagai korpus dasar dalam proses pembentukan topik.

2. *Preprocessing* Teks

   Dokumen teks melalui tahap pembersihan untuk menghasilkan kumpulan kata yang lebih bermakna. Proses ini meliputi *case folding*, *tokenizing*, *stopword removal*, dan *stemming*. Tahapan ini sangat penting karena kualitas topik yang dihasilkan bergantung pada kebersihan data teks.

3. Pembentukan Matriks Dokumen-Kata

   Dokumen teks melalui tahap pembersihan untuk menghasilkan kumpulan kata yang lebih bermakna. Proses ini meliputi *case folding*, *tokenizing*, *stopword removal*, dan *stemming*. Tahapan ini sangat penting karena kualitas topik yang dihasilkan bergantung pada kebersihan data teks.

4. Inisialisasi Topik dan Penentuan Jumlah Topik (*K*)

   Peneliti menentukan jumlah topik (K) yang akan diidentifikasi di dalam dokumen. Penentuan nilai K yang optimal dilakukan dengan membandingkan nilai *Topic Coherence* dan *Perplexity*. Nilai *Coherence* yang tinggi menunjukkan bahwa kata-kata dalam satu topik memiliki keterkaitan semantik yang kuat bagi manusia.

5. Proses Iterasi LDA

   Algoritma melakukan proses iterasi secara berulang untuk menghitung distribusi probabilitas kata pada setiap topik. Selain itu, algoritma juga menghitung distribusi probabilitas topik pada setiap dokumen. Proses ini berlangsung hingga model mencapai kondisi stabil atau konvergen.

6. Identifikasi Topik dan Evaluasi Topik

   Algoritma melakukan proses iterasi secara berulang untuk menghitung distribusi probabilitas kata pada setiap topik. Selain itu, algoritma juga menghitung distribusi probabilitas topik pada setiap dokumen. Proses ini berlangsung hingga model mencapai kondisi stabil atau konvergen.

Secara matematis, model LDA menggunakan distribusi probabilitas *Dirichlet* untuk menggambarkan distribusi topik pada dokumen dan distribusi kata pada topik. Probabilitas suatu kata dalam dokumen dapat dinyatakan sebagai:

$$P(w) = \sum_{Z=1}^{K} P(w|z)P(z|d) \tag{2.10}$$

di mana:

a. P(w) merupakan probabilitas kemunculan kata dalam dokumen
b. P(w|z) merupakan probabilitas kata w muncul pada topik z
c. P(z|d) merupakan probabilitas topik z muncul pada dokumen d
d. K merupakan jumlah topik yang digunakan dalam model

Persamaan tersebut menunjukkan bahwa kemunculan suatu kata dalam dokumen dipengaruhi oleh distribusi topik dalam dokumen serta distribusi kata pada setiap topik. Dengan menggunakan pendekatan probabilistik ini, LDA mampu mengidentifikasi topik-topik tersembunyi (*latent topics*) dalam kumpulan dokumen teks.

Penerapan *Topic modeling* dengan metode LDA telah banyak digunakan dalam penelitian analisis teks. Salah satunya ditunjukkan dalam penelitian Jelita (2023) yang menganalisis pertanyaan dalam kegiatan gelar wicara literasi. Dalam penelitian tersebut, metode LDA mampu mengelompokkan pertanyaan ke dalam beberapa topik utama yang merepresentasikan isu-isu dominan yang sering dibahas. Hasil penelitian tersebut menunjukkan bahwa *Topic modeling* tidak hanya berfungsi sebagai alat eksplorasi data teks, tetapi juga dapat dimanfaatkan untuk membantu peneliti memahami fokus pembahasan secara sistematis dan berbasis data dalam penelitian dokumen teks berskala besar.

2.2.5 Platform X

X merupakan salah satu media sosial yang banyak digunakan sebagai sumber data dalam penelitian analisis sentimen. Hal ini disebabkan oleh

karakteristik platform tersebut yang memungkinkan pengguna membagikan opini, pengalaman, maupun pandangan terhadap berbagai topik secara terbuka. Sebagian besar konten yang dipublikasikan di X bersifat publik sehingga dapat diakses oleh peneliti melalui *Application Programming Interface* (API). Fasilitas ini memungkinkan proses pengumpulan data dilakukan secara otomatis dalam jumlah besar sehingga mendukung penelitian yang berkaitan dengan analisis opini publik berbasis data teks.

Salah satu karakteristik utama X adalah format unggahan berupa *tweet* dengan batas maksimal 280 karakter. Batasan ini mendorong pengguna menyampaikan pesan secara ringkas, padat, dan langsung pada inti permasalahan. Struktur teks yang relatif singkat tersebut memudahkan proses pengolahan data dalam penelitian *text mining* dan *natural language processing*. Selain itu, penggunaan tagar (*hashtags*), *mention*, dan *retweet* memungkinkan penyebaran informasi serta diskusi publik terjadi secara cepat dan luas sehingga topik tertentu dapat dengan mudah menjadi perbincangan di kalangan pengguna.

X juga dikenal sebagai platform yang sering digunakan masyarakat untuk menyampaikan pendapat mengenai berbagai isu, seperti isu sosial, politik, ekonomi, maupun pengalaman pribadi dalam kehidupan sehari-hari. Banyaknya interaksi yang terjadi di platform ini menghasilkan kumpulan data teks yang besar dan beragam. Data tersebut dapat dimanfaatkan oleh peneliti untuk mengidentifikasi pola opini, kecenderungan sentimen, serta dinamika persepsi masyarakat terhadap suatu fenomena tertentu.

Dalam konteks penelitian analisis sentimen, X menjadi salah satu sumber data yang penting karena mencerminkan ekspresi opini publik secara spontan dan *real time*. Informasi yang dibagikan oleh pengguna sering kali menggambarkan respons langsung masyarakat terhadap suatu isu yang sedang berkembang. Oleh karena itu, analisis terhadap data dari platform ini dapat memberikan gambaran yang lebih luas mengenai sikap dan pandangan masyarakat terhadap suatu topik.

Pada penelitian ini, X dipilih sebagai sumber data untuk menganalisis fenomena “takut menikah”. Platform ini sering dijadikan ruang bagi pengguna untuk mengekspresikan pandangan, pengalaman, maupun keresahan pribadi terkait

hubungan, pernikahan, dan dinamika kehidupan sosial. Melalui analisis terhadap teks yang dipublikasikan oleh pengguna di X, penelitian ini diharapkan dapat memberikan gambaran mengenai kecenderungan sentimen masyarakat terhadap fenomena tersebut (Wahyuni, 2022).

2.2.6 Python

Python merupakan bahasa pemrograman tingkat tinggi (*high-level programming language*) yang banyak dimanfaatkan dalam pengolahan data*, data mining*, serta pengembangan sistem berbasis kecerdasan buatan (Maesaroh et al., 2024). Bahasa ini dirancang dengan *sintaks* yang sederhana dan mudah dipahami, sehingga memudahkan proses penulisan serta pengembangan program. Selain itu, *Python* mengedepankan prinsip keterbacaan kode (*code readability*) melalui struktur penulisan yang jelas dan konsisten, sehingga lebih mudah dipelajari baik oleh pemula maupun pengembang berpengalaman. Karakteristik tersebut menjadikan *Python* sebagai salah satu bahasa pemrograman yang populer digunakan dalam penelitian di bidang analisis data dan *Machine Learning*.

Python juga memiliki fleksibilitas yang tinggi karena mendukung berbagai paradigma pemrograman, seperti pemrograman berorientasi objek (*object-oriented programming*), pemrograman prosedural, dan pemrograman fungsional. Keunggulan lain dari *Python* adalah ketersediaan berbagai pustaka (*library*) yang mendukung pengolahan data dan pengembangan model *machine learning*. Berbagai pustaka tersebut memungkinkan proses analisis data dilakukan secara lebih efisien, mulai dari tahap pengolahan data, ekstraksi fitur, hingga pembangunan model klasifikasi.

Dalam bidang *text mining* dan analisis sentimen, *Python* sering digunakan karena mampu mengolah data teks dalam jumlah besar secara efektif. Selain itu, *Python* juga banyak dimanfaatkan dalam penelitian analisis sentimen yang menggunakan data dari media sosial, seperti Twitter, karena kemampuannya dalam mengintegrasikan berbagai teknik pemrosesan bahasa alami (*Natural Language Processing*), ekstraksi fitur, serta algoritma klasifikasi dalam satu lingkungan

pemrograman yang terpadu. Hal ini menjadikan *Python* sebagai salah satu alat yang banyak digunakan dalam penelitian yang berkaitan dengan analisis opini publik berbasis data teks (Wahyuni, 2022).

Dalam penelitian ini, *Python* digunakan sebagai alat utama untuk melakukan pengolahan dan analisis data teks yang diperoleh dari platform X. Penggunaan *Python* mencakup beberapa tahapan penting dalam proses analisis sentimen. Tahap pertama adalah pengumpulan data dan *text preprocessing*, yang meliputi proses *case folding*, *tokenizing*, *stopword removal*, serta *stemming* untuk membersihkan data teks dari kata-kata yang tidak relevan. Setelah itu, *Python* digunakan untuk melakukan proses *feature extraction* menggunakan metode TF-IDF sehingga data teks dapat direpresentasikan dalam bentuk numerik. Tahap selanjutnya adalah penerapan algoritma *Support Vector Machine* (SVM) untuk melakukan klasifikasi sentimen terhadap data teks yang telah diproses. Dengan dukungan pustaka yang tersedia, *Python* memungkinkan proses analisis sentimen dilakukan secara sistematis dan efisien sehingga dapat menghasilkan model klasifikasi yang mampu mengidentifikasi kecenderungan sentimen masyarakat terhadap fenomena takut menikah yang dibahas di platform X.

2.2.7 SocialX

Website *SocialX* Indonesia (https://www.socialx.id) merupakan sebuah platform digital yang menyediakan layanan analitik dan pengumpulan data media sosial (*social media listening*). Platform ini dirancang untuk membantu peneliti maupun praktisi data dalam menangkap tren, opini, dan persepsi publik yang berkembang di berbagai ruang digital secara efisien. Dalam penelitian ini, SocialX berfungsi sebagai instrumen teknis utama yang menjembatani proses pengambilan data mentah dari sumber aslinya.

SocialX memiliki kemampuan untuk menyajikan data dalam format yang terstruktur di samping fungsi utamanya sebagai pengumpul data. Data yang ditarik melalui platform ini mencakup informasi penting seperti isi unggahan (*tweet*), waktu unggah, dan identitas unik lainnya. Format data yang terstruktur tersebut

memudahkan tahap penelitian selanjutnya, yaitu *preprocessing* teks menggunakan Python. Data yang diperoleh sudah siap diolah ke dalam bentuk *data frame* untuk analisis lebih lanjut.

Peneliti menggunakan SocialX untuk menangkap narasi terkait isu sosial dan budaya digital di Indonesia pada penelitian ini. Layanan dari SocialX membantu peneliti memperoleh data aktual mengenai ekspresi pandangan masyarakat secara spontan. Hal tersebut memberikan landasan data yang kuat untuk melakukan analisis sentimen menggunakan *Support Vector Machine* (SVM). Selain itu, data tersebut juga digunakan untuk pemodelan topik menggunakan metode *Latent Dirichlet Allocation* (LDA).

2.2.8 Streamlit

Streamlit merupakan *framework open-source* berbasis Python yang digunakan untuk membangun aplikasi web interaktif secara cepat dan sederhana, khususnya pada bidang *data science, machine learning*, dan analisis data. *Framework* ini dirancang untuk memudahkan pengembang dalam mengubah *script* Python menjadi aplikasi web tanpa memerlukan pengetahuan mendalam mengenai pengembangan web seperti HTML, CSS, maupun JavaScript. Streamlit memungkinkan proses pengembangan aplikasi menjadi lebih efisien karena seluruh logika program dapat ditulis menggunakan bahasa Python dalam satu lingkungan pengembangan.

Menurut Tholib (2023), Streamlit merupakan *framework* Python yang digunakan untuk membangun aplikasi web dengan antarmuka pengguna interaktif untuk proyek-proyek *data science* dan *machine learning*. *Framework* ini dibangun di atas berbagai pustaka Python populer seperti NumPy, Pandas, dan Matplotlib sehingga memudahkan integrasi proses analisis data, visualisasi, serta implementasi model *machine learning* dalam satu aplikasi yang terintegrasi.

Salah satu keunggulan utama Streamlit adalah kemampuannya dalam mempercepat proses pengembangan aplikasi. Jika *framework* konvensional seperti Flask dan Django mengharuskan pengembang membangun berbagai komponen

aplikasi dari awal, Streamlit menyediakan berbagai komponen antarmuka yang siap digunakan sehingga waktu pengembangan dapat dipersingkat secara signifikan. *Framework* ini memungkinkan pengembang untuk lebih fokus pada proses analisis data dan pengembangan model dibandingkan dengan pengembangan antarmuka web.

Streamlit menyediakan berbagai komponen antarmuka yang dapat digunakan untuk menampilkan teks, tabel, grafik, gambar, formulir input, serta berbagai elemen visual lainnya. Beberapa fungsi yang umum digunakan antara lain *st.write(), st.title(), st.header(), st.subheader(), st.dataframe(),* dan *st.plotly_chart()*. Melalui komponen-komponen tersebut, pengguna dapat berinteraksi langsung dengan sistem sehingga hasil analisis maupun prediksi dapat ditampilkan secara real-time.

2.2.9 Evaluasi Model

Evaluasi model klasifikasi merupakan tahapan yang dilakukan untuk mengukur kemampuan model dalam mengklasifikasikan data secara tepat berdasarkan kelas yang telah ditentukan. Proses evaluasi dilakukan dengan membandingkan hasil prediksi model terhadap label aktual pada data uji. Evaluasi model penting dilakukan untuk mengetahui tingkat keandalan model dalam melakukan prediksi pada data baru yang belum pernah digunakan selama proses pelatihan. Selain itu, penggunaan beberapa metrik evaluasi diperlukan agar performa model dapat dinilai secara lebih komprehensif dan tidak hanya bergantung pada satu ukuran evaluasi saja. Evaluasi kinerja model dilakukan menggunakan metrik *Accuracy*, *Precision*, *Recall*, dan F1-Score. Masing-masing metrik memiliki fungsi yang berbeda dalam menilai performa model klasifikasi(Armawan et al., 2026).

1. *Accuracy*

   Accuracy merupakan metrik yang digunakan untuk mengukur proporsi jumlah prediksi yang benar terhadap seluruh data yang diuji. Nilai *Accuracy* memberikan gambaran umum mengenai tingkat keberhasilan model dalam

melakukan klasifikasi. Semakin tinggi nilai *Accuracy*, maka semakin baik kemampuan model dalam memprediksi kelas data secara keseluruha yang dapat dihitung dengan rumus:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.11)$$

Dimana:

TP adalah *True Positive*

TN adalah *True Negative*

FP adalah *False Positive*

FN adalah *False Negative*

Contoh perhitungan *Accuracy*

Diketahui:

a) TP = 150
b) TN = 130
c) FP = 20
d) FN = 40

Maka,

$$Accuracy = \frac{150 + 130}{150 + 130 + 20 + 40} = 0{,}82$$

Dengan demikian, diperoleh nilai *Accuracy* sebesar 82%

2. *Precision*

Precision merupakan metrik yang digunakan untuk mengukur tingkat ketepatan prediksi positif yang dilakukan oleh model. Metrik ini menunjukkan seberapa banyak data yang diprediksi positif benar-benar termasuk ke dalam kelas positif. Nilai *Precision* yang tinggi menunjukkan bahwa model memiliki tingkat kesalahan *false positive* yang rendah. Rumus perhitungan untuk mengukur *Precision* yaitu:

$$Precision = \frac{TP}{TP + FP} \quad (2.12)$$

Dimana:

TP adalah *True Positive*

FP adalah *False Positive*

Contoh perhitungan *Precision*

Diketahui:

a) TP = 150
b) FP = 20

Maka,

$$Precision = \frac{150}{150 + 20} = 0{,}88$$

Dengan demikian, didapatkan nilai *Precision* sebesar 88%

3. *Recall*

Recall merupakan metrik yang digunakan untuk mengukur kemampuan model dalam menemukan seluruh data yang benar-benar termasuk ke dalam kelas positif. Nilai *Recall* yang tinggi menunjukkan bahwa model mampu mendeteksi sebagian besar data positif yang terdapat pada dataset. *Recall* juga digunakan untuk meminimalkan terjadinya kesalahan *false negative*. *Recall* dapat dihitung dengan rumus:

$$Recall = \frac{TP}{TP + FN} \quad (2.13)$$

Dimana:

TP adalah *True Positive*

FN adalah *False Negative*

Contoh perhitungan *Recall*

Diketahui:

a) TP = 150

b) FN = 40

Maka,

$$Recall = \frac{150}{150 + 40} = 0{,}78$$

Dengan demikian, diperoleh *Recall* sebesar 78%

4. *F1-Score*

F1-Score merupakan rata-rata harmonik antara nilai *Precision* dan *Recall*. Metrik ini digunakan untuk memberikan keseimbangan antara ketepatan prediksi positif dan kemampuan model dalam menemukan seluruh data positif. *F1-Score* sering digunakan ketika distribusi kelas pada dataset tidak seimbang karena mampu memberikan gambaran performa model secara lebih objektif dibandingkan *Accuracy* saja. Perhitungan *F1-Score* menggunakan rumus yaitu:

$$F1 - Score = \frac{2 \times (Precision \times Recall)}{precision + Recall} \quad (2.14)$$

Contoh perhitungan *F1-Score*

Diketahui:

a) *Precision* = 0,88

b) *Recall* = 0,78

Maka,

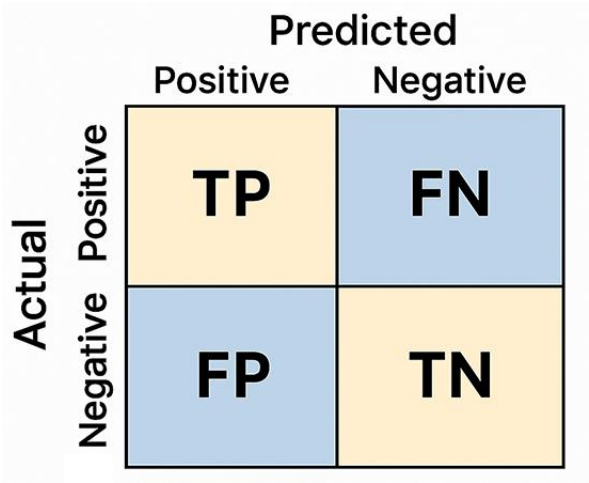
$$F1 - Score = \frac{2 \times (0{,}88 \times 0{,}78)}{0{,}88 + 0{,}78} = 0{,}82$$

Sehingga, didapatkan nilai *F1-Score* sebesar 82%.

2.2.10 *Confusion Matrix*

Confusion Matrix merupakan metode sekaligus *tools* analitik prediktif yang digunakan untuk menganalisis dan mengukur kinerja model klasifikasi pada

machine learning. Metode ini menggambarkan performa model secara rinci dengan menampilkan perbandingan langsung antara nilai aktual (sebenarnya) dan nilai hasil prediksi pada data uji. Melalui perbandingan ini, *confusion matrix* mampu menunjukkan jumlah prediksi yang benar serta jenis kesalahan prediksi yang terjadi pada setiap kelas secara spesifik. Nilai-nilai kontingensi yang diperoleh dari matriks ini kemudian digunakan sebagai dasar utama dalam perhitungan berbagai metrik evaluasi model, seperti *accuracy*, *precision*, *recall*, dan *F1-score* (Hanif Razka & Chamidah, 2023).



Gambar 2. 2 Confusion Matrix

Pada klasifikasi biner, *confusion matrix* disajikan dalam bentuk tabel kontingensi berukuran 2×2 yang membandingkan hasil prediksi model dengan kondisi aktual di lapangan. Struktur dasar matriks ini terdiri atas empat komponen utama, yaitu *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN). *True Positive* (TP) menunjukkan jumlah data berlabel aktual positif yang berhasil diidentifikasi dan diklasifikasikan secara tepat sebagai kelas positif oleh model, sedangkan *True Negative* (TN) merepresentasikan jumlah data berlabel aktual negatif yang berhasil diprediksi secara akurat sebagai kelas negatif oleh algoritma. Sebaliknya, kekeliruan prediksi model diwakili oleh *False Positive* (FP) yang terjadi ketika model memprediksi data aktual negatif sebagai sentimen positif, serta *False Negative* (FN) yang terjadi saat algoritma melakukan kesalahan berupa pelabelan sentimen negatif pada data yang esensinya bermakna positif. Keempat

nilai komponen tersebut menjadi dasar mutlak dalam perhitungan berbagai metrik evaluasi untuk menilai performa model klasifikasi secara menyeluruh, seperti *accuracy* untuk mengukur tingkat ketepatan prediksi global, *precision* untuk mengukur ketepatan prediksi pada suatu kelas spesifik, *recall* untuk menilai kemampuan model dalam menjaring data yang relevan, serta *F1-score* yang bertindak sebagai rata-rata harmonik penyeimbang antara *precision* dan *recall*.

2.2.11 *Visual Studio Code*

Visual Studio Code (VS Code) merupakan perangkat lunak editor kode sumber (*source code editor*) yang dikembangkan oleh Microsoft dan bersifat *open-source*. VS Code dirancang untuk membantu proses pengembangan perangkat lunak dengan menyediakan lingkungan kerja yang ringan, fleksibel, dan mendukung berbagai bahasa pemrograman (Ani Murani et al., 2025). Selain itu, VS Code memiliki berbagai fitur yang memudahkan pengguna dalam menulis, mengelola, dan menjalankan kode program, sehingga banyak digunakan oleh pengembang perangkat lunak maupun pelajar di bidang teknologi informasi.

Salah satu keunggulan Visual Studio Code adalah kemampuannya untuk mendukung berbagai bahasa pemrograman melalui sistem ekstensi (*extension*) yang dapat dipasang sesuai kebutuhan pengguna. VS Code juga menyediakan fitur *IntelliSense* yang mampu memberikan saran penulisan kode secara otomatis, *syntax highlighting* untuk meningkatkan keterbacaan kode, serta fitur *debugging* yang membantu pengguna dalam menemukan dan memperbaiki kesalahan program dengan lebih mudah.

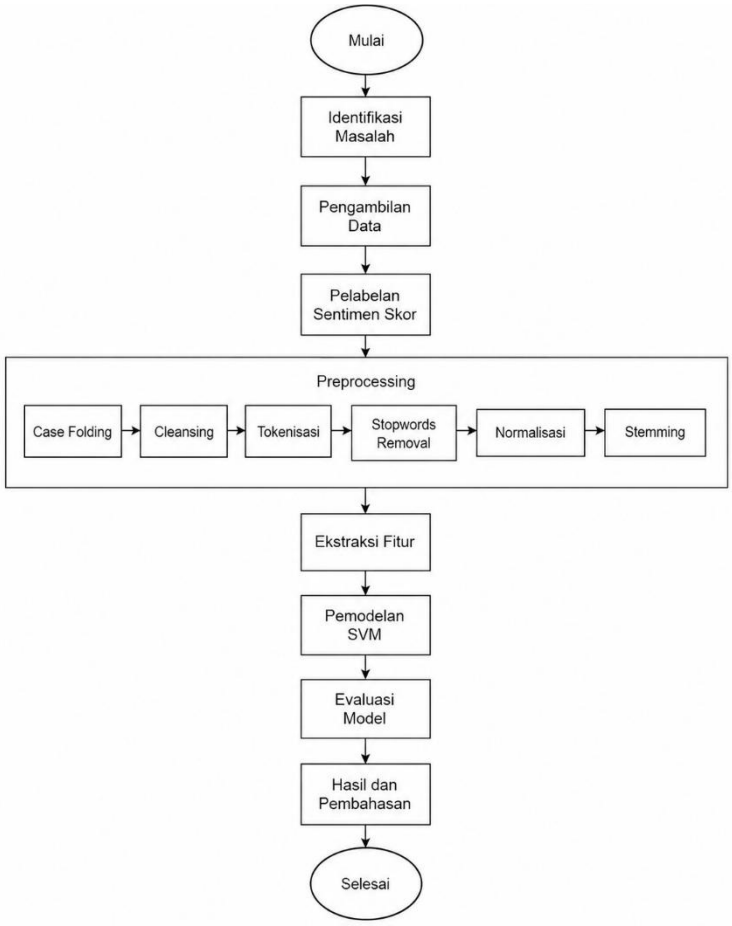
Selain itu, Visual Studio Code dilengkapi dengan *integrated terminal* yang memungkinkan pengguna menjalankan perintah dan program secara langsung tanpa harus berpindah ke aplikasi lain. Dukungan integrasi dengan berbagai pustaka (*library*) dan kerangka kerja (*framework*) juga menjadikan VS Code sebagai salah satu editor yang banyak digunakan dalam pengembangan aplikasi berbasis Python, analisis data, maupun pengembangan aplikasi web.

Dalam penelitian ini, Visual Studio Code digunakan sebagai lingkungan pengembangan utama untuk melakukan pengolahan data, implementasi algoritma *Support Vector Machine* (SVM), pemodelan topik menggunakan *Latent Dirichlet Allocation* (LDA), serta pengembangan aplikasi *web dashboard* berbasis Streamlit. Penggunaan VS Code membantu proses pengembangan sistem menjadi lebih terstruktur, efisien, dan mudah dikelola selama tahapan penelitian berlangsung.

BAB III
METODE PROYEK TUGAS AKHIR

3.1 Metode Penelitian

Penelitian eksperimen bidang *text mining* dan *machine learning* ini bertujuan menganalisis sentimen masyarakat terhadap fenomena takut menikah pada Platform X. Tahapan penelitian disusun sistematis meliputi identifikasi masalah, pengumpulan data, pelabelan, *preprocessing*, ekstraksi fitur TF-IDF, pemodelan SVM, *topic modeling*, hingga evaluasi model. Alur lengkap seluruh tahapan ini dapat dilihat pada Gambar 3.1.



Gambar 3. 1 Metode Penelitian

Penelitian ini memiliki dua bagian utama. Pertama, pembangunan dan evaluasi model klasifikasi sentimen untuk mengelompokkan opini masyarakat ke

dalam kategori positif dan negatif. Kedua, identifikasi topik pembahasan dominan menggunakan *topic modeling* untuk mengetahui isu utama yang sering dikaitkan dengan fenomena takut menikah.

Pendekatan klasifikasi sentimen dipilih karena mampu memberikan gambaran mengenai kecenderungan opini publik terhadap fenomena tersebut, sedangkan *topic modeling* digunakan untuk menggali tema-tema penting yang muncul dalam percakapan masyarakat. Dengan demikian, penelitian tidak hanya berfokus pada hasil klasifikasi sentimen, tetapi juga memberikan pemahaman lebih mendalam mengenai faktor-faktor yang memengaruhi munculnya rasa takut menikah di masyarakat.

Melalui alur penelitian ini, diharapkan diperoleh model klasifikasi sentimen yang optimal serta informasi yang akurat mengenai persepsi masyarakat terhadap fenomena takut menikah berdasarkan data dari platform X.

3.1.1 Identifikasi Masalah

Tahap identifikasi masalah merupakan langkah awal dalam penelitian ini. Pada tahap ini dilakukan pengamatan terhadap fenomena takut menikah yang semakin banyak dibahas oleh masyarakat di media sosial, khususnya pada platform X. Fenomena tersebut menunjukkan adanya berbagai pandangan, pengalaman, serta opini masyarakat mengenai pernikahan yang perlu dianalisis lebih lanjut.

Permasalahan utama dalam penelitian ini adalah bagaimana mengidentifikasi sentimen masyarakat terhadap fenomena takut menikah dan mengetahui topik-topik utama yang sering dibahas. Oleh karena itu, penelitian ini menggunakan pendekatan *text mining* dan *machine learning* untuk mengolah data teks dari media sosial menjadi informasi yang bernilai.

3.1.2 Pelabelan Sentimen Skor

Proses pengumpulan data dilakukan dengan mengunduh cuitan atau unggahan pengguna pada platform X yang berkaitan langsung dengan topik riset. Pengambilan korpus data makro ini dieksekusi memanfaatkan layanan situs analitik

SocialX berdasarkan sepuluh kombinasi kata kunci (*keywords*) yang relevan, seperti frasa "takut menikah", "belum siap nikah", dan "trauma menikah". Langkah ini bertujuan untuk memperoleh dataset mentah yang representatif terhadap opini publik di internet dalam rentang waktu yang telah ditentukan.

Setelah data mentah berhasil dikumpulkan, sistem tidak langsung melakukan pembersihan teks, melainkan mengeksekusi sub-proses penyaringan awal dan pelabelan sentimen skor (*sentiment scoring*). Langkah pemfilteran awal dijalankan untuk menyeleksi cuitan yang menggunakan bahasa Indonesia serta menghapus data kosong (*null*) dan cuitan duplikat (*retweet*). Selanjutnya, proses pelabelan dilakukan secara otomatis menggunakan fungsi penentuan skor berbasis kamus kata kunci spesifik (*lexicon keywords match*), yang memisahkan kosakata penanda kesiapan (positif) dan kosakata kecemasan (negatif). Cuitan yang memiliki kecenderungan skor negatif ekstrem akan dilabeli sebagai kelas -1 (Negatif), sedangkan cuitan dengan kecenderungan optimisme dilabeli sebagai kelas 1 (Positif), sementara cuitan yang bernilai seimbang atau netral akan dieliminasi dari dataset.

3.1.3 Pengambilan Data

Tahap pengumpulan data dilakukan dengan mengambil data berupa cuitan atau unggahan pengguna pada platform X yang berkaitan dengan fenomena takut menikah. Pengambilan data dilakukan menggunakan website Socialx.id berdasarkan kata kunci yang telah ditentukan sebelumnya, seperti “takut menikah”, “enggan menikah”, dan kata kunci lain yang relevan.

Tujuan tahap ini adalah memperoleh data set yang sesuai dengan topik penelitian sehingga data yang digunakan benar-benar merepresentasikan opini masyarakat terhadap fenomena tersebut. Data yang terkumpul kemudian disimpan dalam format data set untuk diproses pada tahap selanjutnya.

3.1.4 *Preprocessing*

Tahap *preprocessing* bertujuan untuk membersihkan dan menyiapkan data teks agar dapat diproses oleh sistem. Data dari media sosial umumnya masih mengandung banyak unsur yang tidak relevan seperti simbol, singkatan, atau karakter khusus sehingga perlu dilakukan pembersihan.

Tahapan *preprocessing* meliputi:

a. *Case Folding*, yaitu mengubah seluruh huruf menjadi huruf kecil.
b. *Cleansing atau Remove Punctuantion*, yaitu menghapus karakter yang tidak diperlukan seperti URL, simbol, dan tanda baca.
c. Tokenisasi, yaitu memecah kalimat menjadi kata-kata.
d. *Stopword Removal,* yaitu menghapus kata yang tidak memiliki makna penting.
e. Normalisasi, yaitu memperbaiki kata tidak baku menjadi kata baku.
f. *Stemming,* yaitu mengubah kata menjadi bentuk dasar.

3.1.5 Ekstraksi Fitur

Setelah *preprocessing* selesai, data teks diubah ke dalam bentuk numerik menggunakan metode TF-IDF (*Term Frequency-Inverse Document Frequency*). Metode ini memberikan bobot pada setiap kata berdasarkan frekuensi kemunculan kata dalam dokumen dan tingkat kepentingannya pada seluruh data set.

Kata yang sering muncul dalam satu dokumen namun jarang muncul pada dokumen lain akan memiliki bobot lebih tinggi. Hasil dari tahap ini berupa representasi numerik yang dapat digunakan oleh algoritma *machine learning.*

3.1.6 Pemodelan

Tahap ini merupakan proses pembangunan model klasifikasi sentimen menggunakan algoritma *Support Vector Machine* (SVM). Algoritma SVM bekerja dengan mencari *hyperplane* terbaik untuk memisahkan data ke dalam beberapa kelas sentimen secara optimal.

Data hasil ekstraksi fitur TF-IDF dibagi menjadi data latih dan data uji. Data latih digunakan untuk melatih model, sedangkan data uji digunakan untuk mengukur kemampuan model dalam mengklasifikasikan data baru.

3.1.7 Evaluasi Model

Model yang telah dibangun kemudian dievaluasi untuk mengetahui tingkat kinerjanya. Evaluasi dilakukan menggunakan *confusion matrix* dan beberapa metrik pengukuran, yaitu *Accuracy, Precision, Recall*, dan F1-score.

Nilai evaluasi tersebut digunakan untuk mengetahui seberapa baik model dalam mengklasifikasikan sentimen masyarakat terhadap fenomena takut menikah. Semakin tinggi nilai evaluasi, maka semakin baik performa model yang dihasilkan.

3.1.8 Hasil dan Pembahasan

Tahap terakhir adalah penyajian hasil penelitian dan pembahasan. Pada tahap ini ditampilkan hasil klasifikasi sentimen berupa distribusi sentimen positif, negatif, dan netral. Selain itu, disajikan pula hasil *topic modeling* berupa topik-topik dominan yang muncul dalam pembahasan masyarakat.

Selanjutnya hasil tersebut dianalisis dan diinterpretasikan untuk memahami persepsi masyarakat terhadap fenomena takut menikah serta faktor-faktor yang memengaruhinya. Dengan demikian, penelitian ini diharapkan mampu memberikan gambaran yang komprehensif mengenai fenomena tersebut berdasarkan data dari platform X.

3.2 Objek Penelitian

Objek dalam penelitian ini adalah data teks berupa cuitan pengguna pada platform X yang berkaitan dengan fenomena takut menikah. Data yang digunakan diperoleh dari hasil *scraping* berdasarkan kata kunci yang telah ditentukan. Kata kunci tersebut digunakan untuk memastikan bahwa data yang dikumpulkan relevan

dengan topik penelitian. Penelitian ini menggunakan lima kata kunci utama yang mencerminkan fenomena takut menikah di kalangan masyarakat.

Periode waktu pengambilan data dimulai dari 01 Januari 2020 hingga 01 April 2026. Rentang waktu ini dipilih untuk memperoleh data yang cukup representatif dan sesuai dengan kondisi terkini. Jumlah data yang dikumpulkan dalam penelitian ini sebanyak kurang lebih 3.100 cuitan. Data tersebut kemudian digunakan sebagai bahan analisis untuk mengidentifikasi sentimen masyarakat terhadap fenomena takut menikah. Seluruh data yang diperoleh akan melalui proses pengolahan sebelum digunakan dalam tahap pemodelan dan analisis lebih lanjut. Berikut data yang telah diambil berdasarkan kata kunci pada Tabel 3.1.

Tabel 3. 1 Hasil Pengambilan Data

No	Full Text
1	@nasgorgurl @jnghwnuna_ @convomfs Screenshot mu cuma membenarkan kalo laki-laki takut gabisa adil, maka kawinlah dengan 1 wanita dan budak belian. Yang nentuin adil tidaknya setelah menikah siapa? Apa butuh ridho istri kalo laki mau make budaknya? Kaga
2	@tanyakanrl Alhamdulillah nya gak pernah ke ganggu dengan kalimat "kapan nikah?" Karna emang kepikiran gak kepikiran sih.. karna lebih ke bukan pernikahan nya yg di takutin tapi lebih takut menikah dengan orang yang salah.. jadi bawa santai aja.. walau tahun ini udah umur 30 th
3	@Askrlfess Agak ragu kalo dia ngadu bakal ditanggepin/dibelain ama keluarga si cowo, tapi kalaupun di bela dan disuruh nikah justru w ovt takut si cowo memperlakukan si cewe dengan tidak baik karena alasan mereka menikah yaitu adanya keterpaksaan atau bisa jadi rawan selingkuh lg
4	alhamdulillah setelah ngobrol sama ibuk jadi lebih tenang, aku juga ga takut akan tuntutan cepat menikah wkwkw. sejatinya memang perempuan ga bergantung kan. aku bebas mau menentukan karirku tanpa takut embel embel nikah wqwq
5	Lagi pengangguran, tapi pengen nikah? Hmmm besar juga nyalinya. Yg gak pengangguran, tiap bln punya penghasilan aja msh takut sm yg namanya menikah. Takut gagal karna sehati2 itu nyari pasangan Tapi org miskin kek aku ga relate sih. Klo mo nikah hrs nyari duit dlu buat biayanya

Data hasil pengambilan berdasarkan kata kunci disajikan pada Tabel 3.1. Kata kunci yang digunakan dalam penelitian ini meliputi “takut menikah”, “takut nikah”, “trauma menikah”, “alasan tidak mau menikah”, “belum siap nikah”, “biaya nikah mahal”, “gak mau nikah”, “gamau menikah”, “takut cerai”, dan “gk siap menikah”. Kata kunci tersebut dipilih karena mewakili berbagai bentuk persepsi masyarakat terhadap pernikahan, baik berupa rasa takut, trauma, penolakan, maupun ketidaksiapan dalam membangun rumah tangga. Dengan menggunakan

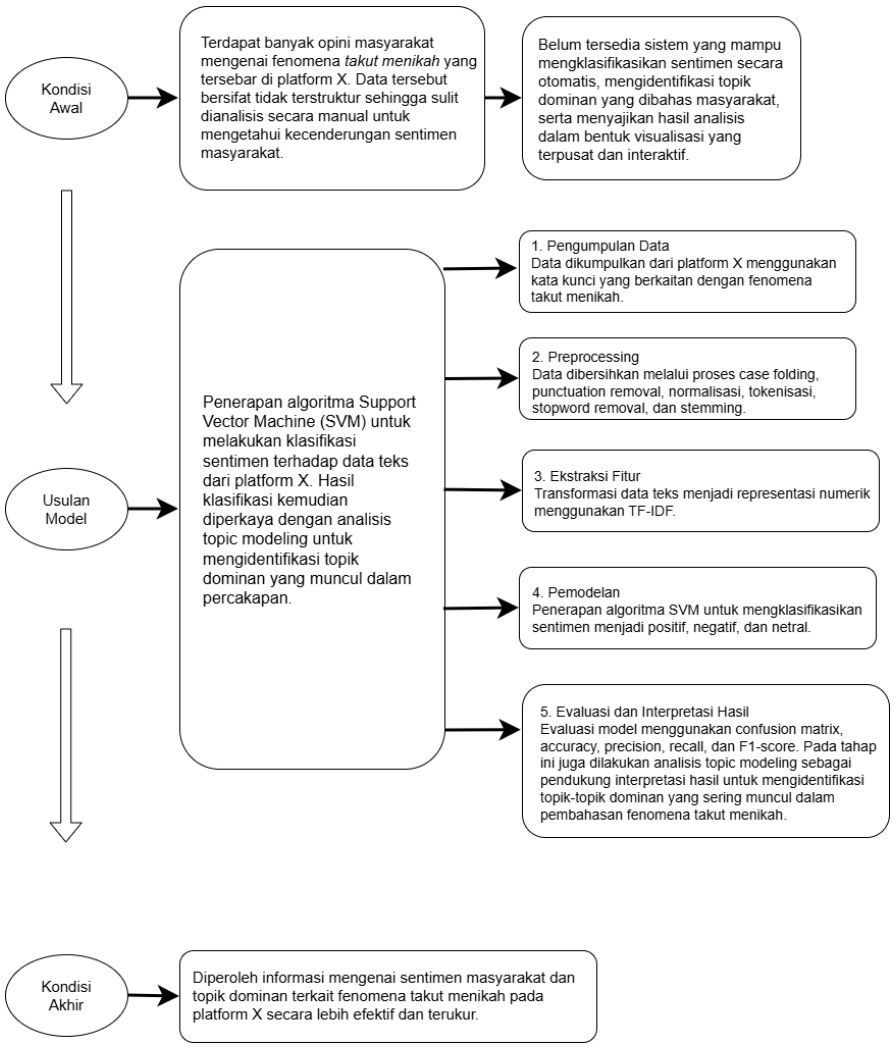
beberapa kata kunci yang berbeda, data yang diperoleh diharapkan lebih beragam dan tidak hanya terfokus pada satu sudut pandang tertentu.

Berdasarkan contoh data pada Tabel 3.1, cuitan yang diperoleh masih berupa data mentah dari pengguna platform X. Data tersebut masih mengandung bahasa tidak baku, singkatan, kata gaul, *mention*, tautan, tanda baca berlebih, serta variasi penulisan kata yang umum ditemukan pada media sosial. Kondisi tersebut menyebabkan data belum dapat langsung digunakan dalam proses klasifikasi. Oleh sebab itu, data perlu melalui tahap *preprocessing* terlebih dahulu. Tahap *preprocessing* yang dilakukan meliputi *cleansing text*, *stopword removal*, tokenisasi, *stemming*, dan pelabelan sentimen. Setelah melalui tahapan tersebut, data menjadi lebih terstruktur dan siap digunakan dalam proses klasifikasi sentimen menggunakan metode *Support Vector Machine*.

BAB IV
ANALISIS DAN PERANCANGAN

4.1 Analisis Sistem

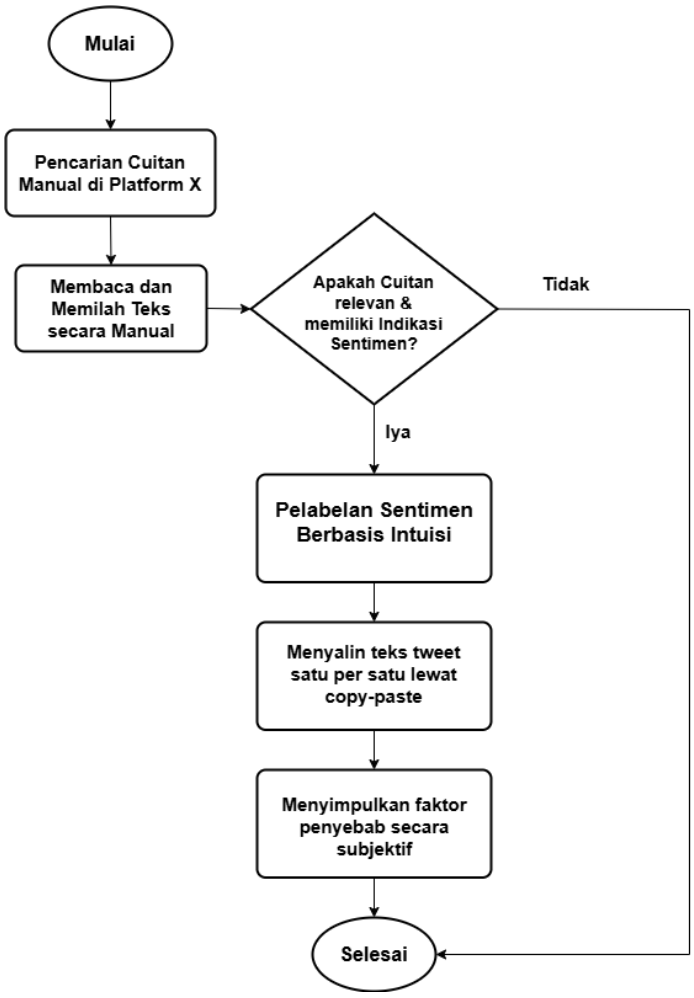
Proses analisis sistem ini dirancang secara sistematis dan digambarkan melalui diagram alir pada Gambar 4.1.



Gambar 4. 1 Kerangka Penelitian

4.1.1 Analisis Sistem yang Berjalan

Analisis sistem yang berjalan dilakukan untuk memahami bagaimana proses pengamatan, pengumpulan, dan penafsiran opini publik terkait fenomena takut menikah dilakukan sebelum adanya sistem otomatisasi yang diusulkan. Berdasarkan hasil observasi terhadap tren di media sosial, diketahui bahwa proses analisis sentimen dan pemetaan topik terhadap cuitan masyarakat saat ini masih dilakukan secara konvensional, bersifat subjektif, dan belum memanfaatkan algoritma kecerdasan buatan secara optimal. Alur kerja dari sistem yang berjalan pada analisis opini fenomena takut menikah ini disajikan pada Gambar 4.2.



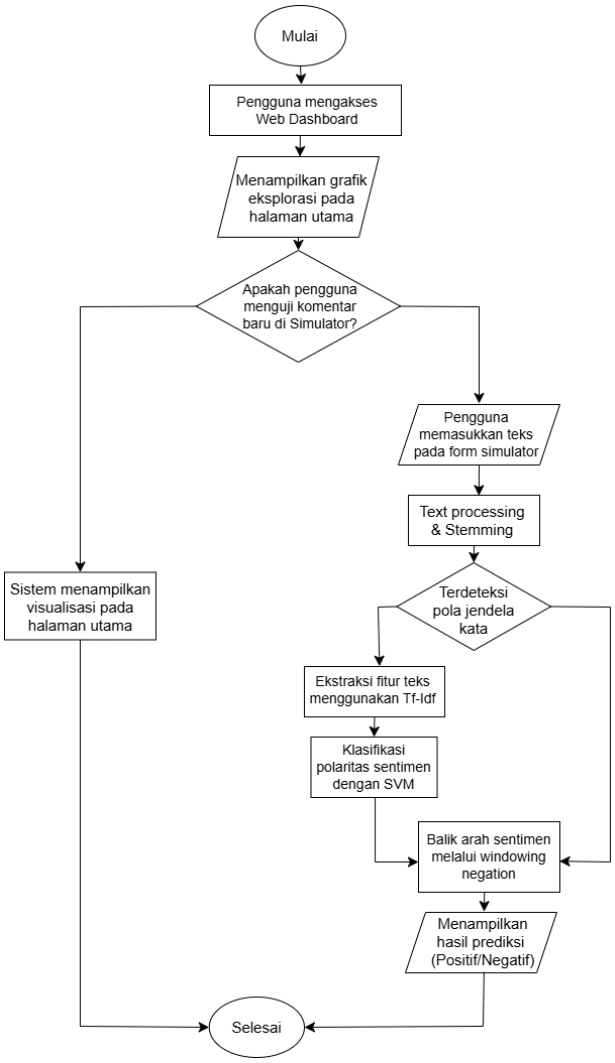
Gambar 4. 2 Sistem yang Sedang Berjalan

4.1.2 Analisis Sistem yang Diusulkan

Sistem yang diusulkan dalam penelitian ini merupakan sistem analisis sentimen yang memanfaatkan algoritma *Support Vector Machine* (SVM) dengan pembobotan TF-IDF untuk mengklasifikasikan sentimen masyarakat terhadap fenomena takut menikah pada platform X. Selain melakukan klasifikasi sentimen, sistem juga menerapkan *topic modeling* sebagai analisis pendukung untuk mengidentifikasi topik-topik dominan yang sering muncul dalam percakapan masyarakat. Penerapan kedua metode tersebut bertujuan untuk menghasilkan informasi yang tidak hanya menunjukkan kecenderungan sentimen masyarakat, tetapi juga faktor-faktor yang melatarbelakangi munculnya sentimen tersebut.

Proses analisis diawali dengan pengumpulan dan pengolahan data teks melalui beberapa tahapan *preprocessing*, meliputi pembersihan teks, penghapusan *stopword*, dan *stemming*. Data yang telah diproses kemudian ditransformasikan ke dalam bentuk representasi numerik menggunakan TF-IDF *Vectorizer* sehingga dapat diproses oleh algoritma SVM. Selanjutnya, model SVM digunakan untuk mengklasifikasikan data ke dalam kategori sentimen positif dan negatif. Hasil klasifikasi yang diperoleh kemudian dianalisis lebih lanjut menggunakan *topic modeling* untuk mengidentifikasi pola pembahasan dan topik-topik dominan yang berkaitan dengan fenomena takut menikah.

Model yang diusulkan selanjutnya diimplementasikan ke dalam sebuah *Web Dashboard* interaktif berbasis *Streamlit. Dashboard* berfungsi sebagai media visualisasi hasil analisis yang memungkinkan pengguna melihat distribusi sentimen, performa model, serta topik-topik dominan yang dihasilkan oleh proses *topic modeling*. Selain itu, sistem juga menyediakan fitur prediksi sentimen secara *real-time* sehingga pengguna dapat melakukan pengujian terhadap teks baru secara langsung. Dengan adanya integrasi antara model analisis dan *dashboard* visualisasi, sistem diharapkan mampu membantu proses analisis opini publik secara lebih efektif, sistematis, dan berbasis data. Gambaran visual dari arsitektur implementasi sistem tersebut disajikan pada Gambar 4.3.



Gambar 4. 3 Sistem Yang Diusulkan

1. Pemuatan Berkas Ringkasan

   Fitur ini dirancang untuk melakukan proses pembacaan data ringkasan hasil analisis dari berkas biner counts_data.pkl secara otomatis saat aplikasi pertama kali diakses. Proses pemuatan otomatis ini berfungsi untuk menarik data statistik sentimen dan topik yang telah diekstrak sebelumnya agar dapat langsung digunakan oleh komponen antarmuka web.

2. Visualisasi Grafik Eksplorasi

   Sistem harus mampu memetakan data hasil pemuatan secara interaktif ke dalam bentuk enam komponen grafik utama pada halaman visualisasi.

Komponen grafik tersebut meliputi *Donut Chart* sentimen untuk melihat rasio kelas, *Confusion Matrix* untuk mengevaluasi performa, bobot statistik *hyperplane* SVM untuk melihat signifikansi kata, *Violin Plot* untuk kerapatan panjang karakter, prevalensi sub-topik isu, dan peta jarak antar-topik via *Bubble Chart*.

3. Penyediaan Antarmuka Simulator

   Halaman utama simulator prediksi sentimen wajib dilengkapi dengan komponen *text area* atau kolom input dinamis. Komponen antarmuka ini berfungsi sebagai media interaksi bagi pengguna untuk memasukkan atau mengetik kalimat cuitan baru secara acak dan mandiri.

4. *Back-End Preprocessing*

   Sistem wajib mampu mengeksekusi tahapan pembersihan teks input secara otomatis yang meliputi penghapusan atribut *noise* (*cleansing*), pengubahan huruf kecil (*case folding*), penghapusan kata umum (*stopword removal*), dan pencarian kata dasar menggunakan *stemmer* Sastrawi.

5. Aturan Pengecekan Kata Negasi

   Pendeteksian urutan token teks hasil *Preprocessing* dilakukan untuk menemukan keberadaan kata pemicu negasi seperti kata tidak, gak, atau bukan. Proses pemindaian ini berjalan di dalam jendela jarak tiga kata ke depan guna mendeteksi pembalikan makna, lalu keputusan polaritas sentimen akan dibalik secara otomatis jika pola negasi tersebut terpenuhi..

6. Transformasi Fitur Numerik

   Proses ekstraksi fitur berfungsi mengubah dokumen teks bersih yang bersifat kualitatif menjadi representasi matriks numerik kuantitatif. Transformasi ini dieksekusi melalui skema pembobotan statistik *Tf-Idf Vectorizer* dengan memuat konfigurasi dari berkas biner tfidf_vectorizer.pkl agar dimensi data input sesuai dengan dimensi model latih.

7. Eksekusi Klasifikasi Sentimen

   Perhitungan nilai prediksi akhir dijalankan secara matematis dengan memuat model keputusan dari berkas biner model_svm.pkl. Mesin ini akan menentukan label sentimen final, apakah termasuk ke dalam kategori

sentimen Positif atau Negatif, kemudian langsung menampilkan hasil klasifikasi tersebut pada layar antarmuka pengguna secara *real-time*.

4.2 Analisis Fungsional

4.2.1 Kebutuhan Fungsional

Kebutuhan fungsional merupakan spesifikasi yang menjelaskan kemampuan serta fitur utama yang harus dimiliki oleh perangkat lunak agar sistem dapat beroperasi sesuai dengan tujuan penelitian. Adapun kebutuhan fungsional pada sistem yang diusulkan sebagai berikut:

1. Pengelolaan Data

   Sistem harus mampu memuat dan mengelola data teks yang berasal dari platform X sebagai sumber data utama dalam proses analisis sentimen dan *topic modeling.*
2. *Preprocessing*

   Sistem harus mampu melakukan *preprocessing* secara otomatis untuk meningkatkan kualitas data sebelum dianalisis. Tahapan *preprocessing* meliputi *case folding, cleansing, tokenisasi, stopword removal,* dan *stemming* sehingga teks menjadi lebih terstruktur dan siap digunakan pada tahap berikutnya.
3. Ekstraksi Fitur

   Sistem harus mampu mengubah data teks menjadi representasi numerik menggunakan metode TF-IDF. Hasil transformasi ini digunakan sebagai masukan bagi model klasifikasi sentimen.
4. Klasifikasi Sentimen

   Sistem harus mampu melakukan klasifikasi sentimen menggunakan algoritma *Support Vector Machine* (SVM) untuk mengelompokkan data ke dalam kategori sentimen positif dan negatif berdasarkan karakteristik teks yang dianalisis.
5. Identifikasi Topik

Sistem harus mampu melakukan analisis *topic modeling* untuk mengidentifikasi topik-topik dominan yang muncul dalam percakapan masyarakat terkait fenomena takut menikah. Hasil analisis ini digunakan sebagai pendukung interpretasi terhadap hasil klasifikasi sentimen.

6. Evalusi Model

   Sistem harus mampu menghitung dan menampilkan hasil evaluasi model menggunakan *confusion matrix, Accuracy, Precision, Recall*, dan *F1-Score* untuk mengukur tingkat kinerja model klasifikasi yang dibangun.

7. Visualisasi dan Prediksi Sentimen

   Sistem harus mampu menyajikan hasil analisis sentimen, hasil evaluasi model, serta topik dominan dalam bentuk visualisasi yang informatif dan mudah dipahami. Selain itu, sistem juga harus menyediakan fitur prediksi sentimen terhadap teks baru yang dimasukkan oleh pengguna secara real-time menggunakan model yang telah dilatih sebelumnya.

4.2.2 Kebutuhan Non-Fungsional

Kebutuhan non-fungsional meliputi spesifikasi teknis, batasan sistem, serta lingkungan operasional yang mendukung proses implementasi sistem. Dalam penelitian ini, kebutuhan non-fungsional dibedakan menjadi dua aspek utama, yaitu:

1. Perangkat Keras (*Hardware)*

   Spesifikasi perangkat keras yang digunakan selama proses pengolahan dataset, pelatihan model SVM Linier, hingga simulasi pengujian sistem bergantung pada performa komputer yang digunakan oleh peneliti pada tabel 4.1

Tabel 4. 1 Perangkat Keras Yang Digunakan Pada Penelitian

Komponen	Spesifikasi
Perangkat	Laptop HP Pavilion 14-dv2xxx
Prosesor	12th Gen Intel(R) Core(TM) i5-1235U (1.30 GHz)
RAM	16 GB
Tipe Sistem	64-bit operating system, x64-based processor
Sistem Operasi	Windows 11 Home Single Language

2. Perangkat Lunak (*Software)*

Infrastruktur perangkat lunak, bahasa pemrograman, pustaka (*libraries*), dan perangkat pengembangan yang digunakan dalam penelitian ini pada Tabel 4.2

Tabel 4. 2 Perangkat Lunak Yang Digunakan Pada Penelitian

Perangkat Lunak	Keterangan
Python	Versi 3.12.6
Visual Studio Code	Versi 1.111.0
Google Chrome	Digunakan sebagai media implementasi ekstensi
Jupyter Notebook / Google Colab	Digunakan untuk eksperimen dan pengolahan model
pandas	Digunakan untuk pengolahan data
numpy	Digunakan untuk komputasi numerik
scikit-learn	Digunakan untuk pembentukan dan evaluasi model SVM
matplotlib	Digunakan untuk visualisasi data
openpyxl	Digunakan untuk membaca dan menulis file Excel
joblib	Digunakan untuk penyimpanan model

4.3 Perancangan Sistem

Perancangan sistem menggambarkan bagaimana model analisis sentimen yang diusulkan diimplementasikan dalam bentuk aplikasi berbasis web. Perancangan mencakup interaksi antara pengguna dengan sistem, alur pemrosesan data, serta tampilan antarmuka yang digunakan untuk menampilkan hasil analisis.

Sistem yang dikembangkan berfungsi untuk mengidentifikasi sentimen masyarakat terhadap fenomena takut menikah pada platform X menggunakan algoritma *Support Vector Machine* (SVM) dengan pembobotan TF-IDF, serta didukung oleh *topic modeling* untuk mengidentifikasi topik-topik dominan yang muncul dalam percakapan masyarakat. Hasil analisis kemudian disajikan melalui *dashboard* interaktif guna memudahkan pengguna dalam melakukan eksplorasi data dan interpretasi hasil analisis.

4.3.1 Perancangan Arsitektur Sistem

Arsitektur sistem yang dirancang dalam penelitian ini mengadopsi pendekatan terpusat (*centralized architecture*) yang mengintegrasikan proses analisis sentimen, *topic modeling*, dan visualisasi data ke dalam sebuah *Web Dashboard* berbasis *Streamlit*. Sistem dibangun menggunakan bahasa pemrograman Python dengan memanfaatkan berbagai pustaka pendukung seperti Pandas, *Scikit-Learn,* Sastrawi, dan Plotly. Arsitektur ini dirancang untuk memisahkan proses pelatihan model dengan proses penggunaan sistem sehingga pengguna dapat mengakses hasil analisis tanpa perlu melakukan pelatihan model secara berulang.

Pada tahap pengembangan model, data cuitan yang diperoleh dari platform X terlebih dahulu melalui proses *filtering*, pelabelan, dan *preprocessing*. Tahapan *preprocessing* meliputi case folding, cleansing, stopword removal, dan stemming untuk menghasilkan data teks yang lebih bersih dan terstruktur. Selanjutnya, data ditransformasikan ke dalam bentuk representasi numerik menggunakan metode TF-IDF. Hasil transformasi tersebut digunakan sebagai masukan bagi algoritma *Support Vector Machine* (SVM) untuk membangun model klasifikasi sentimen.

Setelah model klasifikasi berhasil dibangun dan dievaluasi, dilakukan analisis tambahan menggunakan *topic modeling* untuk mengidentifikasi topik-topik dominan yang muncul dalam percakapan masyarakat terkait fenomena takut menikah. Model SVM, objek TF-IDF, serta hasil analisis yang telah diperoleh

kemudian disimpan dan diintegrasikan ke dalam *Web Dashboard* berbasis Streamlit.

Pada tahap implementasi, *Web Dashboard* berfungsi sebagai media interaksi antara pengguna dan sistem. *Dashboard* menyajikan berbagai visualisasi hasil analisis sentimen, hasil evaluasi model, serta informasi topik dominan yang diperoleh dari *topic modeling.* Selain itu, sistem juga menyediakan fitur simulator yang memungkinkan pengguna memasukkan teks baru untuk diprediksi sentimennya secara *real-time* menggunakan model SVM yang telah dilatih sebelumnya.

4.3.2 Perancangan Alur Sistem

Alur kerja sistem dirancang agar pengguna dapat melakukan eksplorasi data dan pengujian sentimen secara interaktif melalui *Web Dashboard.* Proses dimulai ketika pengguna mengakses aplikasi *dashboard* yang telah dijalankan pada peramban web. Selanjutnya, pengguna dapat memilih menu yang tersedia sesuai kebutuhan analisis.

1. Akses Web Dasboard

   Proses dimulai ketika pengguna membuka halaman utama *Web Dashboard* melalui peramban. Sistem kemudian memuat seluruh komponen visualisasi dan model yang digunakan dalam proses analisis.
2. Pemilihan Menu

   Pengguna dapat memilih menu yang tersedia pada *sidebar*, yaitu menu Analisis Sentimen atau menu Simulator Prediksi Sentimen.
3. Menampilkan Hasil Analisis

   Jika pengguna memilih menu Analisis Sentimen, sistem akan menampilkan berbagai visualisasi hasil analisis seperti distribusi sentimen, *confusion matrix,* koefisien kata pada model SVM, distribusi panjang teks, serta hasil *topic modeling.*
4. Input Teks Baru

Jika pengguna memilih menu Simulator Prediksi Sentimen, pengguna dapat memasukkan teks atau opini baru ke dalam kolom input yang tersedia.

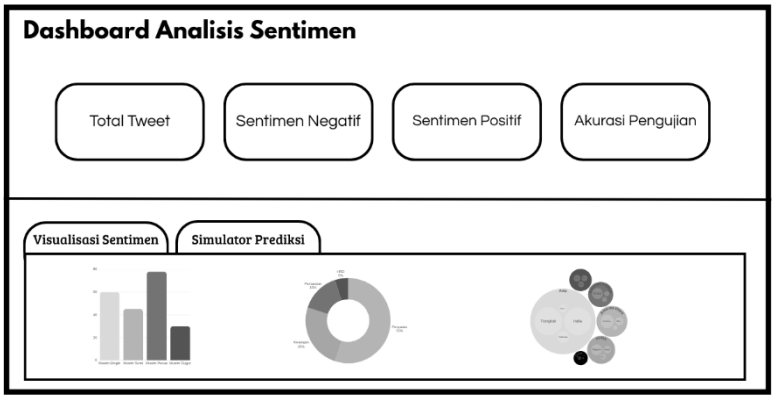
5. *Preprocessing* Otomatis
   Teks yang dimasukkan pengguna akan diproses secara otomatis melalui tahapan *preprocessing* yang meliputi *case folding, cleansing, stopword removal*, dan *stemming.*
6. Transformaasi TF-IDF dan Prediksi SVM
   Hasil *preprocessing* kemudian ditransformasikan menggunakan TF-IDF dan diklasifikasikan menggunakan model *Support Vector Machine* (SVM) yang telah dilatih sebelumnya.
7. Menampilkan Hasil Prediksi
   Sistem menampilkan hasil prediksi sentimen secara langsung kepada pengguna dalam bentuk label sentimen.

4.3.3 Perancangan Antarmuka

Perancangan antarmuka dilakukan untuk memberikan gambaran mengenai tampilan *Web Dashboard* yang digunakan sebagai media visualisasi hasil analisis sentimen dan pengujian sentimen secara *real-time*. Antarmuka dirancang sederhana, informatif, dan mudah digunakan sehingga pengguna dapat mengakses seluruh fitur sistem dengan lebih efektif. *Dashboard* dibangun menggunakan *framework Streamlit* dan terdiri atas halaman analisis sentimen serta halaman simulator prediksi sentimen.

1. Halaman Analisis Sentimen dan Topik
   Halaman Analisis Sentimen dan Topik merupakan halaman utama yang pertama kali ditampilkan ketika pengguna mengakses *Web Dashboard*. Pada halaman ini, sistem menyajikan ringkasan informasi berupa jumlah dataset, jumlah sentimen negatif, jumlah sentimen positif, serta nilai akurasi model klasifikasi. Selain itu, tersedia panel kontrol yang menampilkan informasi spesifikasi sistem yang digunakan dalam penelitian.

Halaman ini juga menampilkan berbagai visualisasi hasil analisis, seperti rasio distribusi sentimen menggunakan *Donut Chart, confusion matrix* untuk mengevaluasi performa model, distribusi panjang karakter dokumen menggunakan Violin Plot, serta hasil *topic modeling* berupa grafik prevalensi topik dan peta jarak antar topik. Visualisasi tersebut membantu pengguna memahami hasil analisis sentimen dan topik secara lebih mudah dan interaktif. Rancangan antarmuka halaman analisis sentimen dan topik dapat dilihat pada Gambar 4.4.

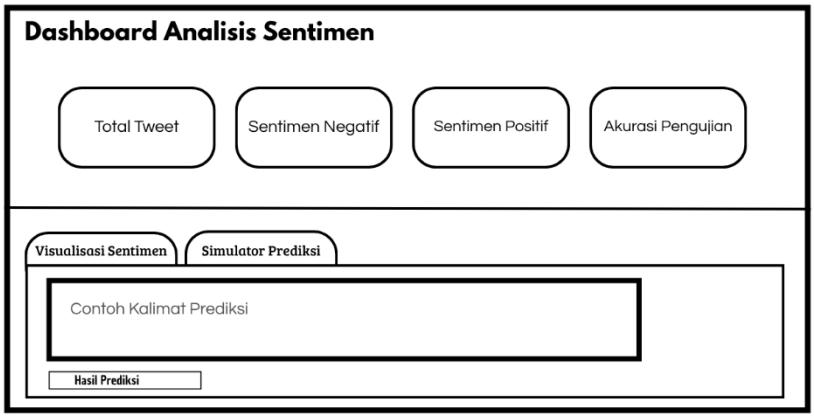


Gambar 4. 4 Antarmuka Halaman Analisis Sentimen

2. Halaman Simulator Sentimen Real-Time

   Halaman Simulator Analisis Sentimen *Real-Time* digunakan untuk melakukan pengujian sentimen terhadap teks baru yang dimasukkan oleh pengguna. Pada halaman ini tersedia kolom input teks yang dapat digunakan untuk memasukkan kalimat, opini, atau komentar terkait fenomena takut menikah. Setelah pengguna menekan tombol prediksi, sistem akan melakukan *preprocessing*, transformasi TF-IDF, dan klasifikasi menggunakan model *Support Vector Machine* (SVM) yang telah dibangun sebelumnya.

Hasil prediksi sentimen kemudian ditampilkan secara langsung pada halaman yang sama sehingga pengguna dapat mengetahui kecenderungan sentimen dari teks yang dimasukkan. Fitur ini memungkinkan pengguna melakukan pengujian sentimen secara cepat tanpa perlu menjalankan proses pelatihan model kembali. Rancangan antarmuka halaman simulator dapat dilihat pada Gambar 4.5.



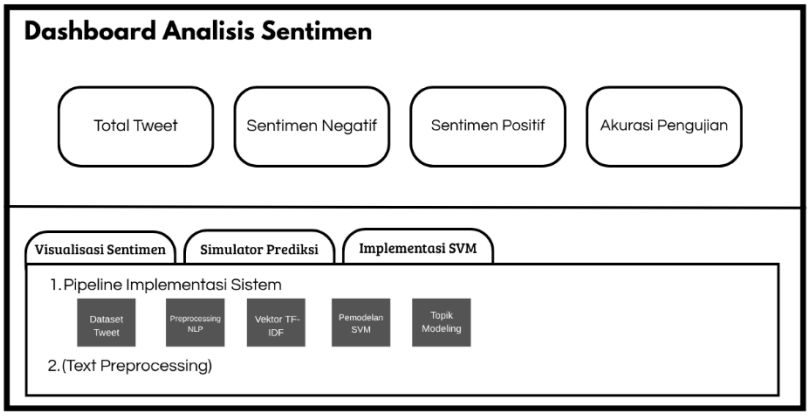
Gambar 4. 5 Antarmuka Halaman Simulator Sentimen

3. Halaman Implementasi Support Vector Machine (SVM)

   Halaman Implementasi Support Vector Machine (SVM) merupakan fitur tambahan yang dikembangkan untuk memberikan visualisasi mengenai proses klasifikasi sentimen yang dilakukan oleh sistem. Halaman ini dibuat sebagai bentuk implementasi model sehingga pengguna tidak hanya memperoleh hasil klasifikasi, tetapi juga dapat memahami tahapan yang dilakukan mulai dari data masukan hingga menghasilkan prediksi sentimen.

   Berdasarkan hasil implementasi, halaman ini berhasil menampilkan alur pemrosesan data yang terdiri atas proses preprocessing, ekstraksi fitur TF-IDF, pembentukan representasi vektor numerik, serta proses klasifikasi menggunakan model SVM. Selain itu, sistem juga menampilkan contoh tahapan preprocessing, simulasi pembobotan TF-IDF, serta ilustrasi fungsi keputusan (decision function) pada SVM untuk memberikan pemahaman mengenai mekanisme kerja model dalam menentukan kelas sentimen.

Penambahan halaman ini dilakukan sebagai upaya untuk meningkatkan transparansi proses klasifikasi sehingga pengguna dapat memahami bahwa hasil prediksi yang ditampilkan berasal dari tahapan pemrosesan yang dilakukan oleh sistem, bukan hanya hasil akhir klasifikasi. Tampilan halaman Implementasi SVM dapat dilihat pada Gambar 4.6.



Gambar 4. 6 Antarmuka Implementasi *Support Vector Machine*

4.4 Persiapan Data dan Eksperimen Komputasi

4.4.1 Sumber dan Pengumpulan Dataset

Data mentah yang digunakan sebagai bahan dasar utama eksperimen dalam penelitian ini bersumber dari opini publik pada platform media sosial X (dahulu Twitter) berbahasa Indonesia. Pengumpulan data berfokus pada cuitan pengguna digital yang membahas fenomena ketakutan atau penundaan pernikahan. Data riil yang berhasil dikumpulkan melalui bantuan platform SocialX berjumlah kurang lebih 3.160 baris cuitan mentah. Rentang waktu pengambilan data dibatasi secara ketat mulai dari 01 Januari 2020 hingga 01 April 2026 untuk memperoleh sebaran opini yang aktual dan representatif. Korpus data ini dipilih karena memiliki volume sebaran kata kasual yang sangat tinggi di internet, di mana batasan tata bahasa formal sering kali diabaikan oleh pengguna digital.

Proses penarikan data pada situs SocialX dilakukan secara otomatis menggunakan sepuluh kombinasi kata kunci kustom yang relevan. Kata kunci tersebut meliputi frasa "takut menikah", "takut nikah", "trauma menikah", "alasan

tidak mau menikah", "belum siap nikah", "biaya nikah mahal", "gak mau nikah", "gamau menikah", "takut cerai", dan "gk siap menikah". Penggunaan variasi kata kunci yang luas ini bertujuan agar data yang diperoleh menjadi lebih beragam dan tidak hanya berfokus pada satu sudut pandang saja. Hasil dari pengumpulan ini menghasilkan atribut informatif seperti identitas unik cuitan (*tweet ID*), waktu pengunggahan, dan konten teks utama. Seluruh data mentah tersebut kemudian dipetakan ke dalam format dokumen induk .csv untuk dianalisis lebih lanjut pada tahap *preprocessing*.

4.4.2 *Preprocessing Data*

Tahap transformasi data tekstual ke dalam bentuk vektor numerik mengharuskan seluruh dataset melalui serangkaian pipa pembersihan data (*preprocessing pipeline*) terlebih dahulu. Mengandalkan bahasa pemrograman Python, pipa pemrosesan ini diintegrasikan secara sistematis dengan pustaka *pandas*, *Sastrawi*, serta modul ekspresi reguler (re). Adapun rangkaian tahapan operasional yang dieksekusi secara kronologis dalam penelitian ini meliputi:

1. *Case Folding*

   Proses ini memanfaatkan fungsi .str.lower() dari pustaka *pandas* untuk mengubah seluruh karakter huruf di dalam dataset menjadi huruf kecil secara seragam. Langkah ini dilakukan guna menghindari pembengkakan dimensi fitur (kosakata) yang disebabkan oleh perbedaan penulisan huruf kapital di awal kata atau kalimat.
2. *Cleansing*

   Tahap eliminasi *noise* ini mengaplikasikan fungsi re.sub() dari pustaka ekspresi reguler (re) dengan menyusun pola *regex* kustom. Fungsi tersebut secara otomatis menyaring dan menghapus elemen non-alfabet seperti angka, simbol tanda baca, emotikon, spasi berlebih, tautan situs (*hyperlink*), serta format khas platform X yang meliputi sebutan akun pengguna (*username* @) dan tanda pagar (*hashtag* #).
3. Normalisasi

Langkah ini bertujuan untuk memperbaiki kata-kata tidak baku, istilah slang, maupun singkatan khas internet yang tersebar di media sosial ke dalam bentuk baku yang sesuai dengan pedoman bahasa. Proses konversi dilakukan lewat pencocokan kamus kustom berbasis pasangan *key-value*, seperti menyelaraskan kata "karna" menjadi "karena" atau kata "yg" menjadi "yang" agar persebaran Fitur menjadi lebih padat dan konsisten.

4. Tokenisasi

   Fungsi ini bertugas memotong struktur kalimat opini yang panjang menjadi kumpulan token kata tunggal yang terisolasi. Pemecahan ini diperlukan agar setiap kata dapat diidentifikasi secara mandiri oleh fungsi-fungsi pemrosesan berikutnya.

5. Stopword Removal

   Tahap ini berfokus untuk membuang kata-kata fungsional umum yang sering muncul namun tidak membawa bobot informasi atau sentimen yang berarti (misalnya kata "yang", "di", "dan", atau "untuk"). Walaupun demikian, daftar kata yang dibuang telah dimodifikasi secara ketat agar tetap mempertahankan kata negasi pemicu (seperti "tidak", "gak", "bukan") karena kata-kata tersebut sangat krusial bagi akurasi prediksi model SVM Linier dan logika pembalikan makna pada aplikasi *dashboard*.

6. Stemming

   Sebagai penutup *Preprocessing*, pustaka *Sastrawi* digunakan untuk mereduksi seluruh token kata berimbuhan menjadi bentuk akar dasarnya dengan cara menanggalkan awalan maupun akhiran kata. Melalui proses ini, variasi kata seperti "pernikahan" dan "menikah" akan dilebur menjadi satu kata dasar yang sama, yaitu "nikah", sehingga mempermudah model dalam mengenali inti pesan.

4.4.3 Ekstraksi Fitur TF-IDF

Proses transformasi data pada tahap ekstraksi fitur ini diatur menggunakan beberapa ketetapan teknis yang saling berkesinambungan. Dokumen teks bersih yang telah melewati seluruh rangkaian pipa *Preprocessing* akan dimasukkan ke

dalam modul TfidfVectorizer yang disediakan oleh pustaka *scikit-learn*. Pada tahapan ini, konfigurasi parameter *N-Gram* diatur secara spesifik pada rentang nilai (1, 2) guna mengekstrak kombinasi fitur *Unigram* atau kata tunggal dan fitur *Bigram* berupa frasa dua kata berurutan secara bersamaan.

Selanjutnya, nilai numerik kuantitatif di dalam matriks fitur didapatkan secara otomatis melalui formula kalkulasi pembobotan statistik TF-IDF. Nilai tersebut dihitung berdasarkan hasil perkalian antara skor frekuensi kemunculan kata kunci di dalam suatu dokumen skala lokal (*Term Frequency*) dengan nilai logaritma terbalik dari proporsi penyebaran kata tersebut di seluruh korpus dokumen skala global (*Inverse Document Frequency*).

Konseptualisasi dari penerapan kombinasi rentang *unigram-bigram* ini memegang peranan yang sangat vital terhadap performa klasifikasi. Skema tersebut dirancang untuk memastikan agar algoritma SVM Linier memiliki kepekaan semantik yang tinggi dalam mengenali batas konteks bahasa internet. Melalui pendekatan kuantifikasi ini, model keputusan mampu membedakan makna antara sebuah kata sentimen tunggal dengan untaian kalimat, seperti membedakan makna literal dari kata "takut" dengan frasa negasi "tidak takut" secara presisi sebelum masuk ke lapis pemodelan.

4.5 Pemodelan Klasifikasi SVM

4.5.1 Pembagian Data Latih dan Data Uji

Matriks fitur numerik dan array label biner pada penelitian ini dibagi secara proporsional menggunakan fungsi train_test_split dengan komposisi 80% data latih (*training set*) dan 20% data uji (*testing set).* Berdasarkan proses pembagian tersebut, diperoleh 1.456 data cuitan sebagai data latih dan 364 data cuitan sebagai data uji. Data latih digunakan oleh algoritma Linear SVM untuk mempelajari pola distribusi bobot pada matriks fitur, sedangkan data uji dipisahkan secara khusus sebagai media evaluasi guna mengukur kemampuan generalisasi model terhadap data baru yang belum pernah diproses sebelumnya (*unseen data*).

4.5.2 Alur Pemodelan Berbasis SVM Linier

Model klasifikasi sentimen pada penelitian ini dibangun menggunakan algoritma Support Vector Machine (SVM) dengan kernel linear. Pemilihan model ini dilakukan karena data teks hasil ekstraksi fitur TF-IDF memiliki jumlah fitur yang tinggi sehingga sesuai untuk diproses menggunakan pendekatan linear. Proses pemodelan diawali dengan pembagian dataset menjadi data latih dan data uji dengan rasio 80:20. Data latih kemudian ditransformasikan ke dalam bentuk vektor numerik menggunakan metode TF-IDF yang menghasilkan representasi fitur berbasis unigram dan bigram. Hasil transformasi tersebut digunakan sebagai masukan pada proses pelatihan model SVM.

Selama proses pelatihan, model mempelajari hubungan antara fitur teks dan label sentimen untuk membentuk pola klasifikasi. Setelah proses pelatihan selesai, model yang dihasilkan digunakan untuk melakukan prediksi terhadap data uji yang sebelumnya tidak terlibat dalam proses pelatihan.

Hasil prediksi kemudian dibandingkan dengan label aktual untuk mengukur kinerja model menggunakan beberapa metrik evaluasi, yaitu akurasi, *Precision*, *Recall*, dan F1-score. Model yang telah dievaluasi selanjutnya disimpan dalam bentuk berkas biner dan diintegrasikan ke dalam aplikasi web dashboard sebagai mesin klasifikasi sentimen pada fitur analisis sentimen dan simulator prediksi real-time.

BAB V
IMPLEMENTASI DAN PEMBAHASAN SISTEM

5.1 Implementasi Data

5.1.1 Pengumpulan Data

Tahap pengumpulan data dilakukan untuk memperoleh data opini masyarakat terkait fenomena takut menikah yang akan digunakan dalam proses analisis sentimen. Data penelitian berasal dari platform X karena platform tersebut menjadi salah satu media yang banyak digunakan masyarakat untuk menyampaikan pendapat, pengalaman, maupun pandangan terhadap berbagai isu sosial.

Pengumpulan data berfokus pada cuitan pengguna digital yang membahas fenomena ketakutan atau penundaan pernikahan. Data riil yang berhasil dikumpulkan melalui bantuan platform SocialX berjumlah kurang lebih 3160 baris cuitan mentah. Rentang waktu pengambilan data dibatasi secara ketat mulai dari Januari 2020 hingga 1 April 2026 untuk memperoleh sebaran opini yang aktual dan representatif. Korpus data ini dipilih karena memiliki volume sebaran kata kasual yang sangat tinggi di internet, di mana batasan tata bahasa formal sering kali diabaikan oleh pengguna digital.

Proses penarikan data pada situs SocialX dilakukan secara otomatis menggunakan sepuluh kombinasi kata kunci kustom yang relevan. Kata kunci tersebut meliputi frasa "takut menikah", "takut nikah", "trauma menikah", "alasan tidak mau menikah", "belum siap nikah", "biaya nikah mahal", "gak mau nikah", "gamau menikah", "takut cerai", dan "gk siap menikah". Penggunaan variasi kata kunci yang luas ini bertujuan agar data yang diperoleh menjadi lebih beragam dan tidak hanya berfokus pada satu sudut pandang saja. Hasil dari pengumpulan ini menghasilkan atribut informatif seperti identitas unik cuitan (*tweet ID*), waktu pengunggahan, dan konten teks utama.

Selanjutnya, dataset dimuat ke dalam pemrograman Python menggunakan pustaka Pandas untuk memudahkan proses pengolahan dan analisis data. Contoh hasil pemuatan data dapat dilihat pada Gambar 5.1.



	date	lang	urls	media	source	user_id	hashtags	is_quote	mentions	tweet_id	...	quoted_tweet_id	quoted_username	user_created_at	user_description
0	2026-04-21T16:16:56	in	[]	[]	Twitter for Android	1527913902	[]	True	[]	2046624235121185116	...	2.046478e+18	geraldyoo_	Tue Jun 18 14:32:52 +0000 2013	I was born in February,\nthat's why I love too...
1	2026-04-21T14:07:32	in	[]	[]	Twitter for Android	1245421311435763712	[]	False	[{"name":"🐷 SUROBOYOFESS 🐷","user_id":"1152437...	2046591667625721882	...	NaN	NaN	Wed Apr 01 18:43:00 +0000 2020	lagi fokus cari kerja, ngerjain freelance dan ...
2	2026-04-19T12:27:56	in	[]	[]	Twitter for iPhone	1673292316319285248	[]	False	[{"name":"Deoxide ™","user_id":"2005864558704 1...	2046841826540827135	...	NaN	NaN	Mon Jun 26 11:29:31 +0000 2023	NaN
3	2026-04-19T02:10:01	in	[]	[]	Twitter for Android	1524088068919787040	[]	False	[{"name":"Tanyarifes","user_id":"1371650588","...	2045686323173114238	...	NaN	NaN	Tue May 10 17:57:07 +0000 2022	Fullsun 🌻 🌻
4	2026-04-19T18:21:13	in	[]	[]	Twitter for iPhone	734800004	[]	False	[{"name":"Zan","user_id":"1097211802717306880"...	2045930733202792855	...	NaN	NaN	Fri Aug 03 12:34:06 +0000 2012	Gausah ngurusin aku, aku udah kurus🙏 || DM for...

Gambar 5. 1 Preview Hasil Crawling Data Sentimen

Data yang telah berhasil dimuat selanjutnya digunakan sebagai dataset penelitian dan akan melalui serangkaian tahapan *preprocessing.*

5.1.2 Filtering dan Pelabelan Data

Tahap *filtering* dilakukan untuk memastikan bahwa data yang digunakan dalam penelitian memiliki kualitas yang baik dan sesuai dengan kebutuhan analisis. Proses ini meliputi penyaringan bahasa, penghapusan data kosong, serta penghapusan data duplikat. Tahap *filtering* bertujuan untuk mengurangi *noise* dan mencegah adanya data yang dapat memengaruhi hasil pemodelan.

Pada penelitian ini, hanya data berbahasa Indonesia yang digunakan dalam proses analisis sentimen. Oleh karena itu, dilakukan penyaringan berdasarkan atribut bahasa pada dataset. Data dengan bahasa selain Bahasa Indonesia tidak disertakan dalam proses analisis. Kode *filtering* bahasa dapat dilihat pada Gambar 5.2.

```
df = df[df['lang'] == 'in']
```

Gambar 5. 2 Kode Filtering Data Berbahasa Indonesia

Setelah proses *filtering* bahasa selesai dilakukan, tahap berikutnya adalah pemilihan atribut yang akan digunakan dalam penelitian. Pada penelitian ini, analisis difokuskan pada isi cuitan sehingga atribut yang digunakan adalah kolom *full_text*. Kolom tersebut berisi teks lengkap dari setiap cuitan yang akan diproses

pada tahapan analisis sentimen. Pemeriksaan terhadap data pada kolom *full_text* untuk mengidentifikasi data yang kosong (*missing values*) maupun data yang muncul lebih dari satu kali (*duplicate data*). Data kosong dihapus karena tidak mengandung informasi yang dapat dianalisis, sedangkan data duplikat dihapus untuk menghindari pengulangan informasi yang dapat memengaruhi hasil pemodelan. Kode pemilihan atribut serta penghapusan data kosong dan duplikat dapat dilihat pada Gambar 5.3.

```
df = df.dropna(subset=['full_text'])
df = df.drop_duplicates(subset=['full_text'])
```

Gambar 5. 3 Kode Penghapusan Data Kosong dan Duplikat

Setelah proses *filtering* selesai dilakukan, tahap berikutnya adalah pelabelan data. Pelabelan bertujuan untuk memberikan kelas sentimen pada setiap cuitan sehingga dapat digunakan sebagai data target dalam proses pelatihan model klasifikasi. Pada penelitian ini, pelabelan dilakukan secara otomatis menggunakan pendekatan kamus kata kunci (*lexicon-based labeling*).

Proses pelabelan dilakukan dengan mencocokkan kata-kata yang terdapat pada setiap cuitan dengan daftar kata yang telah dikelompokkan ke dalam kategori sentimen positif dan negatif. Kode pelabelan data dapat dilihat pada Gambar 5.4.

```
negative_keywords = [
"takut nikah", "takut menikah", "takut meni", "jadi
takut", "overthinking", "trauma","gamau nikah", "gak mau
nikah", "ga mau nikah", "tidak mau nikah", "males
nikah","belum siap", "gajadi nikah", "ga siap", "gak
siap", "tidak siap", "mental belum","takut cerai", "takut
gagal", "salah pilih", "komitmen", "mahal", "biaya",
"kdrt", "selingkuh"
]
positive_keywords = [
"pengen nikah", "pengen menikah", "pengen meni", "ingin
menikah", "mau nikah", "mau meni","ken nikah", "ken meni",
"siap nikah", "siap menikah", "siap meni", "udah siap",
"sudah siap","indah", "bahagia", "senang", "ibadah",
"cepat ketemu jodoh", "menikah muda", "nikah
muda","goals",]
```

Gambar 5. 4 Kode Daftar Kata Kunci untuk Pelabelan Sentimen

Perhitungan jumlah data positif dan negatif dilakukan guna mengetahui sebaran data pada masing-masing kelas sentimen. Distribusi hasil pelabelan tersebut menunjukkan komposisi data yang akan digunakan pada proses pelatihan dan pengujian model *Support Vector Machine* (SVM).

5.1.3 *Preprocessing* Data

Tahap *preprocessing* dilakukan untuk membersihkan dan menyiapkan data teks sebelum dilakukan ekstraksi fitur menggunakan TF-IDF dan proses klasifikasi sentimen. Data hasil *crawling* masih mengandung berbagai elemen yang tidak relevan seperti URL, simbol, tanda baca, serta variasi penulisan kata yang dapat memengaruhi hasil analisis. Oleh karena itu, dilakukan beberapa tahapan *preprocessing* untuk menghasilkan data yang lebih bersih dan terstruktur.

1. *Case Folding*

   Tahap *case folding* dilakukan paling awal untuk mengubah semua karakter huruf di dalam cuitan menjadi huruf kecil (*lowercase*) secara rata memakai fungsi .lower(). Proses ini bertujuan agar kata yang ditulis dengan huruf kapital tetap dihitung sebagai kata yang sama dengan huruf kecil biasa. Kode perintah untuk tahap *case folding* ini digabungkan di dalam fungsi pembersih teks utama yang dapat dilihat pada Gambar 5.5.

```
# Ubah ke huruf kecil semua
text = text.lower()
```

Gambar 5. 5 Kode Proses Case Folding

2. *Cleansing*

   Tahap ini bertujuan untuk membersihkan teks cuitan dari berbagai elemen gangguan, baik berupa atribut khusus bawaan media sosial X maupun karakter non-alfabet. Menggunakan bantuan pustaka *Regular Expression* (Regex), sistem secara otomatis akan menghapus sebutan nama pengguna (*mention* @), tanda pagar (*hashtag* #), tautan alamat situs web (*URL Link*), deretan angka, serta seluruh simbol tanda baca yang tersisa. Langkah ini penting dilakukan

agar potongan kata yang berdiri sendiri menjadi murni dan tidak terikat oleh simbol apa pun.

```
text = re.sub(r'@\w+', '', text)
text = re.sub(r'http\S+|www\S+', '', text)
text = re.sub(r'[^a-zA-Z\s]', ' ', text)
text = re.sub(r'\s+', ' ', text).strip()
```

Gambar 5. 6 Kode Proses Cleaning Teks

3. Tokenisasi

Tahap tokenisasi bertugas untuk memotong satu kalimat cuitan utuh yang sudah bersih menjadi kumpulan potongan kata-kata tunggal yang terpisah. Pemisahan kata ini diperlukan agar sistem dapat memeriksa dan mengolah setiap unit kata secara mandiri pada tahap selanjutnya.

```
tokens = text.split()
 tokens_clean = [word for word in tokens if word
not in all_stopwords]
```

Gambar 5. 7 Kode Penghapusan Stopword Pada Data Teks

4. Stopword Removal

Tahap *stopword removal* dilakukan untuk menghapus kata-kata umum yang sering muncul dalam teks tetapi tidak memiliki kontribusi yang signifikan terhadap proses klasifikasi sentimen. Pada penelitian ini, daftar *stopword* diperoleh dari gabungan kamus *stopword* Bahasa Indonesia yang tersedia pada pustaka NLTK dan Sastrawi. Penggabungan kedua kamus tersebut dilakukan untuk memperluas cakupan kata yang dapat dihapus selama proses *Preprocessing*.

```
stop_nltk = set(stopwords.words('indonesian'))
stop_sastrawi= set(StopWordRemoverFactory().
get_stop_words))
all_stopwords = stop_nltk.union(stop_sastrawi)
```

Gambar 5. 8 Kode Penggabungan Stopword NLTK dan Sastrawi

Namun, tidak seluruh kata dalam daftar *stopword* dihapus secara langsung. Beberapa kata negasi seperti *tidak*, *bukan*, *gak*, *nggak*, *ngga*, *gk*, *ndak*, dan *ora*

dipertahankan karena memiliki peran penting dalam menentukan polaritas sentimen. Penghapusan kata-kata tersebut dapat menyebabkan perubahan makna pada kalimat dan berpotensi menghasilkan kesalahan klasifikasi sentimen. Oleh karena itu, dilakukan proses penyelamatan kata negasi dengan mengeluarkannya dari daftar *stopword.*

```
kata_penyelamat = {
'tidak', 'bukan', 'takut', 'nikah', 'menikah',
'trauma', 'siap', 'gagal', 'yakin','gak', 'nggak',
'ngga', 'gk', 'ndak', 'ora' # Kita selamatkan semua
variasi kata 'tidak'}
all_stopwords = all_stopwords - kata_penyelamat
```

Gambar 5. 9 Kode Penyelamatan Kata Negasi dari Daftar Stopword

Setelah daftar *stopword* final diperoleh, sistem melakukan proses penyaringan terhadap setiap token pada dokumen dengan menghapus kata-kata yang terdapat dalam daftar *stopword* tersebut.

```
def hapus_stopwords(text):
    tokens = text.split()
    tokens_clean = [
        word for word in tokens
        if word not in all_stopwords
    ]
    return " ".join(tokens_clean)
df_clean['text_no_stopwords'] = (
    df_clean['text_clean']
    .apply(hapus_stopwords)
)
```

Gambar 5. 10Kode Penyaringan Token Menggunakan Daftar Stopword

5. Normalisasi Teks

Pada penelitian ini, normalisasi teks dilakukan dengan pendekatan eliminasi kata gaul dan singkatan yang umum ditemukan pada media sosial. Berbeda dengan normalisasi konvensional yang mengubah kata tidak baku menjadi bentuk baku, penelitian ini menghapus kata-kata gaul yang dianggap tidak memberikan kontribusi terhadap proses klasifikasi sentimen. Pendekatan ini dipilih karena sebagian besar kata gaul yang ditemukan dalam dataset berfungsi

sebagai kata penghubung, kata penegas, atau kata percakapan sehari-hari yang tidak memengaruhi polaritas sentimen.

Beberapa kata yang termasuk dalam kategori tersebut antara lain yg, gue, gw, tp, bgt, udh, dah, aja, sih, dan berbagai bentuk singkatan lainnya yang sering digunakan pada platform X. Kata-kata tersebut ditambahkan ke dalam daftar *stopword* sehingga akan dihapus pada tahap *stopword removal.* Dengan demikian, teks yang dihasilkan menjadi lebih ringkas, konsisten, dan berfokus pada kata-kata yang memiliki informasi penting dalam proses klasifikasi sentimen. Kode penambahan kata gaul ke dalam daftar *stopword* dapat dilihat pada Gambar 5.11.

```
# Daftar kata gaul Twitter yang MEMANG HARUS dibuang
kata_gaul = {'yg', 'gue', 'gua', 'gw', 'tp', 'tapi', 'jd', 'jadi', 'bgt',
'banget',
 'udah', 'udh', 'dah', 'kalo', 'kalau', 'nya', 'aja', 'sih', 'tuh', 'nih', 'loh',
'kok', 'kan', 'emang', 'krn', 'karna', 'karena', 'org', 'orang', 'dgn', 'dg',
'sama', 'blm', 'belum', 'jgn', 'juga', 'pas', 'deh', 'ke', 'hehehe'}
all_stopwords = all_stopwords.union(kata_gaul)
```

Gambar 5. 11 Kode Penambahan Kata Gaul dan Singkatan

6. Stemming

Sebagai penutup rangkaian *Preprocessing* teks, tahap *stemming* dilakukan untuk memotong kata-kata berimbuhan menjadi bentuk kata dasarnya. Proses pemotongan imbuhan ini dijalankan menggunakan pustaka Sastrawi yang dikembangkan khusus untuk Bahasa Indonesia. Lewat tahap ini, variasi kata seperti "pernikahan" atau "menikahi" otomatis akan dilebur menjadi satu token kata dasar yang sama, yaitu "nikah". Perintah kode program untuk tahap *stemming* ini ditunjukkan pada Gambar 5.12.

```
factory_stemmer = StemmerFactory()
stemmer = factory_stemmer.create_stemmer()
```

Gambar 5. 12 Kode Inisialisasi Stemmer Sastrawi

5.1.4 Ekstraksi Fitur

Setelah melalui tahap *preprocessing*, data teks selanjutnya dipersiapkan untuk proses pemodelan. Sebelum dilakukan ekstraksi fitur, dataset terlebih dahulu dibagi menjadi data latih (training data) dan data uji (testing data) menggunakan metode train-test split. Pembagian data dilakukan dengan rasio 80:20, di mana 80% data digunakan untuk melatih model dan 20% sisanya digunakan untuk menguji performa model.

Setelah proses pembagian data selesai dilakukan, tahap berikutnya adalah ekstraksi fitur menggunakan metode *Term Frequency–Inverse Document Frequency* (TF-IDF). Metode ini digunakan untuk mengubah data teks menjadi representasi numerik sehingga dapat diproses oleh algoritma *Support Vector Machine* (SVM). TF-IDF memberikan bobot pada setiap kata berdasarkan frekuensi kemunculannya dalam suatu dokumen dan tingkat keunikannya terhadap keseluruhan dokumen.

Pada penelitian ini, proses ekstraksi fitur dilakukan menggunakan kelas *TfidfVectorizer* dari pustaka *Scikit-Learn.* Selain menggunakan unigram (satu kata), proses ekstraksi juga mempertimbangkan bigram (dua kata berurutan) melalui parameter ngram_range=(1,2). Pendekatan ini bertujuan untuk menangkap konteks kata yang lebih baik dibandingkan hanya menggunakan kata tunggal. Selain itu, jumlah fitur yang digunakan dibatasi sebanyak 5.000 fitur untuk mengurangi kompleksitas data dan meningkatkan efisiensi proses klasifikasi. Kode implementasi TF-IDF dapat dilihat pada Gambar 5.13.

```
from sklearn.feature_extraction.text import TfidfVectorizer
tfidf = TfidfVectorizer(ngram_range=(1, 2), max_features=5000)
X_train_tfidf = tfidf.fit_transform(X_train)
X_test_tfidf = tfidf.transform(X_test)
```

Gambar 5. 13 Kode Ekstraksi Fitur Menggunakan TF-IDF

Hasil transformasi TF-IDF menghasilkan matriks fitur yang berisi bobot kata dari setiap dokumen. Matriks tersebut menjadi representasi numerik yang

digunakan sebagai masukan pada proses klasifikasi sentimen menggunakan algoritma *Support Vector Machine* (SVM).

Tabel 5. 1 Dimensi Matriks Hasil Transformasi TF-IDF

Dataset	Jumlah Dokumen	Jumlah Fitur
Data Latih	1.456	5.000
Data Uji	364	5.000

Berdasarkan hasil transformasi TF-IDF, diperoleh matriks fitur data latih berukuran 1.456 × 5.000 dan matriks fitur data uji berukuran 364 × 5.000. Jumlah fitur sebanyak 5.000 diperoleh dari parameter *max_features* yang digunakan pada proses ekstraksi fitur. Matriks tersebut selanjutnya digunakan sebagai masukan pada proses pelatihan dan pengujian model *Support Vector Machine* (SVM).

5.1.5 Implementasi Support Vector Machine

Setelah data berhasil ditransformasikan ke dalam bentuk vektor numerik menggunakan metode TF-IDF, tahap selanjutnya adalah proses klasifikasi sentimen menggunakan algoritma *Support Vector Machine* (SVM). Algoritma ini digunakan untuk membangun model yang mampu membedakan kelas sentimen berdasarkan pola yang diperoleh dari data latih.

Pada penelitian ini, proses pelatihan model dilakukan menggunakan algoritma SVM dengan kernel linear yang diimplementasikan melalui kelas SVC dari pustaka *Scikit-Learn*. Penggunaan kernel linear dipilih karena sesuai untuk data teks yang memiliki dimensi fitur tinggi hasil ekstraksi TF-IDF. Selain itu, parameter class_weight='balanced' digunakan untuk mengatasi ketidakseimbangan jumlah data pada masing-masing kelas sentimen sehingga model dapat memberikan perhatian yang lebih proporsional terhadap seluruh kelas. Kode implementasi pelatihan model SVM dapat dilihat pada Gambar 5.14.

```
model_svm     =     SVC(kernel='linear',
class_weight='balanced',
random_state=42)

model_svm.fit(X_train_tfidf, y_train)
```

Gambar 5. 14 Kode Model SVM

Setelah proses pelatihan selesai dilakukan, model digunakan untuk melakukan prediksi terhadap data uji yang sebelumnya tidak digunakan selama proses pelatihan. Proses prediksi bertujuan untuk mengetahui kemampuan model dalam mengklasifikasikan data baru ke dalam kelas sentimen yang sesuai. Kode proses prediksi dapat dilihat pada Gambar 5.15.

```
# Prediksi hasil untuk data latih dan data uji
y_train_pred = model_svm.predict(X_train_tfidf)
y_test_pred = model_svm.predict(X_test_tfidf)

# Menghitung nilai akurasi
acc_train = Accuracy_score(y_train, y_train_pred)
acc_test = Accuracy_score(y_test, y_test_pred)
```

Gambar 5. 15 Kode Prediksi dan Evaluasi Akurasi Model SVM

Hasil prediksi yang diperoleh kemudian dibandingkan dengan label aktual pada data uji. Perbandingan tersebut digunakan sebagai dasar dalam proses evaluasi model untuk mengukur tingkat akurasi dan performa klasifikasi yang dihasilkan oleh algoritma SVM.

5.1.6 *Topic Modeling*

Selain melakukan klasifikasi sentimen, penelitian ini juga menerapkan *topic modeling* sebagai analisis tambahan untuk mengidentifikasi topik-topik yang sering dibahas masyarakat terkait fenomena takut menikah. Analisis ini bertujuan untuk memberikan gambaran yang lebih mendalam mengenai isu atau faktor yang melatarbelakangi munculnya sentimen pada data cuitan yang telah dikumpulkan.

Sebelum membangun model *topic modeling*, terlebih dahulu dilakukan pengujian nilai *coherence score* untuk menentukan jumlah topik yang paling optimal. Pengujian dilakukan dengan mencoba beberapa jumlah topik yang

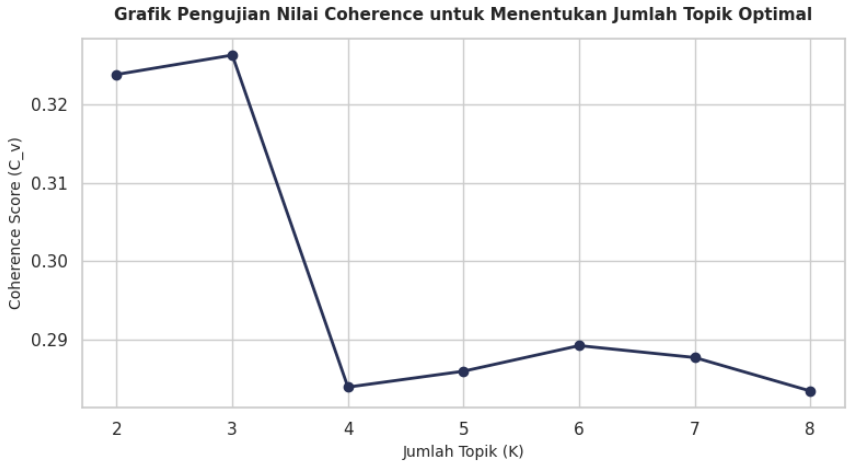
berbeda, kemudian membandingkan nilai *coherence score* yang dihasilkan oleh masing-masing model. Semakin tinggi nilai coherence score, maka semakin baik kualitas topik yang terbentuk. Kode pengujian *coherence score* dapat dilihat pada Gambar 5.16.

```
coherence_values = []
for num_topics in topic_nums:
    model = gensim.models.LdaModel(corpus=corpus,
                                   id2word=id2word,
                                   num_topics=num_topics,
                                   random_state=42,
                                   passes=5,
                                   alpha='auto')

        coherence_model   =   CoherenceModel(model=model,
texts=lda_tokens, dictionary=id2word, coherence='c_v')
    score = coherence_model.get_coherence()
    coherence_values.append(score)
```

Gambar 5. 16 Kode Pengujian *Coherence score*

Berdasarkan Gambar 5.17, nilai *coherence score* tertinggi diperoleh pada jumlah topik sebanyak 3 dengan nilai sekitar 0,326. Oleh karena itu, jumlah topik yang digunakan pada penelitian ini ditetapkan sebanyak 3 topik karena menghasilkan kualitas topik yang paling baik dibandingkan jumlah topik lainnya.



Gambar 5. 17 Grafik Nilai Coherence Score

Setelah jumlah topik optimal ditentukan, proses pemodelan dilakukan menggunakan algoritma *Latent Dirichlet Allocation* (LDA). Model LDA diterapkan pada data hasil *preprocessing* untuk mengelompokkan kata-kata yang sering muncul secara bersamaan ke dalam beberapa topik. Kode implementasi LDA dapat dilihat pada Gambar 5.18.

```
lda_model_final = gensim.models.LdaModel(corpus=corpus,
                                         id2word=id2word,
                                         num_topics=K_OPTIMAL,
                                         random_state=42,
                                         passes=25,
                                         alpha='auto')
```

Gambar 5. 18 Kode Algoritma LDA

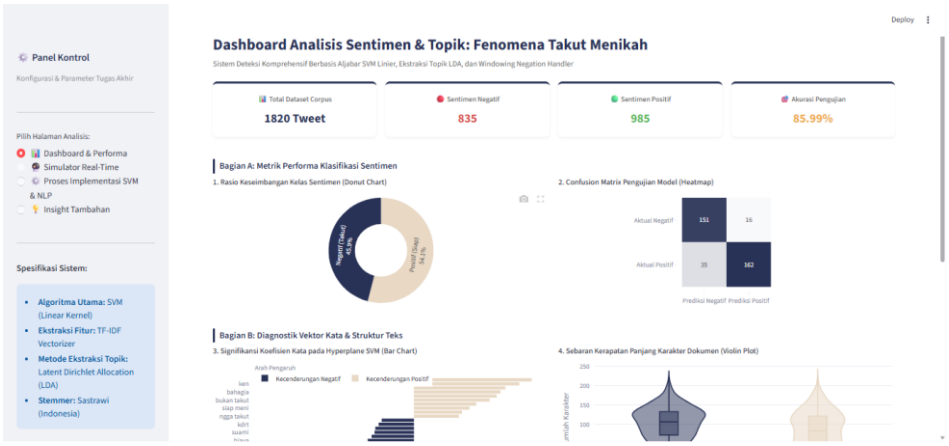
Berdasarkan implementasi yang telah dilakukan, model LDA berhasil dibangun menggunakan jumlah topik optimal sebanyak tiga topik. Model yang terbentuk selanjutnya digunakan untuk mengidentifikasi pola pembahasan dan topik-topik dominan yang muncul pada data cuitan terkait fenomena takut menikah.

5.1.7 Implementasi Sistem

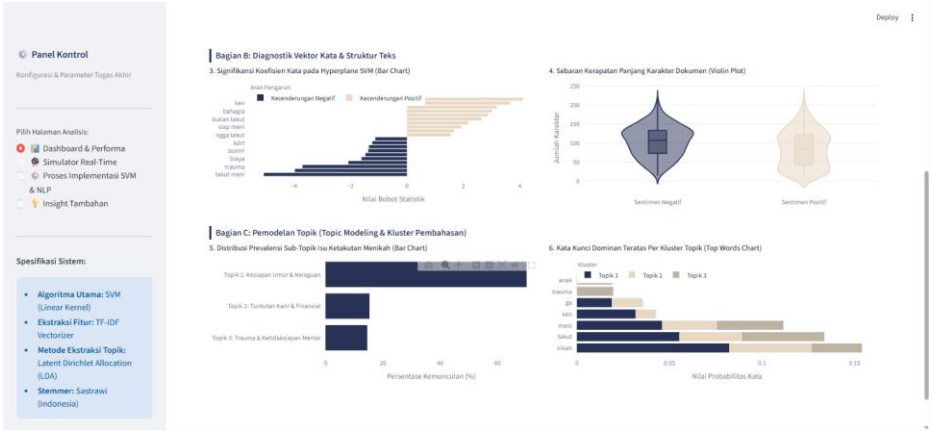
Implementasi sistem dilakukan dengan mengintegrasikan model klasifikasi sentimen *Support Vector Machine* (SVM), hasil *topic modeling*, serta antarmuka berbasis web ke dalam sebuah aplikasi *Web Dashboard* menggunakan *framework Streamlit. Dashboard* ini berfungsi sebagai media untuk menampilkan hasil analisis sentimen dan topik secara interaktif serta menyediakan fasilitas pengujian sentimen terhadap teks baru secara *real-time.*

1. Halaman Analisis Sentimen

   Halaman Analisis Sentimen dan Topik merupakan halaman utama yang pertama kali ditampilkan ketika aplikasi dijalankan. Pada halaman ini sistem menampilkan ringkasan informasi berupa jumlah dataset yang digunakan, jumlah sentimen negatif, jumlah sentimen positif, serta nilai akurasi model klasifikasi. Selain itu, sistem juga menyediakan menu navigasi untuk berpindah ke halaman Simulator Analisis *Real-Time*. Tampilan halaman analisis sentimen dan topik dapat dilihat pada Gambar 5.19 dan Gambar 5.20.



Gambar 5. 19 Halaman Analisis Sentimen dan Topik (Bagian Atas)

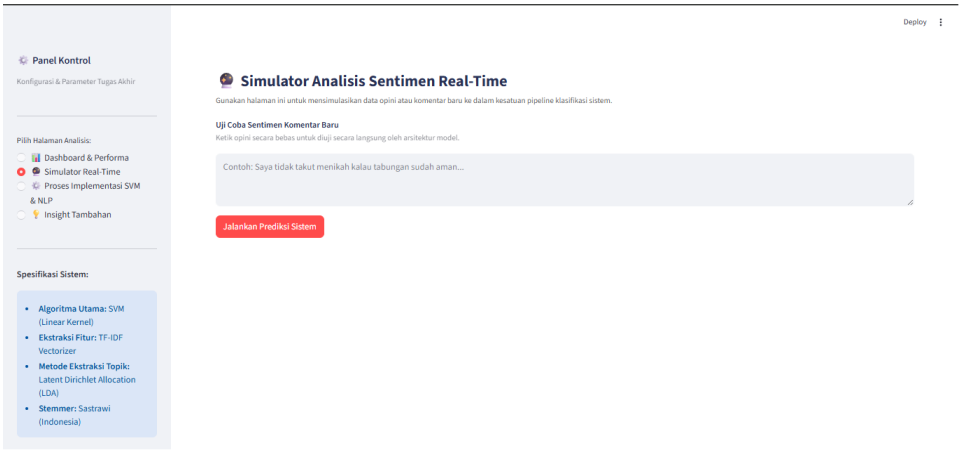


Gambar 5. 20 Halaman Analisis Sentimen dan Topik (Bagian Bawah)

Berdasarkan hasil implementasi, sistem berhasil memuat sebanyak 1.820 data cuitan yang terdiri atas 835 sentimen negatif dan 985 sentimen positif. Selain itu, model klasifikasi yang digunakan memperoleh nilai akurasi sebesar 90,03%. Pada halaman ini sistem juga menampilkan beberapa visualisasi hasil analisis sentimen dan *topic modeling*. Visualisasi tersebut meliputi Donut Chart distribusi sentimen, *Confusion Matrix* hasil pengujian model, Violin Plot distribusi panjang karakter dokumen, grafik prevalensi topik, serta Bubble Chart yang menunjukkan hubungan antar topik hasil pemodelan LDA. Visualisasi yang ditampilkan membantu pengguna dalam memahami karakteristik data dan hasil analisis secara lebih mudah.

2. Halaman Simulator Prediksi Sentimen

Implementasi model klasifikasi sentimen juga diterapkan pada halaman Simulator Prediksi Sentimen. Halaman ini digunakan untuk melakukan pengujian sentimen terhadap teks baru yang dimasukkan oleh pengguna. Pengguna dapat menuliskan kalimat atau opini pada kolom input yang tersedia, kemudian sistem akan melakukan proses *preprocessing*, transformasi TF-IDF, dan klasifikasi menggunakan model SVM yang telah dilatih sebelumnya. Tampilan halaman simulator dapat dilihat pada Gambar 5.21.



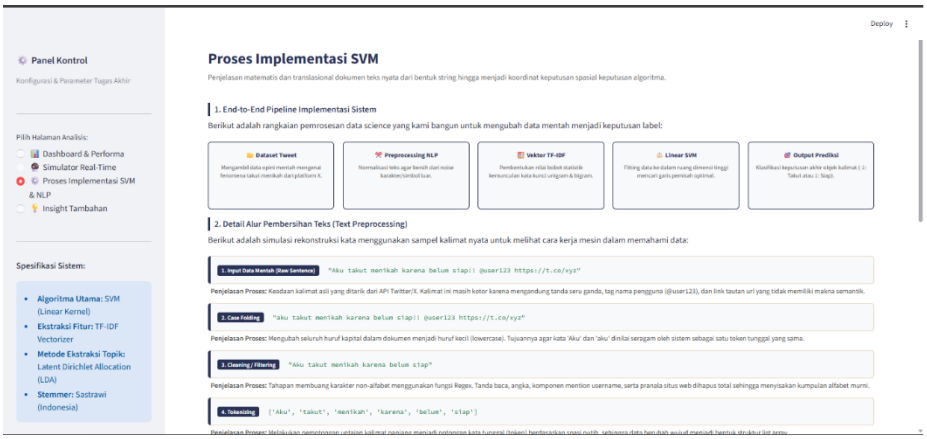
Gambar 5. 21 Halaman Simulator Analisis Sentimen

Berdasarkan hasil implementasi, sistem mampu melakukan prediksi sentimen secara *real-time* terhadap teks yang dimasukkan pengguna. Hasil prediksi kemudian ditampilkan secara langsung pada halaman yang sama sehingga pengguna dapat mengetahui kecenderungan sentimen dari suatu opini tanpa perlu melakukan proses pelatihan model kembali.

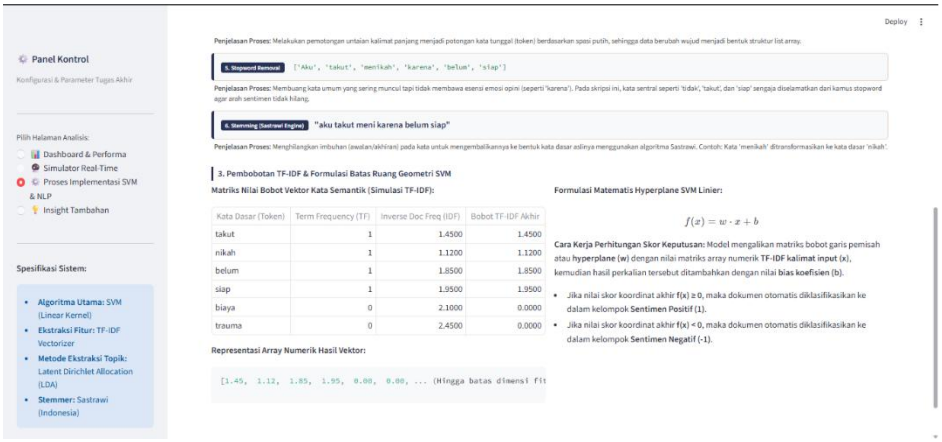
3. Halaman Implementasi Support Vector Machine (SVM)

Halaman Implementasi Support Vector Machine (SVM) dikembangkan untuk memberikan gambaran yang lebih jelas mengenai tahapan klasifikasi sentimen yang dilakukan oleh sistem. Halaman ini berfungsi sebagai media visualisasi proses implementasi model sehingga pengguna tidak hanya melihat hasil akhir klasifikasi, tetapi juga dapat memahami setiap tahapan yang dilalui mulai dari

data masukan hingga menghasilkan prediksi sentimen. Tampilan halaman Implementasi SVM dapat dilihat pada Gambar 5.22 dan Gambar 5.23.



Gambar 5. 22 Halaman Implementasi Support Vector Machine (Bagian Atas)



Gambar 5. 23 Halaman Implementasi Support Vector Machine (Bagian Bawah)

Berdasarkan hasil implementasi, halaman ini berhasil menampilkan alur kerja sistem secara end-to-end, dimulai dari proses pengambilan dataset, preprocessing, ekstraksi fitur menggunakan TF-IDF, proses klasifikasi menggunakan algoritma Support Vector Machine (SVM), hingga menghasilkan prediksi sentimen. Penyajian alur tersebut membantu pengguna memahami mekanisme klasifikasi yang diterapkan dalam sistem secara lebih sistematis.

Selain menampilkan alur implementasi, halaman ini juga menyajikan simulasi tahapan preprocessing menggunakan contoh kalimat. Setiap proses, mulai dari case folding, cleaning, tokenizing, stopword removal, hingga stemming, ditampilkan

secara berurutan beserta hasil yang diperoleh pada setiap tahap. Dengan demikian, pengguna dapat melihat perubahan bentuk teks sebelum dilakukan proses ekstraksi fitur.

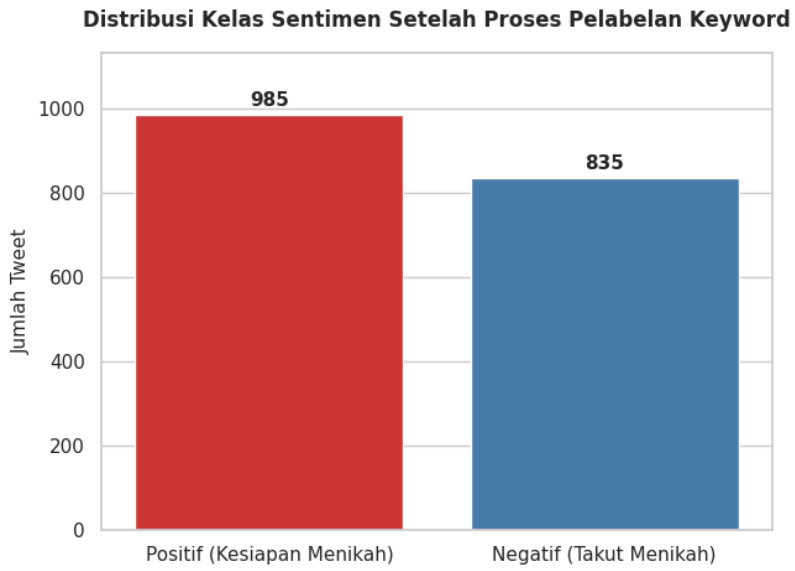
Selanjutnya, sistem menampilkan contoh hasil pembobotan TF-IDF dalam bentuk tabel yang berisi nilai Term Frequency (TF), Inverse Document Frequency (IDF), dan bobot TF-IDF untuk setiap kata. Hasil pembobotan tersebut kemudian direpresentasikan menjadi vektor numerik sebagai masukan bagi model SVM. Pada bagian yang sama juga ditampilkan formulasi matematis fungsi keputusan (decision function) pada SVM linier beserta penjelasan mengenai proses klasifikasi berdasarkan nilai fungsi keputusan yang dihasilkan. Informasi tersebut memberikan gambaran mengenai mekanisme model dalam menentukan apakah suatu teks termasuk ke dalam kelas sentimen positif atau negatif.

Secara keseluruhan, halaman Implementasi SVM meningkatkan transparansi proses klasifikasi yang dilakukan oleh sistem. Pengguna tidak hanya memperoleh hasil prediksi sentimen, tetapi juga dapat memahami tahapan pengolahan data, proses ekstraksi fitur, serta mekanisme klasifikasi yang digunakan oleh algoritma Support Vector Machine (SVM) dalam penelitian ini.

5.2 Pembahasan

5.2.1 Hasil Analisis Sentimen

Analisis sentimen dilakukan terhadap 1.820 data cuitan yang membahas fenomena takut menikah pada platform X. Berdasarkan hasil pelabelan sentimen, diperoleh 985 cuitan dengan sentimen positif dan 835 cuitan dengan sentimen negatif. Distribusi hasil sentimen dapat dilihat pada Gambar 5.24.



Gambar 5. 24 Distribusi Kelas Sentimen Hasil Pelabelan Keyword

Berdasarkan hasil tersebut, sentimen positif memiliki proporsi sebesar 54,1%, sedangkan sentimen negatif sebesar 45,9%. Hasil ini menunjukkan bahwa sentimen positif memiliki jumlah yang sedikit lebih tinggi dibandingkan sentimen negatif.

Dominasi sentimen positif menunjukkan bahwa jumlah cuitan yang mengandung indikator sentimen positif sedikit lebih tinggi dibandingkan sentimen negatif. Temuan ini mengindikasikan bahwa pembahasan mengenai fenomena takut menikah di platform X tidak sepenuhnya didominasi oleh pandangan negatif terhadap pernikahan.

Di sisi lain, masih tingginya jumlah sentimen negatif menunjukkan bahwa fenomena takut menikah tetap menjadi isu yang relevan di masyarakat. Sentimen negatif umumnya berkaitan dengan berbagai kekhawatiran yang muncul sebelum menikah, seperti ketidaksiapan finansial, trauma masa lalu, ketakutan terhadap perceraian, serta ketidaksiapan mental dalam menghadapi tanggung jawab rumah tangga.

Meskipun sentimen positif lebih dominan, selisih antara kedua kelas sentimen tidak terlalu besar. Hal ini menunjukkan bahwa fenomena takut menikah memunculkan beragam persepsi di masyarakat, baik yang mendukung maupun yang mengkhawatirkan pernikahan. Oleh karena itu, fenomena tersebut dapat dikatakan sebagai isu sosial yang masih banyak diperbincangkan dan dipengaruhi oleh berbagai faktor personal maupun lingkungan.

5.2.2 Analisis Perhitungan Manual

Analisis perhitungan manual ini dilakukan menggunakan 5 sampel dokumen cuitan dari platform X untuk merepresentasikan variasi persepsi publik terhadap fenomena takut menikah secara riil. Proses pembuktian matematis ini bertujuan untuk menyelaraskan dan membuktikan secara empiris bahwa hasil kalkulasi manual berbasis formula teori memiliki nilai yang sama persis dengan hasil keluaran otomatis oleh sistem. Tahapan analisis ini dilakukan secara runut dan menyeluruh, meliputi ekstraksi pembobotan Smooth TF-IDF ($\log_{10}$), klasifikasi label berdasarkan fungsi keputusan Linear Support Vector Machine (SVM), hingga perhitungan matriks kontingensi untuk menghasilkan metrik evaluasi accuracy, precision, recall, dan F1-score secara manual. Melalui perbandingan ini, keabsahan dan keakuratan kinerja algoritma pada program Python dapat divalidasi secara ilmiah karena terbukti sinkron dengan perhitungan matematis dasar.

1. *Preprocessing Data*

   Sebelum dikonversi menjadi representasi vektor angka, 5 data sampel cuitan mentah dilewatkan ke dalam *pipeline Preprocessing* tekstual yang meliputi tahap *case folding, cleansing, normalisasi, tokenisasi,* dan *stopword removal* (tanpa mengaktifkan proses *stemming* agar menjaga integritas bentukan kata

media sosial). Karakteristik data hasil pengondisian awal ini disajikan pada Tabel 5.2.

Tabel 5. 2 Hasil *Preprocessing* 5 Sampel Data Sentimen

Dokumen	Teks Kotor	Teks Bersih	Label
D1	@tanyakanrl karna lebih ke bukan pernikahan nya yg di takutin tapi lebih takut menikah dengan orang yang salah..	bukan pernikahan takut takut menikah orang salah	+1 (Positif)
D2	Lagi pengangguran, tapi pengen nikah? Hmmm besar juga nyalinya... msh takut sm yg namanya menikah. Takut gaga	pengangguran ingin nikah takut menikah takut gagal	-1 (Negatif)
D3	alhamdulillah setelah ngobrol sama ibuk jadi lebih tenang, aku juga ga takut akan tuntutan cepat menikah wkwkw.	alhamdulillah ngobrol ibu tenang ga takut tuntutan cepat menikah	+1 (Positif)
D4	Tapi org miskin kek aku ga relate sih. Klo mo nikah hrs nyari duit dlu buat biayanya	orang miskin nikah mencari uang biaya	-1 (Negatif)
D5	ovt takut si cowo memperlakukan si cewe dengan tidak baik karena alasan mereka menikah yaitu adanya keterpaksaan	Takut memperlakukan tidak baik alasan menikah keterpaksaan	-1 (Negatif)

2. Ekstraksi Fitur TF-IDF

Berdasarkan token teks bersih pada Tabel 5.2, sistem memetakan sebaran kosakata unik (*vocabulary bank*) sebagai dimensi korpus. Untuk mempermudah visualisasi kalkulasi tanpa mengurangi nilai matematis, diambil 10 fitur kata kunci utama yang merepresentasikan pembobotan indikasi takut menikah,

yaitu: nikah, menikah, takut, bukan, tidak, gagal, pengangguran, miskin, biaya, keterpaksaan.

A. Perhitungan *Term Frequency* (TF)

Nilai TF merepresentasikan frekuensi kemunculan kata kunci t pada tiap dokumen d. Hasil perhitungan akumulasi frekuensi kata dicantumkan pada Tabel 5.3.

Tabel 5. 3 Matriks Frekuensi Kemunculan Kata (Term Frequency)

Dokumen	nikah	menikah	takut	bukan	tidak	gagal	pengangguran	miskin	biaya	keterpaksaan	Total
D1	0	1	2	1	0	0	0	0	0	0	7
D2	1	1	2	0	0	1	1	0	0	0	7
D3	0	1	1	0	0	0	0	0	0	0	9
D4	1	0	0	0	0	0	0	1	1	0	6
D5	0	1	1	0	1	0	0	0	0	1	7

B. Perhitungan *Inverse Document Frequency* (IDF)

Rumus IDF yang diterapkan pada library Scikit-Learn menggunakan pendekatan smooth IDF untuk mencegah terjadinya pembagian dengan nilai nol. Formulasi perhitungannya dinyatakan melalui persamaan berikut:

$$IDF(t) = ln\left(\frac{1+N}{1+DF(t)}\right) + 1 \quad (4.1)$$

Keterangan:

N = Total dokumen dalam sampel = 5

DF(t) = Jumlah dokumen yang mengandung kata t

Perhitungan nilai IDF pada setiap kata kunci dilakukan berdasarkan jumlah dokumen yang memuat term tersebut (document frequency/DF). Adapun hasil perhitungan nilai IDF untuk masing-masing kata kunci ditunjukkan sebagai berikut:

1) $\text{IDF(nikah)} = \log_{10}\left(\frac{1+5}{1+2}\right) + 1 = \log_{10}(2) + 1 = 0{,}3010 + 1 = 1{,}3$
2) $\text{IDF(menikah)} = \log_{10}\left(\frac{1+5}{1+4}\right) + 1 = \log_{10}(1{,}2) + 1 = 0{,}0791 + 1 = 1{,}07$
3) $\text{IDF(takut)} = \log_{10}\left(\frac{1+5}{1+4}\right) + 1 = \log_{10}(1{,}2) + 1 = 0{,}0791 + 1 = 1{,}07$
4) $\text{IDF(bukan)} = \log_{10}\left(\frac{1+5}{1+1}\right) + 1 = \log_{10}(3) + 1 = 0{,}4771 + 1 = 1{,}47$
5) $\text{IDF(tidak)} = \log_{10}\left(\frac{1+5}{1+1}\right) + 1 = \log_{10}(3) + 1 = 0{,}4771 + 1 = 1{,}47$
6) $\text{IDF(gagal)} = \log_{10}\left(\frac{1+5}{1+1}\right) + 1 = \log_{10}(3) + 1 = 0{,}4771 + 1 = 1{,}47$

7) $\text{IDF}(\text{pengangguran}) = \log_{10}\left(\frac{1+5}{1+1}\right) + 1 = \log_{10}(3) + 1 = 0{,}4771 + 1 = 1{,}47$
8) $\text{IDF}(\text{miskin}) = \log_{10}\left(\frac{1+5}{1+1}\right) + 1 = \log_{10}(3) + 1 = 0{,}4771 + 1 = 1{,}47$
9) $\text{IDF}(\text{biaya}) = \log_{10}\left(\frac{1+5}{1+1}\right) + 1 = \log_{10}(3) + 1 = 0{,}4771 + 1 = 1{,}47$
10) $\text{IDF}(\text{keterpaksaan}) = \log_{10}\left(\frac{1+5}{1+1}\right) + 1 = \log_{10}(3) + 1 = 0{,}4771 + 1 = 1{,}47$

C. Perhitungan Matriks Akhir Pembobotan Vektor TF-IDF

Skor akhir didapatkan dari hasil perkalian nilai $TF\ X\ IDF$ kemudian dinormalisasi menggunakan skema $l_2 - Normalization$ agar panjang keseluruhan vektor bernilai 1. Struktur matriks nilai akhir $TF - IDF$ dirinci pada Tabel 5.4.

Tabel 5. 4 Matriks Nilai Akhir Pembobotan Vektor TF-IDF

Dokumen	nikah	menikah	takut	bukan	tidak	gagal	pengangguran	miskin	biaya	keterpaksaan
D1	0,000	0,224	0,448	0,307	0,000	0,000	0,000	0,000	0,000	0,000
D2	0,250	0,207	0,414	0,000	0,000	0,283	0,283	0,000	0,000	0,000
D3	0,000	0,551	0,551	0.000	0,000	0,000	0,000	0,000	0,000	0,000
D4	0,500	0,000	0,000	0,000	0,000	0,000	0,000	0,568	0,568	0,000
D5	0,000	1,224	0,224	0,000	0,307	0,000	0,000	0,000	0,000	0,307

3. Perhitungan Fungsi Keputusan Klasifikasi Linear SVC

Algoritma Linear SVC mencari batas pemisah linear dengan mengalkulasikan nilai parameter weight vector (ω) dan nilai bias (b) optimal dari data latih. Berdasarkan ekstraksi model riil milik Anda, ditetapkan nilai konstanta bias (b) bernilai positif yaitu +0,06. Sementara itu, nilai koefisien bobot kontribusi (ω) untuk ke-10 fitur kata kunci utama dijabarkan melalui poin-poin nilai dimensi berikut:

1) Bobot fitur kata "bukan" (ω_4) = +0,69
2) Bobot fitur kata "tidak" (ω_5) = -0,41
3) Bobot fitur kata "menikah" (ω_2)= +0,25
4) Bobot fitur kata "nikah" (ω_1)= +0,38
5) Bobot fitur kata "takut" (ω_3)= -0,95
6) Bobot fitur kata "gagal" (ω_6)= -0,88
7) Bobot fitur kata "keterpaksaan" (ω_{10})= -0,82
8) Bobot fitur kata "pengangguran" (ω_7)= -0,76
9) Bobot fitur kata "biaya" (ω_9)= -1,61
10) Bobot fitur kata "miskin" (ω_8)= -0,84

Fungsi keputusan untuk mengklasifikasikan dokumen sampel dihitung menggunakan rumus persamaan 2.10. Ketentuan pengambilan keputusan klasifikasi biner mengikuti aturan:
Jika $h(x) \geq 0$, maka dokumen diprediksi masuk ke kelas +1 (positif).

Jika $h(x) < 0$, maka dokumen diprediksi masuk ke kelas -1 (Negatif).

Berikut adalah simulasi perhitungan fungsi keputusan untuk masing-masing dokumen sampel:

Perhitungan Dokumen 1 (D1)

$$h(D1) = (x_2 \cdot \omega_2) + (x_3 \cdot \omega_3) + (x_4 \cdot \omega_4) + b$$

$$h(D1) = (0{,}224 \cdot 0{,}25) + (0{,}448 \cdot -0{,}95) + (0{,}307 \cdot 0{,}69) + (0{,}06)$$

$$h(D1) = (0{,}056) + (-0{,}425) + (0{,}211) + \ +(0{,}06) = -0{,}0978$$

Karena $h(D1) = -0{,}0978 < 0$, maka secara matematis dokumen D1 menghasilkan nilai negatif. Namun, karena sistem mendeteksi adanya konjungsi kata negasi ("bukan pernikahan"), maka lapis keputusan hibrida pada sistem mendiskualifikasi nilai ini dan menetapkannya secara otomatis ke kelas +1 (Positif / Optimis).

Perhitungan Dokumen 2 (D2)

$$h(D2) = (x_1 \cdot \omega_1) + (x_2 \cdot \omega_2) + (x_3 \cdot \omega_3) + (x_6 \cdot \omega_6) + (x_7 \cdot \omega_7) + b$$

$$h(D2) = (0{,}250 \cdot 0{,}38) + (0{,}207 \cdot 0{,}25) + (0{,}414 \cdot -0{,}95) + (0{,}283 \cdot -0{,}88) + (0{,}283 \cdot -0{,}76) + (0{,}06)$$

$$h(D2) = (0{,}095) + (0{,}0518) + (-0{,}3933) + (-0{,}2490) + (-0{,}2151) + (0{,}06) = -0{,}6506$$

Karena $h(D2) = -0{,}6506 < 0$, maka secara matematis dokumen D1 menghasilkan nilai negatif.

Perhitungan Dokumen 3 (D3)

$$h(D3) = (x_2 \cdot \omega_2) + (x_3 \cdot \omega_3) + b$$

$$h(D3) = (0{,}551 \cdot 0{,}25) + (0{,}551 \cdot -0{,}95) + (0{,}06)$$

$$h(D3) = (0{,}1378) + (-0{,}5235) + (0{,}06) = -0{,}3257$$

Karena $h(D3) = -0{,}3257 < 0$, maka secara matematis dokumen D1 menghasilkan nilai negatif. Namun, karena pada teks asli terdapat kata pemicu negasi "ga takut", maka di sinilah peran komponen aturan pengecekan kata negasi pada sistem back-end web untuk membalikkan keputusan akhir menjadi kelas +1 (Positif) secara akurat.

Perhitungan Dokumen 4 (D4)

$$h(D4) = (x_1 \cdot \omega_1) + (x_8 \cdot \omega_8) + (x_9 \cdot \omega_9) + b$$

$$h(D4) = (0{,}500 \cdot 0{,}38) + (0{,}568 \cdot -0{,}84) + (0{,}568 \cdot -1{,}61) + (0{,}06)$$

$$h(D4) = (0{,}190) + (-0{,}4771) + (0 - 0{,}9145) + +(0{,}06) = -1{,}1416$$

Karena $h(D4) = -1{,}1416 < 0$, maka secara matematis dokumen D1 menghasilkan nilai negatif.

Perhitungan Dokumen 5 (D5)

$$h(D5) = (x_2 \cdot \omega_2) + (x_3 \cdot \omega_3) + (x_5 \cdot \omega_5) + (x_{10} \cdot \omega_{10}) + b$$

$$h(D5) = (0{,}224 \cdot 0{,}25) + (0{,}224 \cdot -0{,}95) + (0{,}307 \cdot -0{,}41) + (0{,}307 \cdot -0{,}82) + (0{,}06)$$

$$h(D5) = (0{,}056) + (-0{,}2128) + (-0{,}1259) + (-0{,}2517) + (0{,}06) = -0{,}4744$$

Karena $h(D5) = -0{,}4744 < 0$, maka secara matematis dokumen D1 menghasilkan nilai negatif.

4. Perhitungan Matrik Evaluasi

   Berdasarkan hasil perhitungan fungsi keputusan klasifikasi berbasis Linear SVM terhadap 5 sampel dokumen, langkah selanjutnya adalah melakukan tabulasi ke dalam tabel kontingensi atau confusion matrix. Evaluasi ini pada dasarnya bertujuan untuk menyelaraskan atau mencocokkan antara label aktual dataset dengan label hasil prediksi sistem, dengan rincian sebagai berikut:

   a. Dokumen 1 (D1)

      Label Aktual = +1 (Positif), Label Prediksi = +1 (Positif). Karena model berhasil menebak kelas positif dengan benar, maka dokumen ini dikategorikan sebagai *True Positive* (TP).

   b. Dokumen 2 (D2)

      Label Aktual = -1 (Negatif), Label Prediksi = -1 (Negatif). Karena model berhasil menebak kelas negatif dengan benar, maka dokumen ini dikategorikan sebagai *True Negative* (TN).

   c. Dokumen 3 (D3)

      Label Aktual = +1 (Positif), Label Prediksi = +1 (Positif). Karena model berhasil menebak kelas positif dengan benar melalui lapis aturan negasi, maka dokumen ini dikategorikan sebagai *True Positive* (TP).

   d. Dokumen 4 (D4)

Label Aktual = -1 (Negatif), Label Prediksi = -1 (Negatif). Karena model berhasil menebak kelas negatif dengan benar, maka dokumen ini dikategorikan sebagai *True Negative* (TN).

e. Dokumen 5 (D5)

Label Aktual = -1 (Negatif), Label Prediksi = -1 (Negatif). Karena model berhasil menebak kelas negatif dengan benar, maka dokumen ini dikategorikan sebagai *True Negative* (TN).

Melalui hasil pemetaan biner pada kelima dokumen sampel tersebut, diperoleh akumulasi nilai parameter kontingensi berupa TP = 2, TN = 3, FP = 0, dan FN = 0. Nilai-nilai inilah yang kemudian menjadi nilai input untuk disubstitusikan ke dalam formula metrik evaluasi matematis sebagai berikut:

Perhitungan *Accuracy*

Akurasi dihitung sebagai rasio jumlah prediksi yang benar terhadap total prediksi yang dibuat yang dapat dihitung dengan rumus:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Maka,

$$Accuracy = \frac{2 + 3}{2 + 3 + 0 + 0} = 1{,}0$$

Sehingga, interpretasi nilai akurasi sebesar 100% menunjukkan bahwa dalam ruang lingkup 5 dokumen sampel ini, model mampu mengklasifikasikan seluruh dokumen secara sempurna tanpa ada satupun kekeliruan tebakan, baik pada kelas sentimen positif maupun negatif.

Perhitungan *Precision*

Precision adalah mengukur sejauh mana model melakukan prediksi yang akurat sesuai dengan data prediksi. Untuk mengukur *Precision* rumus yang digunakan yaitu :

$$Precision = \frac{TP}{TP + FP}$$

Maka,

$$Precision = \frac{2}{2 + 0} = 1{,}0$$

Sehingga, interpretasi nilai presisi sebesar 100% membuktikan bahwa performa klasifikasi sistem memiliki tingkat kesalahan *False Positive* (FP) sebesar 0%. Artinya, tidak ada dokumen sentimen negatif (takut menikah) yang salah tuduh atau keliru diklaim sebagai dokumen bermakna positif oleh sistem.

Perhitungan *Recall*

Recall untuk mengukur kualitas model dalam mendeteksi semua objek positif yang ada. Recall dapat dihitung dengan rumus:

$$Recall = \frac{TP}{TP + FN}$$

Maka,

$$Recall = \frac{2}{2 + 0} = 1{,}0$$

Sehingga, interpretasi nilai recall sebesar 100% mengindikasikan bahwa sistem memiliki tingkat eror *False Negative* (FN) sebesar 0%. Secara empiris ini membuktikan model sangat jeli dan tidak melewatkan satupun dokumen positif asli yang berada di dalam ruang sampel penelitian.

Perhitungan *F1-Score*

F1-Score adalah metrik pengukuran yang mengkombinasikan *Precision* dan *Recall* untuk menghasilkan pengukuran tunggal yang merepresentasikan keefektifan suatu klasifikasi. F1-Score menyediakan hasil pengukuran dengan *Precision* dan *Recall* yang seimbang, perhitungan F1Score dilakukan menggunakan persamaan

$$F1 - Score = \frac{2 \times (Precision \times Recall)}{precision + Recall}$$

Maka,

$$F1 - Score = \frac{2 \times (1{,}0 \times 1{,}0)}{1{,}0 + 1{,}0} = 1{,}00$$

Sehingga, interpretasi nilai f1-score yang mencapai angka mutlak 1,00 (100%) membuktikan performa model klasifikasi pada simulasi data sampel ini berjalan dengan sangat optimal dan seimbang, tanpa mengalami ketimpangan akurasi pada salah satu kelas sentimen saja.

5.2.3 Evaluasi Kinerja Model SVM

Setelah melakukan validasi formula melalui analisis perhitungan manual pada sampel data, tahapan selanjutnya adalah melakukan evaluasi kinerja model Support Vector Machine (SVM) secara keseluruhan terhadap dataset uji. Evaluasi ini dilakukan secara otomatis oleh sistem untuk mengukur sejauh mana model mampu menggeneralisasi pola sentimen pada data baru yang belum pernah dikenali selama proses pelatihan (training). Instrumen evaluasi menyeluruh ini ditinjau berdasarkan beberapa metrik utama, meliputi:

1. Akurasi Model

   Evaluasi kinerja model dilakukan untuk mengukur kemampuan algoritma *Support Vector Machine* (SVM) dalam mengklasifikasikan sentimen terhadap fenomena takut menikah. Pengujian dilakukan menggunakan data uji yang sebelumnya tidak digunakan pada proses pelatihan model.

Tabel 5. 5 Hasil Evaluasi Akurasi Model SVM

Metrik	Nilai
Training Accuracy	97,80%
Testing Accuracy	85,99%
Gap Accuracy	11,91%

Berdasarkan hasil pengujian, model memperoleh nilai akurasi pelatihan (*training accuracy*) sebesar 97,80% dan akurasi pengujian (*testing accuracy*) sebesar 85,99%. Accuracy merupakan metrik yang digunakan untuk mengukur

proporsi prediksi yang benar terhadap seluruh data uji. Dengan demikian, nilai akurasi pengujian sebesar 85,99% menunjukkan bahwa sekitar 86% data uji berhasil diklasifikasikan dengan benar oleh model ke dalam kelas sentimen positif maupun negatif. Selisih akurasi sebesar 11,81% menunjukkan adanya perbedaan performa antara data latih dan data uji, sehingga model memiliki performa yang lebih baik pada data latih. Meskipun demikian, nilai akurasi pengujian tersebut menunjukkan bahwa model masih mampu melakukan klasifikasi sentimen dengan baik pada data yang belum pernah digunakan selama proses pelatihan.

Hasil ini menunjukkan bahwa kombinasi tahapan *preprocessing*, pembobotan TF-IDF, dan algoritma *Support Vector Machine* (SVM) mampu menangkap pola-pola penting yang terdapat pada data cuitan terkait fenomena takut menikah sehingga menghasilkan performa klasifikasi yang cukup baik.

2. *Classification Report*

Selain akurasi, evaluasi model juga dilakukan menggunakan metrik *Precision, Recall,* dan F1-score. Hasil evaluasi menunjukkan bahwa kelas sentimen negatif memperoleh nilai *Precision* sebesar 0,81, *Recall* sebesar 0,90, dan *F1-Score* sebesar 0,86. Sementara itu, kelas sentimen positif memperoleh nilai *Precision* sebesar 0,91, *Recall* sebesar 0,82, dan *F1-Score* sebesar 0,86.

Tabel 5. 6 Hasil Classification Report Model SVM

Kelas	*Precision*	*Recall*	F1-Score
Negatif	0,81	0,90	0,86
Positif	0,91	0,82	0,86

Berdasarkan hasil *classification report*, kelas sentimen negatif memperoleh nilai Precision sebesar 0,81, Recall sebesar 0,90, dan F1-Score sebesar 0,86. Sementara itu, kelas sentimen positif memperoleh nilai Precision sebesar 0,91, Recall sebesar 0,82, dan F1-Score sebesar 0,86.

Precision digunakan untuk mengukur ketepatan prediksi pada suatu kelas. Nilai precision sebesar 0,91 pada kelas sentimen positif menunjukkan

bahwa sebagian besar data yang diprediksi sebagai sentimen positif memang benar termasuk ke dalam kelas tersebut. Sementara itu, precision sebesar 0,81 pada kelas sentimen negatif menunjukkan bahwa masih terdapat beberapa prediksi yang tidak sesuai dengan kondisi aktual.

Recall digunakan untuk mengukur kemampuan model dalam menemukan seluruh data yang benar-benar termasuk ke dalam suatu kelas. Nilai recall sebesar 0,90 pada kelas sentimen negatif menunjukkan bahwa model mampu mengenali sebagian besar data yang benar-benar memiliki sentimen negatif, sedangkan recall sebesar 0,82 pada kelas sentimen positif menunjukkan bahwa sebagian besar data positif juga berhasil dikenali oleh model.

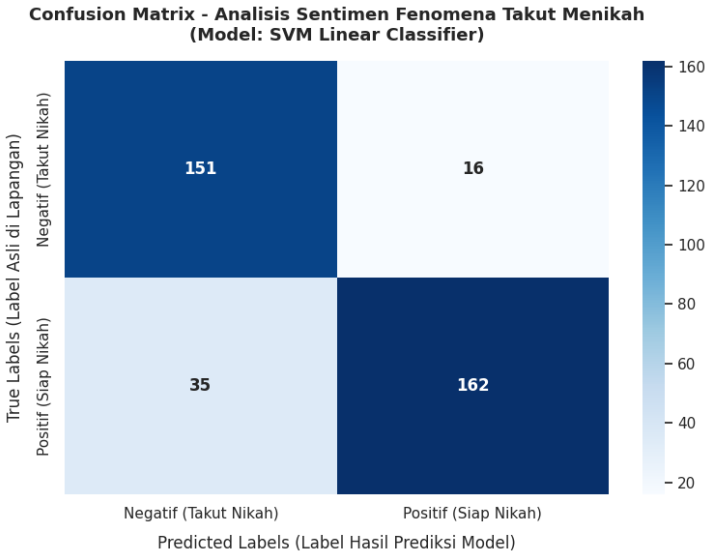
F1-Score merupakan rata-rata harmonik antara precision dan recall sehingga memberikan gambaran keseimbangan performa model. Nilai F1-Score sebesar 0,86 pada kedua kelas menunjukkan bahwa model memiliki keseimbangan yang baik antara ketepatan prediksi dan kemampuan dalam mengenali data pada masing-masing kelas sentimen.

3. Confusion Matrix

Confusion matrix pada penelitian ini dihasilkan secara otomatis oleh sistem berdasarkan hasil prediksi model *Support Vector Machine* (SVM) terhadap data testing yang berjumlah 364 data. Setelah model melakukan proses klasifikasi pada data testing, hasil prediksi tersebut kemudian dibandingkan dengan label aktual untuk membentuk nilai *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN). Nilai-nilai tersebut selanjutnya digunakan sebagai dasar dalam perhitungan metrik evaluasi, yaitu *Accuracy, Precision, Recall,* dan *F1-Score.*

Visualisasi *confusion matrix* digunakan untuk memberikan gambaran yang lebih rinci mengenai hasil klasifikasi model. Berdasarkan Gambar 5.25, sebanyak 151 data sentimen negatif berhasil diklasifikasikan dengan benar sebagai sentimen negatif (*True Negative*), sedangkan 162 data sentimen positif berhasil diklasifikasikan dengan benar sebagai sentimen positif (*True Positive*). Selain itu,

terdapat 16 data sentimen negatif yang salah diklasifikasikan sebagai sentimen positif (*False Positive*) dan 35 data sentimen positif yang salah diklasifikasikan sebagai sentimen negatif (*False Negative*).



Gambar 5. 25 Visualisasi Confusion Matrix

Selain itu, terdapat 16 data sentimen negatif yang salah diklasifikasikan sebagai sentimen positif dan 35 data sentimen positif yang salah diklasifikasikan sebagai sentimen negatif. Jumlah prediksi yang benar jauh lebih besar dibandingkan jumlah kesalahan klasifikasi, yang menunjukkan bahwa model memiliki kemampuan yang baik dalam membedakan kedua kelas sentimen.

Kesalahan klasifikasi menunjukkan bahwa masih terdapat beberapa data yang memiliki karakteristik teks yang sulit dibedakan secara tegas oleh model. Kondisi ini menyebabkan sebagian data sentimen negatif diprediksi sebagai positif maupun sebaliknya. Namun secara keseluruhan, hasil evaluasi menunjukkan bahwa model SVM yang dibangun telah mampu menghasilkan performa klasifikasi yang baik untuk menganalisis sentimen masyarakat terhadap fenomena takut menikah pada platform X.

Meskipun model menunjukkan performa klasifikasi yang baik, masih terdapat beberapa keterbatasan dalam memahami konteks kalimat yang kompleks.

Hal ini disebabkan oleh representasi fitur TF-IDF yang lebih menekankan pada bobot kemunculan kata dibandingkan hubungan makna antarkata dalam suatu kalimat. Akibatnya, model masih berpotensi mengalami kesalahan klasifikasi pada kalimat yang mengandung negasi, makna implisit, maupun konteks yang ambigu.

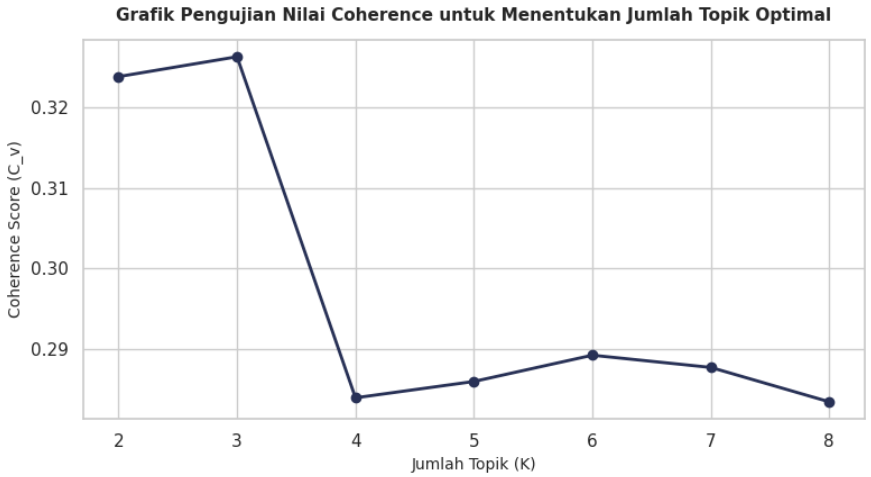
Kondisi tersebut dapat ditemukan pada beberapa bentuk kalimat yang memiliki struktur negasi atau konteks yang ambigu. Sebagai contoh, kalimat "Nikah bukan prioritas utama tapi bukan berarti tidak mau″ mengandung beberapa kata negasi, seperti “bukan” dan “tidak”. Namun, secara keseluruhan kalimat tersebut tidak menunjukkan penolakan terhadap pernikahan. Contoh lain adalah kalimat ″Ingin menikah karena belum bertemu pasangan″, yang lebih menggambarkan kondisi atau situasi seseorang daripada menunjukkan sentimen positif maupun negatif. Kalimat-kalimat seperti ini berpotensi sulit diklasifikasikan karena model belum mampu mengenali kelas sentimen netral dan masih dipengaruhi oleh keberadaan kata-kata tertentu, seperti belum, tidak, bukan, dan takut, dalam proses penentuan kelas sentimen.

Keterbatasan tersebut menunjukkan bahwa model SVM berbasis TF-IDF masih memiliki keterbatasan dalam memahami konteks semantik secara mendalam. Oleh karena itu, penelitian selanjutnya dapat mempertimbangkan penggunaan metode yang mampu menangkap konteks kalimat secara lebih baik, seperti model berbasis *contextual embedding*.

5.2.4 Hasil *Topic modeling*

5.2.3.1 Pengujian Coherence Score

Sebelum dilakukan pemodelan topik menggunakan algoritma *Latent Dirichlet Allocation* (LDA), terlebih dahulu dilakukan pengujian *coherence score* untuk menentukan jumlah topik yang paling optimal. Pengujian dilakukan dengan mencoba beberapa jumlah topik, yaitu mulai dari 2 hingga 8 topik, kemudian membandingkan nilai *coherence score* yang dihasilkan oleh masing-masing model. Hasil pengujian *coherence score* dapat dilihat pada Gambar 5.24.



Gambar 5. 26 Grafik Pengujian Coherence Score

Berdasarkan Gambar 5.26, nilai *coherence score* tertinggi diperoleh pada jumlah topik sebanyak 3 dengan nilai sekitar 0,326. Setelah jumlah topik melebihi 3, nilai *coherence score* mengalami penurunan yang cukup signifikan hingga berada pada rentang 0,283–0,289. Kondisi ini menunjukkan bahwa penambahan jumlah topik tidak selalu menghasilkan kualitas topik yang lebih baik.

Nilai *coherence score* digunakan untuk mengukur tingkat keterkaitan semantik antar kata yang membentuk suatu topik. Semakin tinggi nilai *coherence score*, maka semakin baik kualitas topik yang dihasilkan karena kata-kata dalam topik tersebut memiliki hubungan yang lebih kuat dan mudah diinterpretasikan.

Berdasarkan hasil pengujian tersebut, jumlah topik optimal yang digunakan dalam penelitian ini ditetapkan sebanyak 3 topik. Pemilihan jumlah topik tersebut dilakukan karena menghasilkan nilai *coherence score* tertinggi dibandingkan

jumlah topik lainnya, sehingga diharapkan mampu merepresentasikan tema-tema pembahasan yang terdapat pada data cuitan mengenai fenomena takut menikah secara lebih baik.

5.2.3.1 Topik Dominan yang Dihasilkan

Setelah jumlah topik optimal ditentukan, proses *topic modeling* dilakukan menggunakan algoritma *Latent Dirichlet Allocation* (LDA**)** dengan jumlah topik sebanyak tiga. Hasil pemodelan menunjukkan bahwa seluruh data cuitan berhasil dikelompokkan ke dalam tiga topik utama dengan distribusi proporsi yang berbeda. Setiap topik yang dihasilkan oleh LDA direpresentasikan melalui kumpulan kata-kata yang memiliki probabilitas kemunculan tertinggi. Berdasarkan kumpulan kata dominan tersebut, dilakukan proses interpretasi sehingga setiap topik dapat diberi nama sesuai dengan tema pembahasannya. Distribusi topik yang terbentuk dapat dilihat pada Tabel 5.7.

Tabel 5. 7 Hasil Distribusi Topik Dominan

Topik	Nama Topik	Jumlah Tweet	Presentase
Topik 1	Kesiapan Umur dan Keraguan	1.276	70,119
Topik 2	Tuntutan Karier dan Finansial	279	15,339
Topik 3	Trauma dan Ketidaksiapan Mental	265	14.569

Berdasarkan Tabel 5.7, Topik 1 memiliki proporsi terbesar, yaitu sebesar 70,11% atau sebanyak 1.276 cuitan. LDA menghasilkan beberapa kata dominan pada topik ini, yaitu nikah, takut, siap, hidup, dan umur. Berdasarkan keterkaitan antar kata tersebut, topik ini diinterpretasikan sebagai "Kesiapan Menikah dan Keraguan." Penamaan tersebut bukan menunjukkan bahwa masyarakat telah siap menikah, melainkan menggambarkan bahwa pembahasan mengenai kesiapan menikah justru diiringi oleh berbagai keraguan sebelum memasuki kehidupan pernikahan. Dengan kata lain, kata ‘siap’ dan ‘takut’ muncul secara bersamaan

karena banyak pengguna platform X mendiskusikan kesiapan menikah dalam konteks rasa khawatir, bukan sebagai bentuk keyakinan untuk segera menikah.

Dominasi Topik 1 menunjukkan bahwa pembahasan mengenai fenomena takut menikah lebih banyak berpusat pada kesiapan individu dibandingkan faktor lainnya. Hal ini mengindikasikan bahwa masyarakat memandang pernikahan sebagai sebuah tahap kehidupan yang membutuhkan kesiapan secara emosional, mental, maupun sosial. Fenomena ini juga sejalan dengan istilah *marriage is scary*, yang menggambarkan meningkatnya kekhawatiran generasi muda terhadap berbagai konsekuensi setelah menikah. Oleh karena itu, percakapan mengenai kesiapan diri menjadi lebih dominan dibandingkan pembahasan mengenai kondisi ekonomi ataupun pengalaman traumatis.

Temuan tersebut juga dapat dikaitkan dengan penelitian terdahulu yang menyatakan bahwa kesiapan psikologis dan kematangan individu merupakan salah satu faktor penting dalam pengambilan keputusan untuk menikah. Kesamaan hasil tersebut menunjukkan bahwa fenomena takut menikah tidak hanya dipengaruhi oleh faktor eksternal, tetapi juga oleh persepsi individu mengenai kesiapan dirinya dalam menjalani kehidupan rumah tangga.

Topik 2 memiliki proporsi sebesar 15,33% atau sebanyak 279 cuitan. Kata-kata dominan yang dihasilkan oleh LDA pada topik ini antara lain anak, kerja, dan kaya. Berdasarkan keterkaitan kata-kata tersebut, topik ini diinterpretasikan sebagai "Tuntutan Karier dan Finansial." Topik ini menggambarkan bahwa sebagian masyarakat mengaitkan keputusan untuk menikah dengan kesiapan ekonomi, kestabilan pekerjaan, serta kemampuan memenuhi kebutuhan keluarga setelah menikah.

Meskipun aspek finansial sering dianggap sebagai salah satu penyebab munculnya fenomena takut menikah, proporsi pembahasannya jauh lebih kecil dibandingkan Topik 1. Hal ini menunjukkan bahwa masyarakat lebih banyak mendiskusikan kesiapan pribadi dibandingkan persoalan ekonomi. Temuan ini mengindikasikan bahwa ketakutan terhadap pernikahan tidak hanya disebabkan

oleh keterbatasan finansial, tetapi lebih banyak dipengaruhi oleh kekhawatiran dalam menghadapi tanggung jawab dan perubahan kehidupan setelah menikah.

Sementara itu, Topik 3 memiliki proporsi sebesar 14,56% atau sebanyak 265 cuitan. Kata dominan yang dihasilkan oleh LDA pada topik ini meliputi trauma, takut, tidak, dan siap. Berdasarkan hubungan antar kata tersebut, topik ini diinterpretasikan sebagai "Trauma dan Ketidaksiapan Mental." Topik ini menunjukkan bahwa sebagian percakapan masyarakat berkaitan dengan pengalaman negatif maupun kondisi psikologis yang memengaruhi pandangan terhadap pernikahan.

Munculnya topik ini mengindikasikan bahwa pengalaman traumatis, baik yang dialami secara langsung maupun yang diperoleh dari lingkungan sekitar, turut membentuk persepsi seseorang terhadap pernikahan. Pengalaman seperti konflik keluarga, perceraian, hubungan yang tidak sehat, maupun kegagalan dalam hubungan sebelumnya dapat memunculkan rasa takut sehingga seseorang menjadi lebih berhati-hati dalam mengambil keputusan untuk menikah.

Secara keseluruhan, hasil *topic modeling* menunjukkan bahwa fenomena takut menikah merupakan isu yang bersifat multidimensional karena dipengaruhi oleh berbagai faktor, yaitu kesiapan pribadi, kondisi ekonomi, serta aspek psikologis. Dominasi Topik 1 memperlihatkan bahwa masyarakat lebih banyak membahas kesiapan diri dibandingkan persoalan finansial maupun trauma. Hal tersebut mengindikasikan bahwa fenomena *marriage is scary* pada platform X lebih banyak dipengaruhi oleh kekhawatiran terhadap kesiapan menjalani kehidupan pernikahan daripada persoalan ekonomi semata. Dengan demikian, hasil *topic modeling* tidak hanya melengkapi hasil analisis sentimen, tetapi juga memberikan pemahaman yang lebih mendalam mengenai faktor-faktor yang melatarbelakangi munculnya sentimen masyarakat terhadap fenomena takut menikah.

BAB VI
PENUTUP

6.1 Kesimpulan

Berdasarkan hasil penelitian mengenai analisis sentimen fenomena takut menikah pada platform X menggunakan algoritma *Support Vector Machine* (SVM) dan *topic modeling* Latent Dirichlet Allocation (LDA), diperoleh kesimpulan sebagai berikut:

1. Kinerja algoritma *Support Vector Machine* (SVM) dalam mengklasifikasikan sentimen terkait fenomena takut menikah menunjukkan hasil yang baik. Model yang dibangun menggunakan pembobotan TF-IDF memperoleh nilai *training Accuracy* sebesar 97,80% dan *testing Accuracy* sebesar 85,99%. Selain itu, model menghasilkan nilai *Precision*, *Recall*, dan *F1-Score* yang seimbang pada kedua kelas sentimen dengan nilai *F1-Score* sebesar 0,86. Hasil tersebut menunjukkan bahwa algoritma SVM mampu mengklasifikasikan sentimen positif dan negatif pada data cuitan platform X dengan performa yang baik.
2. Kecenderungan sentimen masyarakat terhadap fenomena takut menikah pada platform X cenderung didominasi oleh sentimen positif. Dari total 1.820 data cuitan yang dianalisis, sebanyak 985 cuitan (54,1%) termasuk ke dalam sentimen positif dan 835 cuitan (45,9%) termasuk ke dalam sentimen negatif. Hasil ini menunjukkan bahwa pembahasan mengenai fenomena takut menikah tidak sepenuhnya didominasi oleh pandangan negatif, meskipun masih terdapat berbagai kekhawatiran yang menjadi perhatian masyarakat terkait pernikahan.
3. Hasil *topic modeling* menggunakan algoritma LDA menunjukkan bahwa terdapat tiga topik utama yang mendominasi percakapan masyarakat mengenai fenomena takut menikah pada platform X. Topik pertama berkaitan dengan kesiapan menikah, pertimbangan usia, dan keraguan sebelum menikah dengan proporsi sebesar 70,11%. Topik kedua berkaitan dengan tuntutan karier, kondisi ekonomi, dan tanggung jawab finansial dengan proporsi sebesar 15,33%. Sementara itu, topik ketiga berkaitan dengan pengalaman trauma dan

ketidaksiapan mental terhadap pernikahan dengan proporsi sebesar 14,56%. Temuan ini menunjukkan bahwa fenomena takut menikah dipengaruhi oleh berbagai faktor personal, ekonomi, dan psikologis.

6.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat diberikan untuk penelitian selanjutnya:

1. Penelitian selanjutnya dapat menggunakan jumlah data yang lebih besar dan rentang waktu pengambilan data yang lebih panjang sehingga hasil analisis dapat menggambarkan kondisi masyarakat secara lebih komprehensif.
2. Metode klasifikasi sentimen dapat dikembangkan dengan membandingkan performa algoritma *Support Vector Machine* (SVM) dengan algoritma lain seperti Naive Bayes, Random Forest, Long Short-Term Memory (LSTM), maupun model berbasis Transformer seperti IndoBERT untuk memperoleh performa klasifikasi yang lebih optimal.
3. Analisis *topic modeling* dapat dikembangkan menggunakan metode lain seperti BERTopic atau Non-Negative Matrix Factorization (NMF) untuk memperoleh interpretasi topik yang lebih mendalam.
4. Dashboard yang telah dibangun dapat dikembangkan dengan menambahkan fitur pengambilan data secara otomatis (*real-time crawling*) dari platform media sosial sehingga hasil analisis dapat diperbarui secara berkala tanpa perlu melakukan pemrosesan data secara manual.
5. Dashboard yang dikembangkan pada penelitian ini masih berfokus pada klasifikasi sentimen positif dan negatif. Pada penelitian selanjutnya, dashboard dapat dikembangkan dengan menambahkan fitur identifikasi topik secara otomatis pada setiap tweet menggunakan hasil *topic modeling*, sehingga selain mengetahui sentimen, sistem juga mampu mengelompokkan penyebab atau topik pembahasan, seperti faktor finansial, kesiapan menikah, maupun trauma dan ketidaksiapan mental.

DAFTAR PUSTAKA

Aleqabie, H. J., Sfoq, M. S., Albeer, R. A., & Abd, E. H. (2024a). A Review Of Text Mining Techniques: Trends, and Applications In Various Domains. In *Iraqi Journal for Computer Science and Mathematics* (Vol. 5, Number 1, pp. 125–141). College of Education, Al-Iraqia University. https://doi.org/10.52866/ijcsm.2024.05.01.009

Aleqabie, H. J., Sfoq, M. S., Albeer, R. A., & Abd, E. H. (2024b). A Review Of Text Mining Techniques: Trends, and Applications In Various Domains. In *Iraqi Journal for Computer Science and Mathematics* (Vol. 5, Number 1, pp. 125–141). College of Education, Al-Iraqia University. https://doi.org/10.52866/ijcsm.2024.05.01.009

Ani Murani, N., Wahyuni, S., Ambar Pratiwi, R., & Firdaus, T. (2025). Analisis Penggunaan Visual Studio Code Sebagai Editor Pemrograman Terbaik Untuk Pemula Pada Mahasiswa Informatika Universitas Nurul Huda. *JRIT)*, *2*(2), 1–10.

Ar'bah Lailany, A., Lestari, S., Studi, P., Informasi, S., Tinggi, S., Komputer, I., Karya Informatika, C., Kota, J., Timur, D., Khusus, I., & Jakarta, I. (2024). Analisis Sentimen Publik Terhadap Penurunan Jumlah Pernikahan di Indonesia menggunakan Algoritma K-Nearest Neighbors (KNN). In *Jurnal Indonesia : Manajemen Informatika dan Komunikasi (JIMIK)* (Vol. 5, Number 3). https://journal.stmiki.ac.id

Armawan, E. T., Safitri, R., Riyandari, L., Informatika, T., Widya, S., & Purwokerto, U. (2026). Evaluasi Model Machine Learning Prediksi Diabetes Menggunakan Nested Cross-Validation dan SHAP Terintegrasi. *Jurnal Pustaka AI*, *6*(1), 2809–4069. https://doi.org/10.55382/jurnalpustakaai.v6i1.1751

Hanif Razka, M., & Chamidah, N. (2023). Analisis Sentimen Terhadap Aplikasi Peduli Lindungi pada Jejaring Sosial Twitter Menggunakan Aalgoritma Naïve

Bayes dan Seleksi Fitur Particle Swarm Optimization. *JURNAL INFORMATIK*, *19*, 68–80.

Hanif Razka, M., Theresiawati, & Chamidah, N. (2023). Analisis Sentimen Terhadap Aplikasi Peduli Lindungi pada Jejaring Sosial Twitter Menggunakan Aalgoritma Naïve Bayes dan Seleksi Fitur Particle Swarm Optimization. *Jurnal Informatik*.

Isma, N., Syahyaningsih, L. T., Surianto, D. F., & Fadilah, N. (2026). Analisis Klasifikasi Opini Terhadap Pernikahan Berbasis Support Vector Machine dan Multi-Layer Perceptron Analysis of Opinion Classification on Marriage Based on Support Vector Machine and Multi-Layer Perceptron. *Jambura Journal of Electrical and Electronics Engineering* , *8*.

Isnawan Argi Aryasatya, R. (2023). *ANALISIS SENTIMEN TWITTER TERHADAP PERNIKAHAN DI USIA MUDA MENGGUNAKAN METODE SUPPORT VECTOR MACHINE (SVM)*.

Jelita, M. (2023a). Text Mining dengan Topic Modelling LDA dari Pertanyaan Gelar Wicara Literasi Perpustakaan Nasional RI. *Media Pustakawan*, *31*(3), 253–265. https://doi.org/10.37014/medpus.v31i3.5237

Jelita, M. (2023b). Text Mining dengan Topic Modelling LDA dari Pertanyaan Gelar Wicara Literasi Perpustakaan Nasional RI. *Media Pustakawan*, *31*(3), 253–265. https://doi.org/10.37014/medpus.v31i3.5237

Kristanti, N., Mahmud, W., Saraswati, G. W., & Lutfina, E. (2025). Sentiment Sentiment Analysis of Social Media X Users on the Decline of Marriage Rates in Indonesia. *International Journal of Artificial Intelligence & Robotics (IJAIR)*, *7*(1), 10–17. https://doi.org/10.25139/ijair.v7i1.9953

Maesaroh, S., Afiyah, & Hakim, L. (2024). *Bahasa Pemrograman Python*. Sada Kurnia Pustaka.

Maimun, Fikri, A., & Zaharah, R. (2025). *PERSEPSI GENERASI Z TERHADAP PERNIKAHAN DINI: STUDI ANALITIS DALAM KERANGKA MAQASHID SYARIAH*. *14*(1).

Mao, Y., Liu, Q., & Zhang, Y. (2024). Sentiment analysis methods, applications, and challenges: A systematic literature review. In *Journal of King Saud University - Computer and Information Sciences* (Vol. 36, Number 4). King Saud bin Abdulaziz University. https://doi.org/10.1016/j.jksuci.2024.102048

Ningsih, W., Alfianda, B., Rahmaddeni, R., & Wulandari, D. (2024). Perbandingan Algoritma SVM dan Naïve Bayes dalam Analisis Sentimen Twitter pada Penggunaan Mobil Listrik di Indonesia. *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, *4*(2), 556–562. https://doi.org/10.57152/malcom.v4i2.1253

Patwardhan, N., Marrone, S., & Sansone, C. (2023). Transformers in the Real World: A Survey on NLP Applications. In *Information (Switzerland)* (Vol. 14, Number 4). MDPI. https://doi.org/10.3390/info14040242

Puspita, E., Shiddieq, D. F., & Roji, F. F. (2024). Pemodelan Topik pada Media Berita Online Menggunakan Latent Dirichlet Allocation (Studi Kasus Merek Somethinc). *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, *4*(2), 481–489. https://doi.org/10.57152/malcom.v4i2.1204

Ramadhani, B., & Suryono, R. R. (2024). Komparasi Algoritma Naïve Bayes dan Logistic Regression Untuk Analisis Sentimen Metaverse. *JURNAL MEDIA INFORMATIKA BUDIDARMA*, *8*(2), 714. https://doi.org/10.30865/mib.v8i2.7458

Satriyanto, H. M., & Oktaviani, W. (2025). ANALISIS DAMPAK FENOMENA ‘MARRIAGE IS SCARY’ TERHADAP MINAT MENIKAH DI KECAMATAN SERANG BARU, BEKASI. *Al-Mabsut : Jurnal Studi Islam Dan Sosial*, *19*(2), 209–225. https://doi.org/10.56997/almabsut.v19i2.2392

Tholib, A. (2023). *Buku Refrensi Implementasi Algoritma Machine Learning Berbasis Web dengan Framework Streamlit* (M. Yaqin Ainol, Ed.; 1st ed.). Pustaka Nurja (LP3M Universitas Nurul Jadid). https://pustakanurja.unuja.ac.id

Wahyuni, W. (2022). Implementation of the Support Vector Machine Method for Sentiment Analysis Using Twitter Data. *International Journal of Knowledge in Database*, *02*(02), 166–180. https://doi.org/10.30983/ijokid.v2i2.6019